Ejercicios de Análisis Factorial

Jan Żurek y Guido D'Inverno

03/2026

Contents

Ejercicio 1: Análisis Factorial de dataset 'iq.xls' **1**
1.3.1. Análisis previos . . . 1
1.3.2. Determinación del número de factores . . . 4
1.3.3. Análisis factorial por Componentes Principales . . . 8
1.3.4. Comunalidades . . . 9
1.3.5. Rotaciones . . . 12
1.3.6. Medidas de consistencia . . . 16
1.3.7. Puntuaciones factoriales . . . 17

Ejercicio 2: Análisis Factorial de dataset 'sdq.xls' **18**
2.3.1. Análisis previos . . . 18
2.3.2 Determinación del número de factores . . . 25
2.3.3. Análisis factorial . . . 27
2.3.4 Comunalidades . . . 28
2.3.5 Rotaciones . . . 30
2.3.6 Alpha de Cronbach . . . 41

Ejercicio 3: Análisis Factorial de dataset 'adhd.xls.' **42**
3.3.1 Análisis previos . . . 42
3.3.2 Determinación del número de factores . . . 46
3.3.3 Análisis factorial . . . 50
3.3.4 Comunalidad . . . 52
3.3.5 Rotacion . . . 56
3.3.6 Verifica della Alpha di Cronbach . . . 58

Ejercicio 1: Análisis Factorial de dataset 'iq.xls'

1.3.1. Análisis previos

Al principio, leemos los datos y comprobamos su estructura.

```
iq <- read_xls("iq.xls", na = "?")
pander(head(iq))
```

vocab1	designs1	similar1	matrix1	veranal2	vocab2	matrix2	designs2
113	124	118	122	116	115	127	105
100	95	115	97	121	102	106	112
124	115	122	116	117	109	119	118
125	110	124	130	114	115	126	127
103	89	109	91	106	102	101	97

vocab1	designs1	similar1	matrix1	veranal2	vocab2	matrix2	designs2
88	113	89	110	96	88	109	111

```r
pander(summary(iq))
```

Table 2: Table continues below

vocab1	designs1	similar1	matrix1
Min. : 55.0	Min. : 58.00	Min. : 55.0	Min. : 55.00
1st Qu.: 88.0	1st Qu.: 89.00	1st Qu.: 94.0	1st Qu.: 89.00
Median : 98.0	Median : 97.00	Median :104.0	Median :102.00
Mean : 97.5	Mean : 97.65	Mean :103.6	Mean : 99.53
3rd Qu.:109.0	3rd Qu.:107.50	3rd Qu.:115.2	3rd Qu.:112.00
Max. :137.0	Max. :130.00	Max. :145.0	Max. :134.00

veranal2	vocab2	matrix2	designs2
Min. : 57.0	Min. : 37.0	Min. : 49.00	Min. : 45.00
1st Qu.: 94.0	1st Qu.: 92.0	1st Qu.: 91.75	1st Qu.: 93.75
Median :104.0	Median :102.0	Median :103.00	Median :102.00
Mean :101.5	Mean :100.6	Mean :101.45	Mean :100.64
3rd Qu.:111.0	3rd Qu.:111.0	3rd Qu.:112.00	3rd Qu.:110.00
Max. :134.0	Max. :144.0	Max. :137.00	Max. :137.00

```r
test <- mvn(iq, univariate_test = "SW")
pander(test$multivariate_normality)
```

Test	Statistic	p.value	Method	MVN
Henze-Zirkler	0.982	0.171	asymptotic	Normal

```r
pander(test$univariate_normality)
```

Test	Variable	Statistic	p.value	Normality
Shapiro-Wilk	vocab1	0.981	0.034	Not normal
Shapiro-Wilk	designs1	0.989	0.3	Normal
Shapiro-Wilk	similar1	0.98	0.029	Not normal
Shapiro-Wilk	matrix1	0.974	0.006	Not normal
Shapiro-Wilk	veranal2	0.97	0.002	Not normal
Shapiro-Wilk	vocab2	0.959	<0.001	Not normal
Shapiro-Wilk	matrix2	0.975	0.007	Not normal
Shapiro-Wilk	designs2	0.98	0.023	Not normal

```r
pander(test$descriptives)
```

Table 6: Table continues below

Variable	n	Mean	Std.Dev	Median	Min	Max	25th	75th	Skew
vocab1	152	97.5	17.34	98	55	137	88	109	-0.315
designs1	152	97.65	14.47	97	58	130	89	107.5	-0.213
similar1	152	103.6	17.26	104	55	145	94	115.2	-0.453
matrix1	152	99.53	16.61	102	55	134	89	112	-0.524
veranal2	152	101.5	14.77	104	57	134	94	111	-0.623
vocab2	152	100.6	16.42	102	37	144	92	111	-0.812
matrix2	152	101.4	16.17	103	49	137	91.75	112	-0.574
designs2	152	100.6	13.92	102	45	137	93.75	110	-0.454

Kurtosis
2.994
2.981
3.308
3.114
3.388
4.788
3.832
4.358

Vemos que los datos han superado con éxito la prueba de normalidad multidimensional (Henze-Zirkler) y que el índice de asimetría es pequeño (inferior a 1); por lo tanto, aunque los valores individuales de las variables no siguen una distribución normal, podemos pasar al análisis factorial.

Veamos cómo es la matriz de correlación y su determinante.

```
R <- cor(iq, method = "pearson")
corrplot(R, sig.level = 0.05, typ = "lower")
```

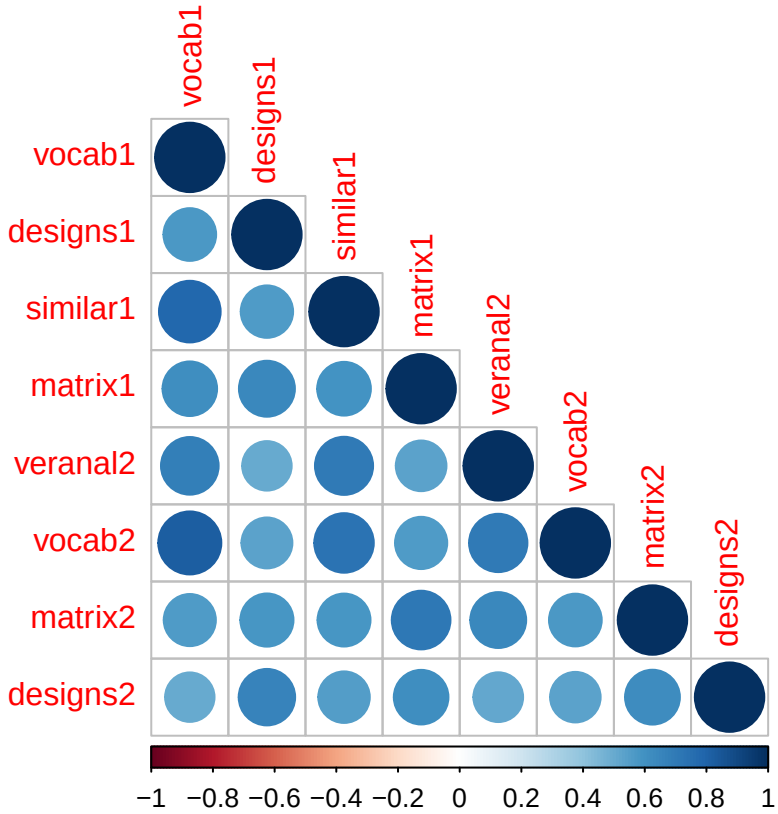


```r
det(R)
```

```
## [1] 0.002444148
```

Vemos que el coeficiente determinante es prácticamente nulo y que la matriz de correlaciones muestra correlaciones fuertes, lo que nos permite concluir que el análisis factorial está justificado.

Prueba Kayser-Meyer-Olkin (KMO)

```r
KMO(iq)
```

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = iq)
## Overall MSA =  0.9
## MSA for each item =
##   vocab1 designs1 similar1  matrix1 veranal2   vocab2  matrix2 designs2
##     0.87     0.92     0.93     0.90     0.92     0.90     0.89     0.91
```

Vemos que tanto las columnas individuales como el conjunto de datos en su conjunto obtienen una puntuación muy alta en esta prueba (alrededor de 0,9), por lo que estos datos son ideales para realizar un análisis factorial.

1.3.2. Determinación del número de factores

Pasemos a determinar el número adecuado de factores para nuestro análisis. En primer lugar, veamos cuáles son los valores propios de la matriz de correlaciones. Según el criterio de Kaiser, deberíamos seleccionar tantos factores como valores propios sean mayores que 1.

```r
eigen(R)$values
```

```
## [1] 5.3280352 0.8370123 0.4743501 0.3989081 0.3203761 0.2683994 0.2193804
```

```
## [8] 0.1535386
```

Hagamos un ACP y veamos qué porcentaje de la información total de la prueba aporta cada componente.

```r
fac <- prcomp(iq, scale.=TRUE, tol=NULL)
summary(fac)
```

```
## Importance of components:
##                          PC1    PC2     PC3     PC4     PC5     PC6     PC7
## Standard deviation     2.308 0.9149 0.68873 0.63159 0.56602 0.51807 0.46838
## Proportion of Variance 0.666 0.1046 0.05929 0.04986 0.04005 0.03355 0.02742
## Cumulative Proportion  0.666 0.7706 0.82992 0.87979 0.91984 0.95339 0.98081
##                            PC8
## Standard deviation     0.39184
## Proportion of Variance 0.01919
## Cumulative Proportion  1.00000
```

Visualización de la varianza

```r
fac2 <- get_eigenvalue(fac)
barplot(fac2[,2],
        main = "Varianzas",
        xlab = "factores",
        ylab = "Porcentaje de varianza",
        col ="blue")
```

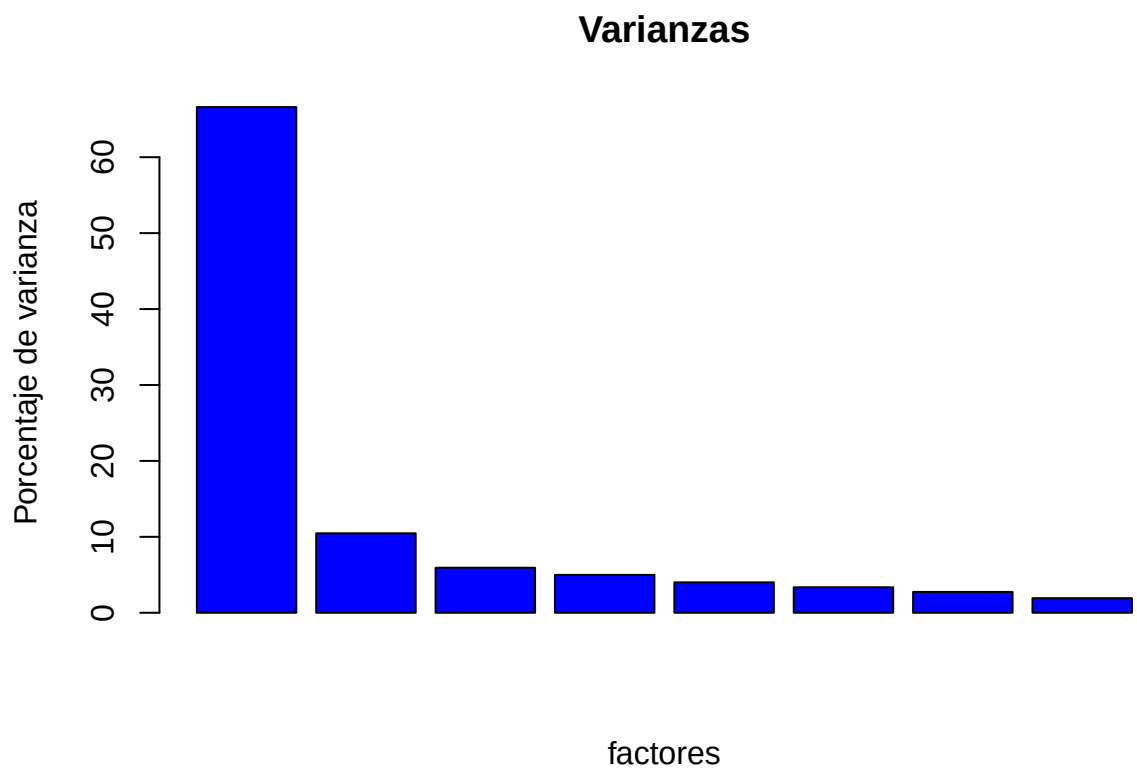

Scree plots

```r
fviz_screeplot(fac, ncp = 8, addlabels = TRUE)
```

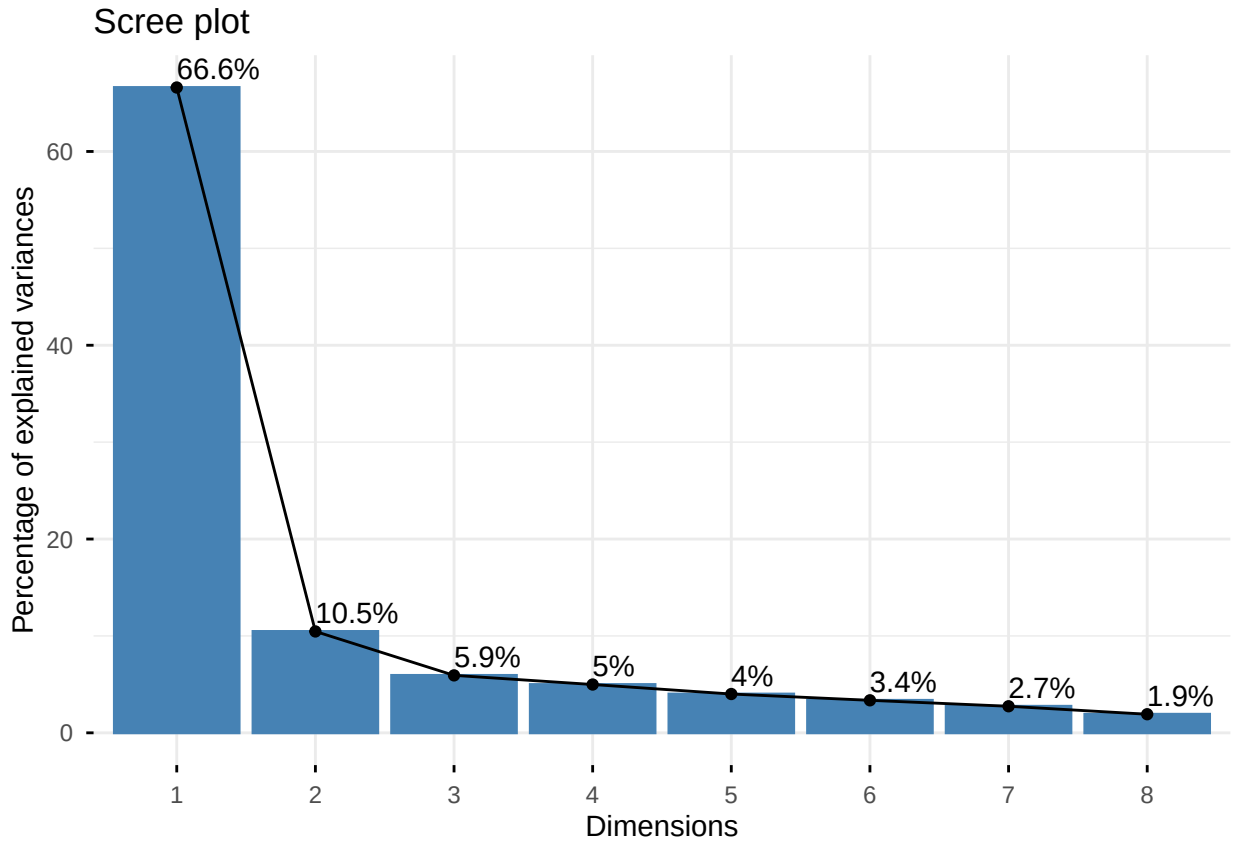


```r
fa.parallel(iq, n.obs = nrow(iq), fa = "fa", fm = "ml")
```

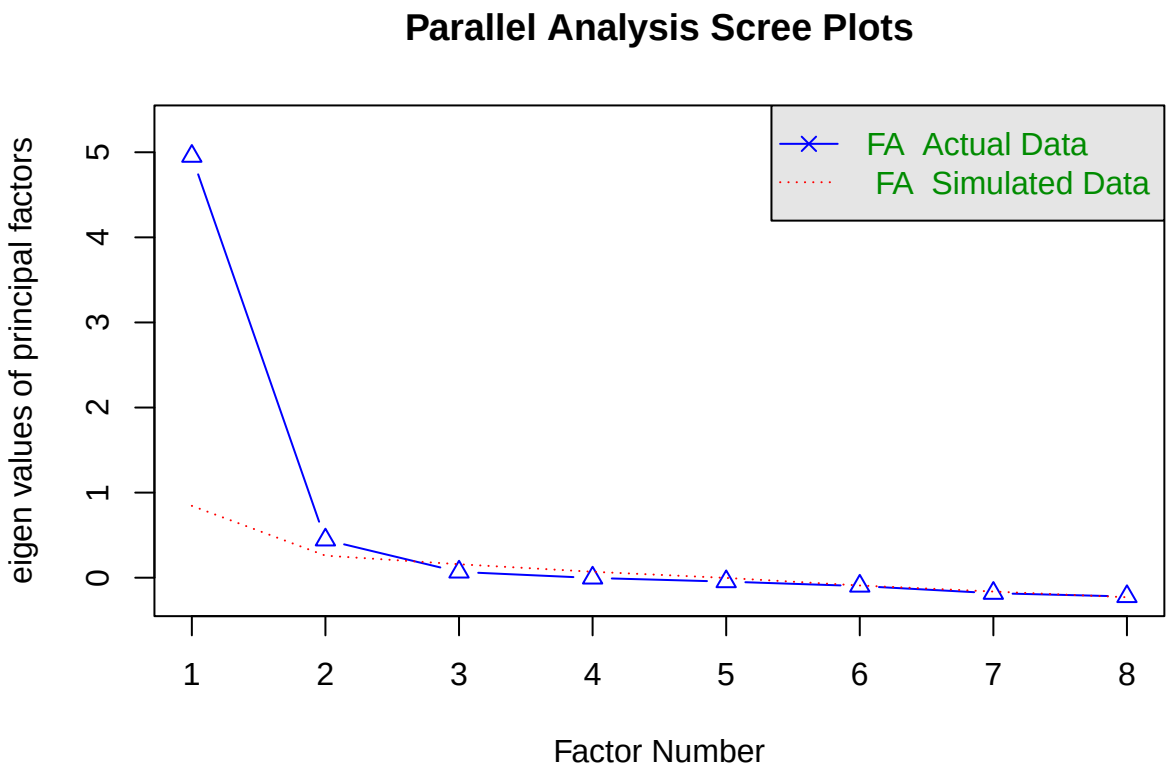


```
## Parallel analysis suggests that the number of factors =  2  and the number of components =  NA
```

```r
ac <- parallel(subject = nrow(iq), var = ncol(iq), rep = 100, cent = .05)
nS <- nScree(x = eigen(R)$values, aparallel = ac$eigen$qevpea)
plotnScree(nS)
```

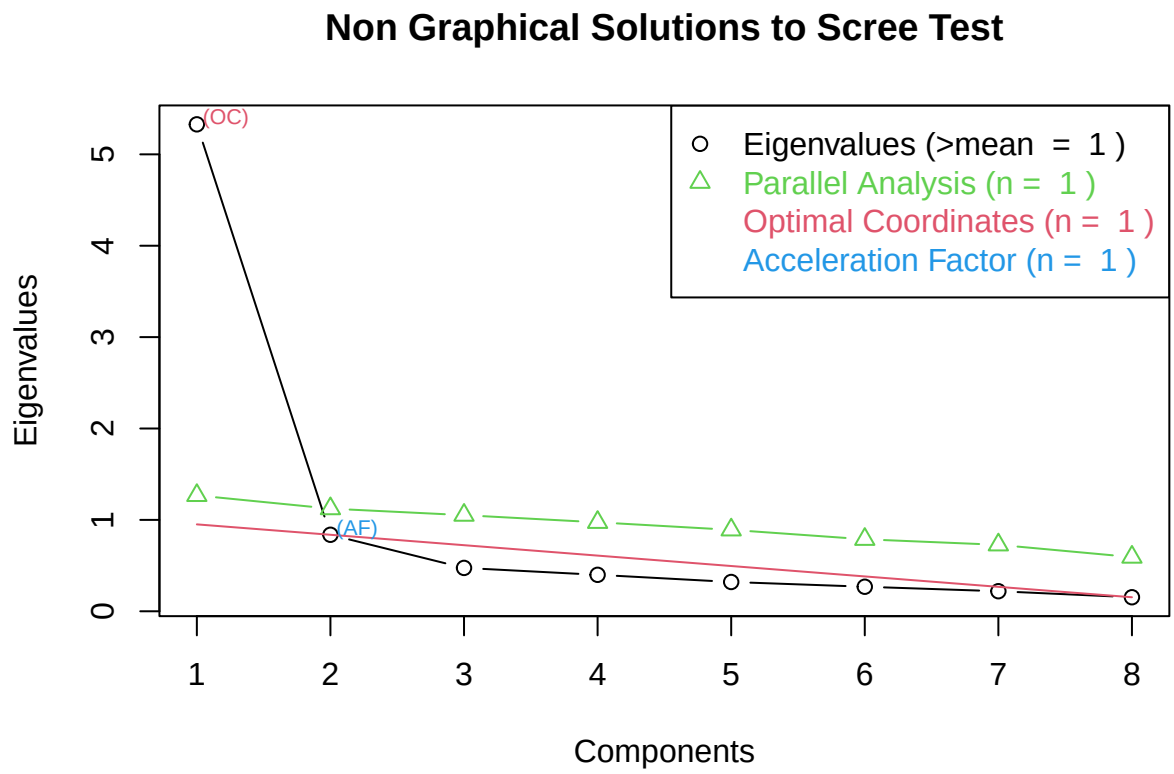

Utilizando los métodos anteriores, podemos afirmar sin lugar a dudas que lo mejor es utilizar dos factores.

1.3.3. Análisis factorial por Componentes Principales

```
facCP<-prcomp(iq, scale.=TRUE, tol=NULL)
summary(facCP)
```

```
## Importance of components:
##                          PC1    PC2     PC3     PC4     PC5     PC6     PC7
## Standard deviation     2.308 0.9149 0.68873 0.63159 0.56602 0.51807 0.46838
## Proportion of Variance 0.666 0.1046 0.05929 0.04986 0.04005 0.03355 0.02742
## Cumulative Proportion  0.666 0.7706 0.82992 0.87979 0.91984 0.95339 0.98081
##                            PC8
## Standard deviation     0.39184
## Proportion of Variance 0.01919
## Cumulative Proportion  1.00000
```

```
cargasCP <- matrix(0,8,2)
for (i in 1:2){
  cargasCP[,i] <- facCP$rotation[,i] * facCP$sdev[i]
}
cargasCP
```

```
##            [,1]       [,2]
## [1,] -0.8589096  0.3404496
## [2,] -0.7747246 -0.3545584
## [3,] -0.8514118  0.2734360
```

```
## [4,] -0.8097354 -0.3055045
## [5,] -0.8146508  0.2669614
## [6,] -0.8445152  0.3496807
## [7,] -0.8092464 -0.2473950
## [8,] -0.7601291 -0.4153855
```

```
fa.diagram(cargasCP)
```

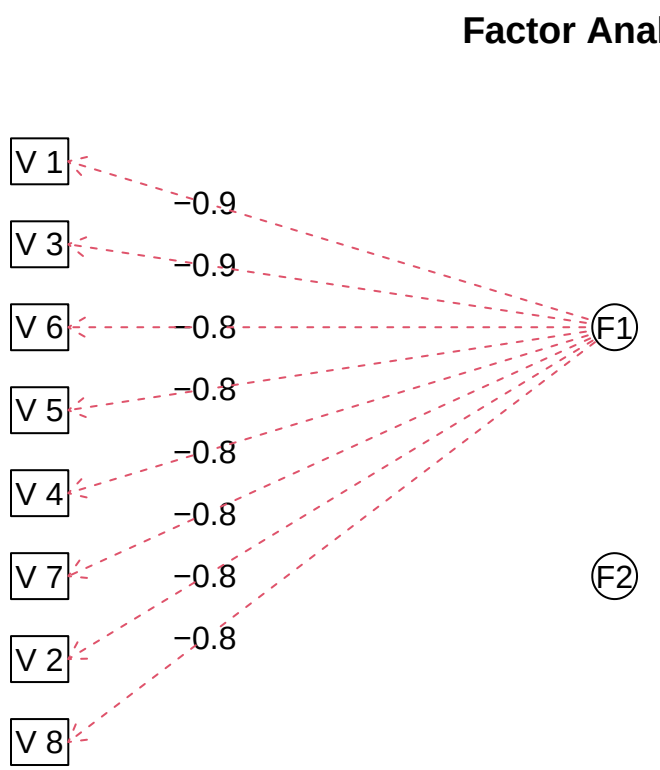

1.3.4. Comunalidades

```
comunalidadCP<-matrix(0,8,2)
for (i in 1:8)
  {for (j in 1:2)
  {comunalidadCP[i,1]=comunalidadCP[i,1]+cargasCP[i,j]^2
    comunalidadCP[i,2]=1-comunalidadCP[i,1]}}
comunalidadCP
```

```
##           [,1]      [,2]
## [1,] 0.8536317 0.1463683
## [2,] 0.7259098 0.2740902
## [3,] 0.7996693 0.2003307
## [4,] 0.7490044 0.2509956
## [5,] 0.7349243 0.2650757
## [6,] 0.8354825 0.1645175
## [7,] 0.7160840 0.2839160
## [8,] 0.7503415 0.2496585
```

Interpretación de Comunalidades y Unicidad

Los resultados muestran **comunalidades altas** (columna 1), todas situadas por encima de **0.70**. Esto indica que los factores extraídos explican más del 70% de la varianza de cada test original, lo cual es un resultado excelente en psicometría. La variable con mejor ajuste es la primera (0.85).

Por otro lado, la **unicidad** (columna 2) es baja en todas las variables (inferior a 0.30), lo que confirma que se pierde muy poca información y el error es mínimo.

En conclusión: El modelo factorial es muy robusto y representa de forma precisa la estructura de los datos originales de inteligencia.

```
variablesCP<-get_pca_var(facCP)
variablesCP$coord[,1:2]
```

```
##               Dim.1      Dim.2
## vocab1   -0.8589096  0.3404496
## designs1 -0.7747246 -0.3545584
## similar1 -0.8514118  0.2734360
## matrix1  -0.8097354 -0.3055045
## veranal2 -0.8146508  0.2669614
## vocab2   -0.8445152  0.3496807
## matrix2  -0.8092464 -0.2473950
## designs2 -0.7601291 -0.4153855
```

Interpretación de las Dimensiones (Cargas Factoriales)

1. **Dimensión 1 (Factor General):** Presenta cargas muy altas y uniformes (entre **-0.76 y -0.86**) en todas las variables. Esto indica la existencia de un **Factor General de Inteligencia (*g*)**. Todas las pruebas, tanto verbales como espaciales, saturan fuertemente en esta dimensión, lo que demuestra que comparten una base común de capacidad cognitiva.
2. **Dimensión 2 (Factor de Contraste):** Esta dimensión actúa como un diferenciador entre los dos tipos de habilidades medidas:
   - **Habilidades Verbales:** Las variables `vocab1`, `similar1`, `veranal2` y `vocab2` tienen cargas **positivas** (aprox. 0.27 a 0.35).
   - **Habilidades No Verbales/Espaciales:** Las variables `designs1`, `matrix1`, `matrix2` y `designs2` tienen cargas **negativas** (aprox. -0.24 a -0.41).

Conclusión: Mientras que la Dimensión 1 mide la inteligencia global, la Dimensión 2 divide claramente los tests en dos grupos: **capacidad verbal frente a capacidad manipulativa/espacial**.

```
var.cos2 <- variablesCP$cor^2
comunalidadCP2=matrix(0,8,3)
for (i in 1:8)
{for (j in 1:2)
{comunalidadCP2[i,j]=var.cos2[i,j]}
  comunalidadCP2[i,3]=comunalidadCP2[i,1]+comunalidadCP2[i,2]}
comunalidadCP2
```

```
##           [,1]       [,2]      [,3]
## [1,] 0.7377257 0.11590593 0.8536317
## [2,] 0.6001982 0.12571165 0.7259098
## [3,] 0.7249021 0.07476727 0.7996693
## [4,] 0.6556713 0.09333301 0.7490044
## [5,] 0.6636559 0.07126840 0.7349243
## [6,] 0.7132059 0.12227658 0.8354825
## [7,] 0.6548797 0.06120430 0.7160840
## [8,] 0.5777963 0.17254515 0.7503415
```

```r
# Gráfico Biplot (individuos + variables)
fviz_pca_biplot(facCP,
                # Rimuove le etichette degli individui (usa solo i punti)
                geom.ind = "point",

                #  Colori ad alta evidenza
                col.var = "red",          # Variabili in rosso acceso
                col.ind = "steelblue",        # Individui in nero
                alpha.ind = 0.3,          # Trasparenza per gestire la sovrapposizione

                #  Estetica delle frecce
                arrowsize = 0.5,
                labelsize = 5,            # Dimensione del testo delle variabili

                #  Titoli e pulizia
                title = "Mapa PCA: Variables y individuos",
                repel = TRUE              # Evita sovrapposizione nomi variabili
)
```

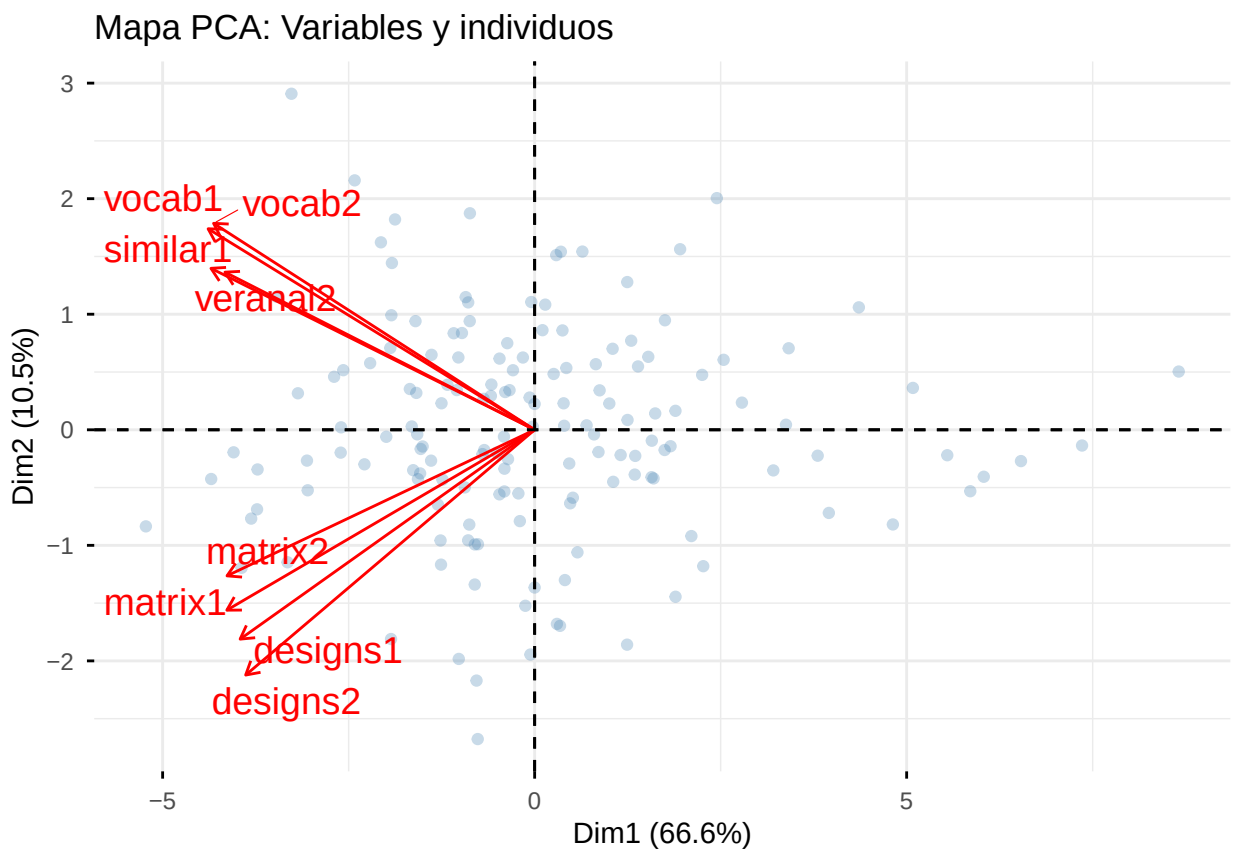


```r
# Variables coloreadas por su calidad de representación (cos2)
fviz_pca_var(facCP, col.var = "red",
             repel = TRUE
)
```

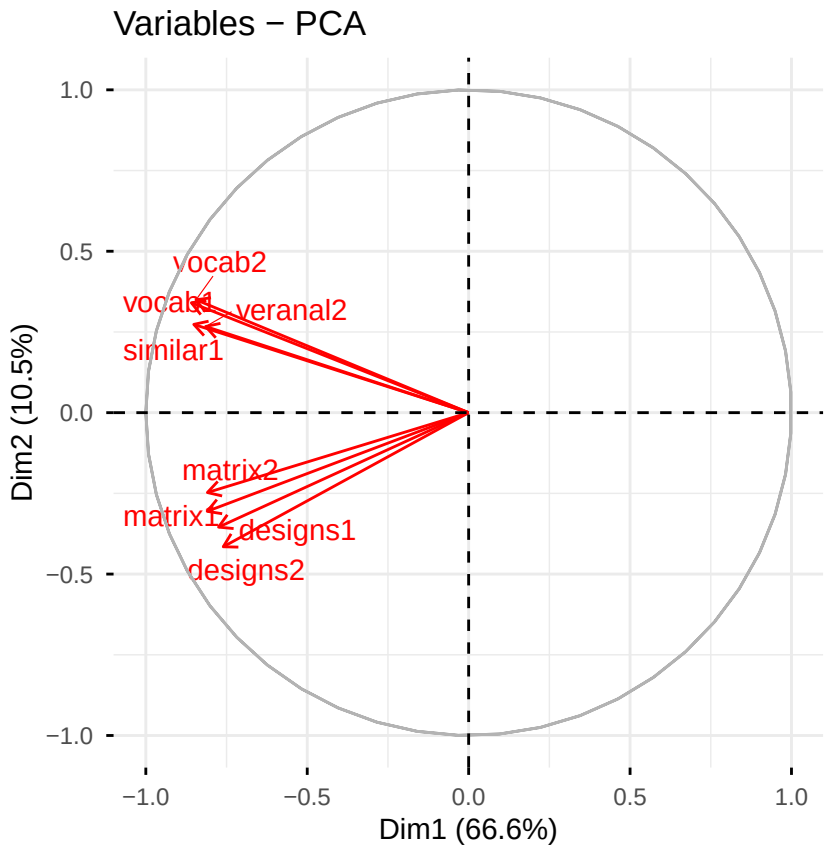

Interpretación del Círculo de Correlación (PCA)

El gráfico de variables (Círculo de Correlación) visualiza la relación entre los tests y las dos primeras dimensiones:

1. **Calidad de la representación:** Todos los vectores (flechas) son largos y llegan cerca del borde del círculo unitario. Esto indica que las dos primeras dimensiones explican muy bien todas las variables (corresponde a las altas **comunalidades** observadas anteriormente).
2. **Dimensión 1 (Eje X - 66.6%):** Todas las variables se sitúan en el lado izquierdo del eje. Esto confirma un **Factor de Inteligencia General (g)**, donde puntuaciones altas en un test tienden a asociarse con puntuaciones altas en los demás.
3. **Dimensión 2 (Eje Y - 10.5%):** Esta dimensión divide claramente las variables en dos grupos bien definidos por su contenido:
   - **Grupo Superior (Verbal):** En el cuadrante superior izquierdo se agrupan los tests de carácter verbal: `vocab1`, `vocab2`, `similar1` y `veranal2`.
   - **Grupo Inferior (No Verbal/Espacial):** En el cuadrante inferior izquierdo se agrupan los tests de capacidad manipulativa y matricial: `designs1`, `designs2`, `matrix1` y `matrix2`.

Conclusión: El gráfico demuestra una excelente validez de constructo. Los tests que miden habilidades similares se agrupan entre sí, y se observa una clara distinción entre la **aptitud verbal** y la **aptitud espacial/manipulativa**, manteniendo todas una fuerte base común (inteligencia general).

1.3.5. Rotaciones

```
rotacionCP <- varimax(cargasCP, normalize=T)$loadings
print(rotacionCP,cutoff=0.3)
```

```
##
## Loadings:
##      [,1]   [,2]
## [1,] -0.856 -0.348
## [2,] -0.315 -0.792
## [3,] -0.804 -0.391
## [4,] -0.374 -0.781
## [5,] -0.773 -0.370
## [6,] -0.852 -0.331
## [7,] -0.414 -0.738
## [8,]        -0.826
##
##                 [,1]  [,2]
## SS loadings    3.182 2.983
## Proportion Var 0.398 0.373
## Cumulative Var 0.398 0.771
```

Interpretación de la Rotación Varimax

Tras aplicar la rotación Varimax, se ha logrado una **estructura simple** y clara, donde los dos factores están equilibrados y son fácilmente interpretables:

1. **Factor 1 (Capacidad Verbal):** Este factor presenta cargas factoriales muy altas (superiores a 0.77) en las variables: `vocab1`, `similar1`, `veranal2` y `vocab2`. Es un factor puramente **verbal**, relacionado con el conocimiento del léxico, sinónimos y analogías. Explica el **39.8%** de la varianza total.
2. **Factor 2 (Capacidad Espacial y Matricial):** Este factor agrupa las variables: `designs1`, `matrix1`, `matrix2` y `designs2`. Todas presentan cargas elevadas (superiores a 0.73). Representa la **capacidad no verbal**, el razonamiento visual y la resolución de problemas espaciales/rompecabezas. Explica el **37.3%** de la varianza.

Análisis de la Varianza: La varianza total explicada acumulada es del **77.1%**. Cabe destacar que, a diferencia del análisis inicial, la rotación ha distribuido la importancia de los factores de manera casi equitativa (aprox. 40% y 37%), lo que confirma que ambas dimensiones de la inteligencia tienen un peso similar en este grupo de participantes.

```r
fa.diagram(rotacionCP)
```

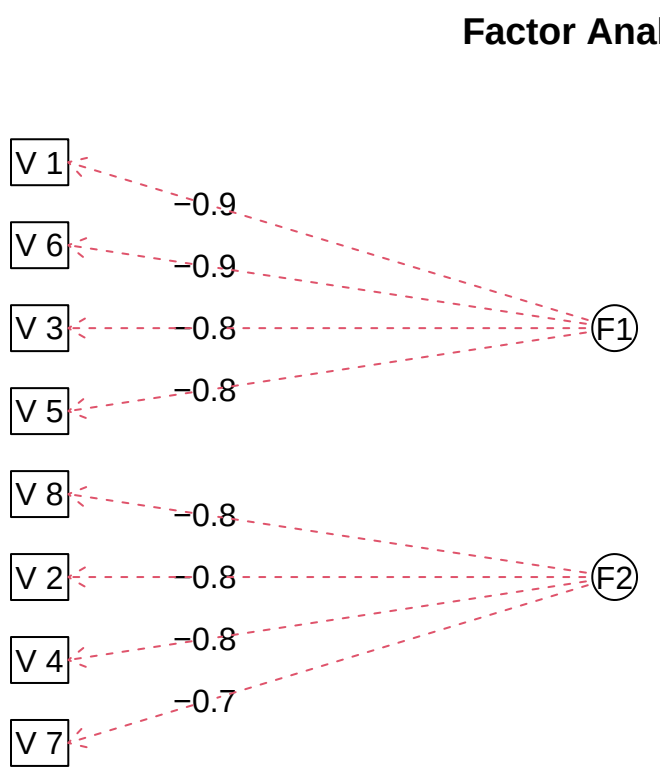


```r
plot(rotacionCP[,1],rotacionCP[,2])
text(rotacionCP[,1],rotacionCP[,2],labels=names(iq),cex=.7)
```

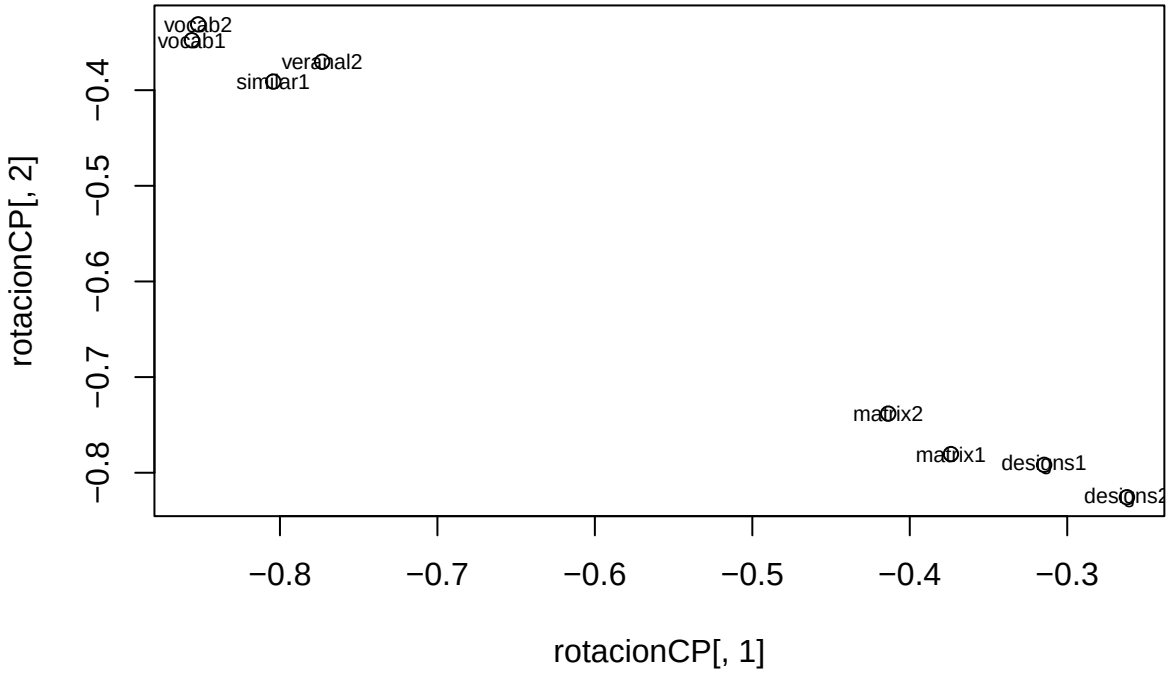

Interpretación del Diagrama de Factores

El diagrama de estructura confirma de manera visual y clara la validez del modelo de dos factores:

1. **Estructura Simple:** El gráfico muestra una "estructura simple" perfecta, donde cada variable carga exclusivamente en un solo factor, sin ambigüedades ni cargas cruzadas significativas.
2. **Configuración del Factor 1 (F1):** Este factor captura las habilidades verbales. Agrupa a las variables **V1, V6, V3 y V5** (pertenecientes a los tests de vocabulario y analogías) con cargas factoriales extremadamente altas, de entre **-0.8 y -0.9**. Esto lo define como el componente de **Inteligencia Verbal**.
3. **Configuración del Factor 2 (F2):** Este factor representa las habilidades de ejecución. Agrupa a las variables **V8, V2, V4 y V7** (tests de diseño con bloques y matrices) con cargas muy sólidas de entre **-0.7 y -0.8**. Esto lo define como el componente de **Inteligencia Visual/Espacial**.

Conclusión final: El análisis factorial ha logrado reducir los 8 tests originales a dos dimensiones fundamentales con una pérdida mínima de información. Los resultados son altamente coherentes con las teorías clásicas de la inteligencia, separando claramente las capacidades lingüísticas de las capacidades lógico-espaciales.

```
fe <- fa.extend(cor(iq), 2,1:8,8)
extension.diagram(fe)
```

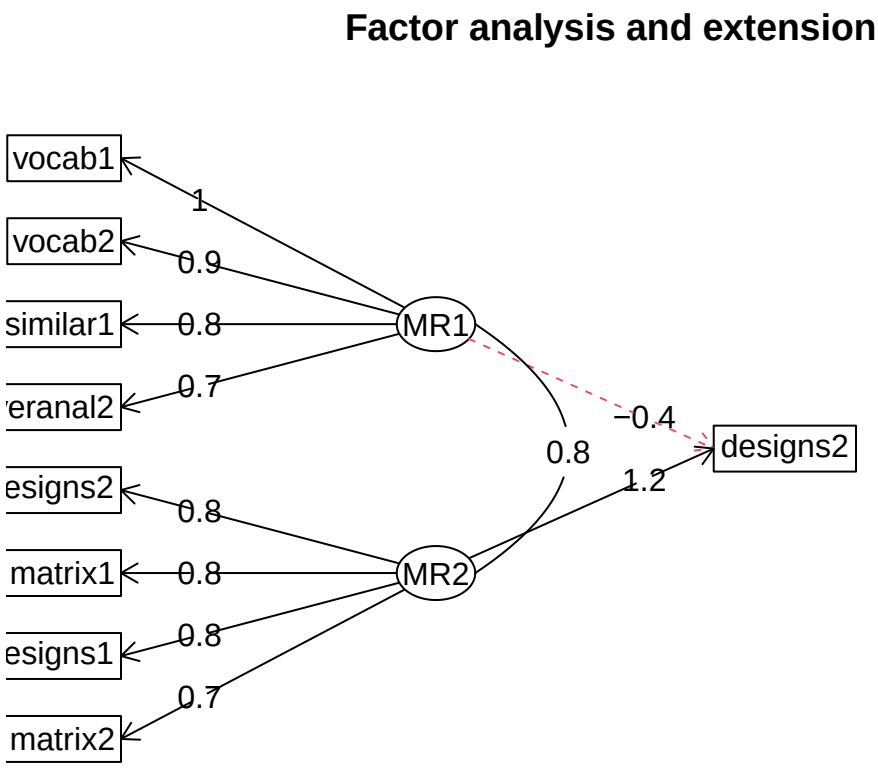

Interpretación del Análisis de Extensión Factorial

Este gráfico presenta un modelo de **rotación oblicua**, que permite analizar la relación entre los factores y la variable específica `designs2`:

1. **Correlación entre Factores:** Lo más relevante es la **fuerte correlación (0.8)** entre el factor verbal (MR1) y el factor espacial/ejecutivo (MR2). Esto indica que ambas capacidades no son independientes, sino que están estrechamente vinculadas, lo cual es evidencia de un factor de inteligencia general (g).
2. **Análisis de Extensión (`designs2`):** El test de rompecabezas (`designs2`) se analiza a la derecha como resultado de ambos factores. Su carga de **1.2** respecto a MR2 confirma que es un indicador extremadamente fuerte de la capacidad espacial. El valor superior a 1.0 (caso de *Heywood*) es común en modelos con factores muy correlacionados.
3. **Estructura del Modelo:** Se mantiene la división clara entre las habilidades lingüísticas (MR1: `vocab`, `similar`, `veranal`) y las manipulativas (MR2: `matrix`, `designs`), demostrando una excelente estabilidad y validez de constructo.

El modelo demuestra que, aunque existen dos dimensiones cognitivas diferenciadas, estas operan de forma conjunta con una alta interconectividad (0.8).

1.3.6. Medidas de consistencia

```
datos1<-iq[,c("matrix1","matrix2","designs1")]
datos2<-iq[,c("vocab1","vocab2","similar1", "veranal2")]
```

```
alpha(datos1,check.keys=TRUE)$total[1]
```

```
##  raw_alpha
```

```
##  0.8477796
```

```r
alpha(datos2,check.keys=TRUE)$total[1]
```

```
##  raw_alpha
##  0.9191956
```

Alpha di Cronbach: Nos dice cuánto los ítems de un grupo están relacionados entre sí, en nuestro caso tenemos la confirmación definía que las variables de un grupo están midiendo el mismo concepto.

1.3.7. Puntuaciones factoriales

```r
# facCP$x[,1:2]
plot(facCP$x[,1],facCP$x[,2])
text(facCP$x[,1],facCP$x[,2],labels=rownames(iq),cex=.7)
```

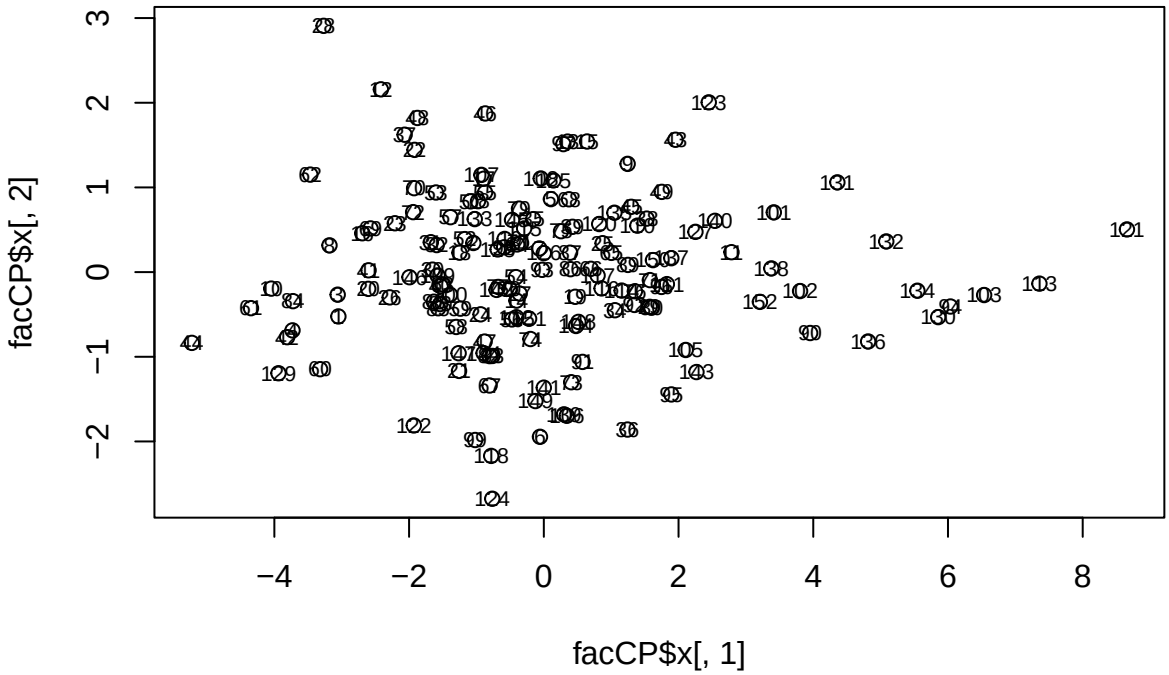


```r
fviz_pca_ind(facCP)
```

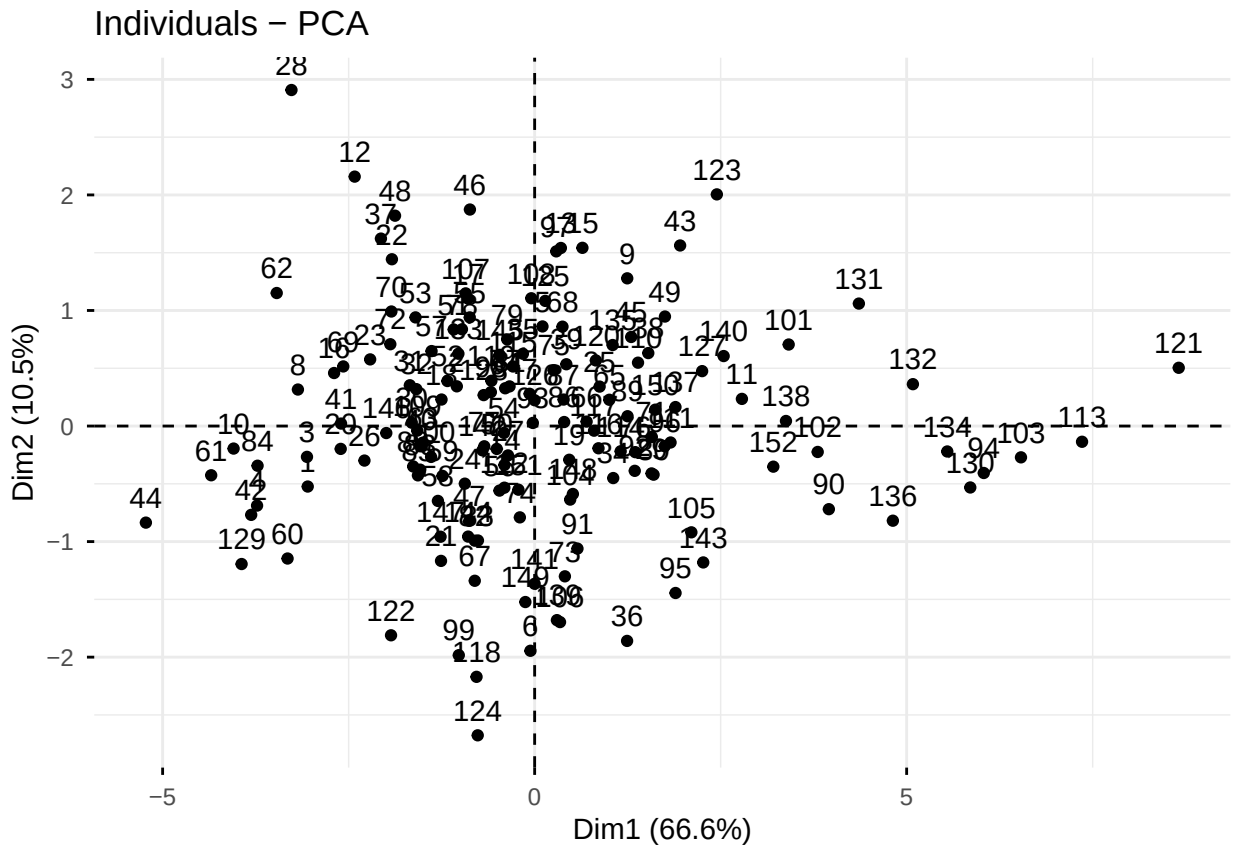

Ejercicio 2: Análisis Factorial de dataset 'sdq.xls'

2.3.1. Análisis previos

```
datos <- read_xls("sdq.xls", na = "?")

glimpse(datos)
```

```
## Rows: 425
## Columns: 30
## $ sdq1   <dbl> 3, 2, 1, 5, 4, 6, 2, 1, 3, 6, 3, 1, 6, 5, 3, 1, 5, 6, 1, 1, 4, ~
## $ sdq2   <dbl> 6, 5, 1, 6, 2, 5, 6, 6, 2, 6, 5, 4, 4, 6, 4, 4, 1, 5, 4, 4, 3, ~
## $ sdq3   <dbl> 6, 6, 3, 6, 5, 5, 6, 6, 6, 6, 6, 6, 5, 5, 6, 6, 2, 3, 2, 5, 4, ~
## $ sdq4r  <dbl> 3, 1, 1, 5, 1, 6, 3, 1, 1, 6, 1, 3, 6, 5, 5, 2, 6, 6, 2, 1, 5, ~
## $ sdq5r  <dbl> 6, 5, 6, 6, 3, 6, 6, 6, 6, 6, 3, 6, 5, 6, 6, 6, 6, 6, 6, 5, 2, ~
## $ sdq6   <dbl> 3, 6, 4, 4, 5, 3, 6, 6, 1, 5, 6, 6, 4, 1, 6, 1, 4, 3, 3, 3, 1, ~
## $ sdq7   <dbl> 4, 2, 1, 4, 2, 5, 1, 1, 3, 6, 3, 4, 5, 1, 2, 1, 5, 1, 1, 1, 6, ~
## $ sdq8   <dbl> 4, 5, 6, 5, 2, 6, 6, 6, 3, 6, 4, 5, 5, 6, 5, 5, 6, 4, 4, 5, 5, ~
## $ sdq9r  <dbl> 6, 6, 6, 5, 4, 6, 6, 6, 6, 5, 5, 5, 5, 5, 6, 4, 1, 5, 6, 5, 1, ~
## $ sdq10r <dbl> 6, 4, 1, 6, 5, 6, 3, 4, 1, 6, 2, 5, 5, 5, 4, 6, 5, 6, 3, 1, 6, ~
## $ sdq11r <dbl> 6, 5, 2, 5, 4, 6, 6, 6, 2, 6, 5, 4, 5, 6, 6, 6, 1, 5, 5, 4, 2, ~
## $ sdq12  <dbl> 4, 6, 5, 5, 5, 5, 6, 6, 6, 5, 5, 5, 5, 2, 5, 5, 2, 3, 5, 5, 1, ~
## $ sdq13  <dbl> 4, 3, 1, 6, 3, 6, 3, 3, 3, 6, 3, 3, 4, 2, 1, 1, 5, 5, 1, 1, 6, ~
## $ sdq14  <dbl> 4, 5, 1, 5, 3, 5, 6, 6, 1, 6, 5, 5, 5, 6, 5, 4, 6, 5, 5, 4, 5, ~
## $ sdq15r <dbl> 6, 5, 6, 6, 5, 6, 6, 6, 6, 5, 6, 5, 6, 6, 6, 6, 4, 2, 6, 2, 6, ~
```

```
## $ sdq16r <dbl> 3, 6, 1, 6, 5, 6, 3, 1, 2, 6, 2, 4, 6, 5, 4, 3, 5, 6, 2, 1, 6, ~
## $ sdq17r <dbl> 6, 5, 1, 6, 4, 6, 6, 6, 1, 6, 6, 4, 3, 6, 6, 6, 1, 6, 6, 5, 6, ~
## $ sdq18  <dbl> 4, 6, 4, 5, 4, 1, 6, 6, 6, 4, 5, 5, 5, 4, 6, 2, 4, 3, 5, 5, 1, ~
## $ sdq19  <dbl> 1, 6, 1, 6, 4, 6, 3, 1, 3, 6, 2, 2, 6, 6, 4, 5, 5, 5, 1, 1, 6, ~
## $ sdq20  <dbl> 6, 6, 1, 6, 5, 6, 4, 6, 3, 6, 5, 5, 6, 5, 5, 5, 3, 5, 4, 4, 6, ~
## $ sdq21r <dbl> 6, 5, 4, 5, 5, 6, 6, 6, 5, 3, 6, 5, 6, 5, 6, 4, 4, 1, 6, 1, 2, ~
## $ sdq22r <dbl> 6, 6, 1, 6, 4, 6, 6, 1, 1, 6, 1, 2, 6, 1, 4, 2, 5, 5, 1, 1, 6, ~
## $ sdq23r <dbl> 6, 5, 1, 6, 3, 6, 6, 6, 1, 6, 6, 5, 6, 6, 5, 6, 5, 4, 3, 5, 5, ~
## $ sdq24  <dbl> 4, 6, 5, 6, 5, 6, 6, 6, 6, 4, 5, 5, 6, 5, 5, 6, 1, 3, 5, 5, 1, ~
## $ sdq25  <dbl> 1, 1, 1, 6, 3, 6, 1, 1, 3, 6, 3, 2, 6, 5, 4, 3, 6, 5, 3, 2, 6, ~
## $ sdq26  <dbl> 4, 5, 6, 6, 6, 6, 6, 6, 6, 6, 5, 6, 6, 6, 5, 6, 6, 5, 3, 5, 6, ~
## $ sdq27r <dbl> 6, 4, 6, 4, 1, 2, 6, 6, 6, 5, 1, 5, 5, 2, 5, 2, 1, 2, 5, 6, 1, ~
## $ sdq28r <dbl> 6, 3, 1, 6, 4, 6, 1, 1, 1, 6, 2, 1, 6, 5, 3, 2, 6, 6, 2, 1, 6, ~
## $ sdq29r <dbl> 6, 5, 2, 6, 4, 6, 6, 6, 4, 6, 6, 6, 6, 6, 6, 6, 5, 6, 6, 5, 5, ~
## $ sdq30  <dbl> 6, 6, 3, 6, 4, 5, 6, 6, 6, 5, 5, 5, 6, 5, 6, 5, 4, 3, 6, 5, 1, ~
```

```r
table(sapply(datos, class))
```

```
##
## numeric
##      30
```

```r
# Verificación de valores faltantes
sum(is.na(datos))
```

```
## [1] 0
```

El conjunto de datos se importó correctamente y no faltan valores.

Ahora deberíamos probar las hipótesis de normalidad, linealidad y correlación porque estas pruebas sirven para asegurar que los datos tengan una estructura matemática coherente y relaciones lineales robustas, sin las cuales el análisis factorial produciría resultados distorsionados o carentes de significado estadístico.

```r
test <- mvn(datos,univariate_test = "SW")
pander(test$univariate_normality)
```

Test	Variable	Statistic	p.value	Normality
Shapiro-Wilk	sdq1	0.844	<0.001	Not normal
Shapiro-Wilk	sdq2	0.8	<0.001	Not normal
Shapiro-Wilk	sdq3	0.796	<0.001	Not normal
Shapiro-Wilk	sdq4r	0.849	<0.001	Not normal
Shapiro-Wilk	sdq5r	0.602	<0.001	Not normal
Shapiro-Wilk	sdq6	0.86	<0.001	Not normal
Shapiro-Wilk	sdq7	0.858	<0.001	Not normal
Shapiro-Wilk	sdq8	0.808	<0.001	Not normal
Shapiro-Wilk	sdq9r	0.735	<0.001	Not normal
Shapiro-Wilk	sdq10r	0.758	<0.001	Not normal
Shapiro-Wilk	sdq11r	0.757	<0.001	Not normal
Shapiro-Wilk	sdq12	0.863	<0.001	Not normal
Shapiro-Wilk	sdq13	0.86	<0.001	Not normal
Shapiro-Wilk	sdq14	0.8	<0.001	Not normal
Shapiro-Wilk	sdq15r	0.64	<0.001	Not normal
Shapiro-Wilk	sdq16r	0.825	<0.001	Not normal
Shapiro-Wilk	sdq17r	0.683	<0.001	Not normal
Shapiro-Wilk	sdq18	0.844	<0.001	Not normal
Shapiro-Wilk	sdq19	0.858	<0.001	Not normal

Test	Variable	Statistic	p.value	Normality
Shapiro-Wilk	sdq20	0.782	<0.001	Not normal
Shapiro-Wilk	sdq21r	0.669	<0.001	Not normal
Shapiro-Wilk	sdq22r	0.699	<0.001	Not normal
Shapiro-Wilk	sdq23r	0.645	<0.001	Not normal
Shapiro-Wilk	sdq24	0.847	<0.001	Not normal
Shapiro-Wilk	sdq25	0.865	<0.001	Not normal
Shapiro-Wilk	sdq26	0.536	<0.001	Not normal
Shapiro-Wilk	sdq27r	0.857	<0.001	Not normal
Shapiro-Wilk	sdq28r	0.738	<0.001	Not normal
Shapiro-Wilk	sdq29r	0.505	<0.001	Not normal
Shapiro-Wilk	sdq30	0.813	<0.001	Not normal

```r
pander(test$multivariate_normality)
```

Test	Statistic	p.value	Method	MVN
Henze-Zirkler	1.27	<0.001	asymptotic	Not normal

Sin embargo, los test formales de normalidad no son necesarias porque los datos son ordinales y discretos (escala 1-6), una condición que viola la condición de continuidad requerida por estas pruebas.

Podemos comprobar la normalidad a través de Skewness y Kurtosis

```r
# Selezioniamo solo Skewness e Kurtosis (colonne 11 e 12 di describe)
desc_norm <- describe(datos)[, c("skew", "kurtosis")]
pander(round(desc_norm, 2))
```

	skew	kurtosis
sdq1	-0.57	-1.06
sdq2	-1.2	0.7
sdq3	-0.96	-0.2
sdq4r	-0.24	-1.49
sdq5r	-1.95	2.85
sdq6	-0.45	-1.18
sdq7	-0.48	-1.14
sdq8	-1.21	0.79
sdq9r	-1.27	0.37
sdq10r	-1.16	0.12
sdq11r	-1.39	1.26
sdq12	-0.83	-0.23
sdq13	-0.31	-1.35
sdq14	-1.28	0.99
sdq15r	-1.65	1.48
sdq16r	-0.67	-0.97
sdq17r	-1.44	0.76
sdq18	-0.57	-1.04
sdq19	-0.62	-0.88
sdq20	-1.26	0.72
sdq21r	-1.52	1.06
sdq22r	-1.33	0.4
sdq23r	-1.66	1.58

	skew	kurtosis
sdq24	-0.87	-0.24
sdq25	-0.47	-1.16
sdq26	-2.76	8.14
sdq27r	-0.17	-1.5
sdq28r	-1.03	-0.41
sdq29r	-2.59	6.26
sdq30	-1.11	0.36

Casi todas tus variables presentan una **asimetría** (*skewness*) negativa; la cola de la distribución se desplaza hacia la izquierda, lo que implica que la mayoría de los 425 encuestados eligieron las puntuaciones más altas de la escala (por ejemplo, 5-6).

Este análisis adicional nos muestra algunas variables consideradas **"casos críticos"**:

- **sdq26** (-2.76 - 8.14)
- **sdq29r** (-2.59 - 6.26)
- **sdq5r** (-1.95 - 2.85)

Las distribuciones de asimetría y curtosis no presentan un rango moderado; al contrario, algunas observaciones superan el umbral de los valores considerados críticos (± 2 para la asimetría y ± 7 para la curtosis). Esto confirma que las variables no siguen una distribución normal, por lo que es recomendable no utilizar métodos como el de Máxima Verosimilitud en el análisis factorial.

Es aconsejable utilizar Spearman en lugar de Pearson; sin embargo, nosotros queremos analizar la hipótesis de linealidad.

```r
# Cálculo de la matriz de correlación de Pearson
R <- cor(datos, method="pearson")

#Observando así la matriz vemos que las correlaciones son todas positivas y relativamente altas(>0.3)
symnum(R)
```

```
##        sd1 sd2 sd3 s4 s5 s6 s7 s8 s9 s10 s11 s12 s13 s14 s15 s16 s17 s18 s19
## sdq1   1
## sdq2       1
## sdq3           1
## sdq4r  .           1
## sdq5r      .           1
## sdq6           .         1
## sdq7   .           .        1
## sdq8       .                   1
## sdq9r          .                   1
## sdq10r .           .                   1
## sdq11r     .   .       .                   1
## sdq12          .                               1
## sdq13  ,           .        ,        .           1
## sdq14      .                   .         .           1
## sdq15r                             .                       1
## sdq16r .           .        .        .           .           1
## sdq17r     .           .                   .                       1
## sdq18          .         .                   .                       1
## sdq19  ,           .        .        .           .           ,           1
## sdq20                              .                       .
## sdq21r                             .                       .
```

```
## sdq22r .           .        .        .           .           .           .
## sdq23r     .          .        .         .           .           .
## sdq24          .         .                  .                       .
## sdq25  ,           .        .        .           .           .           ,
## sdq26
## sdq27r
## sdq28r ,           .        .        .           .           .           .
## sdq29r     .          .        .         .           .           .
## sdq30          .         .                  .                       .
##        s20 s21 s22 s23 s24 s25 s26 s27 s28 s29 s30
## sdq1
## sdq2
## sdq3
## sdq4r
## sdq5r
## sdq6
## sdq7
## sdq8
## sdq9r
## sdq10r
## sdq11r
## sdq12
## sdq13
## sdq14
## sdq15r
## sdq16r
## sdq17r
## sdq18
## sdq19
## sdq20  1
## sdq21r     1
## sdq22r         1
## sdq23r             1
## sdq24                  1
## sdq25          .           1
## sdq26  .                       1
## sdq27r                 .           1
## sdq28r         ,           .           1
## sdq29r .           .                       1
## sdq30      .           .                       1
## attr(,"legend")
## [1] 0 ' ' 0.3 '.' 0.6 ',' 0.8 '+' 0.9 '*' 0.95 'B' 1
```

```r
corrplot(R,sig.level=0.05,typ="lower")
```

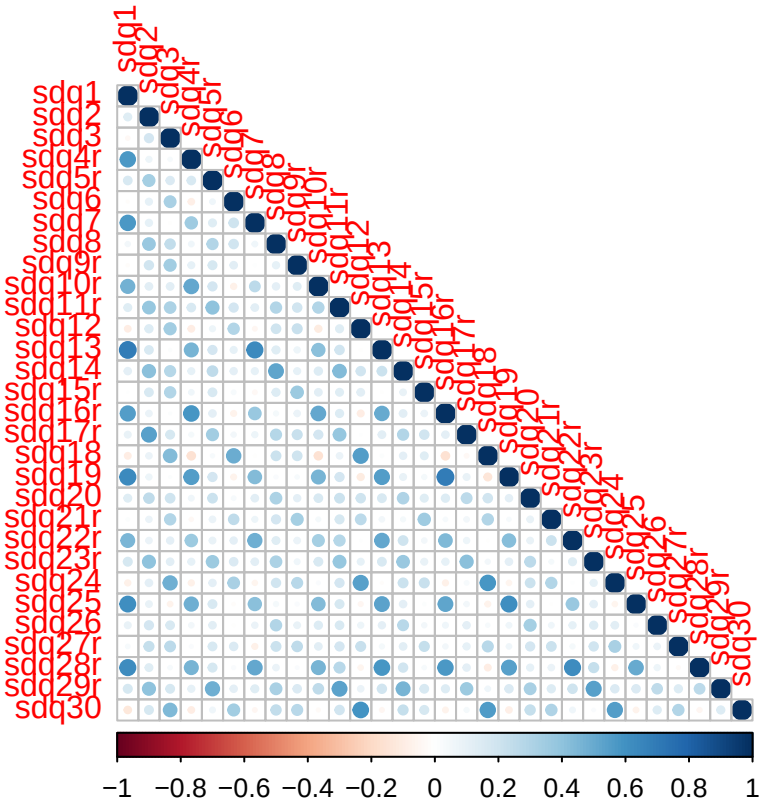


```
#Aquí vemos que en general las correlaciones son positivas  pero también es dificil sacar conclusiones.

det(R)
```

```
## [1] 2.400713e-06
```

```
#Es muy cercano a 0 por tanto es significativa , una última prueba será el test de esfericidad de bartl
```

La matriz presenta muchas correlaciones débiles entre sí; no podemos asumir una correlación lineal clásica (Pearson) con estos datos.

Probablemente existan subgrupos: muchas preguntas correlacionadas entre sí y otras que no tienen correlación alguna.

Un determinante tan bajo podría sugerir problemas de multicolinealidad; para verificar si podemos realizar un análisis factorial, debemos realizar la prueba de esfericidad de Bartlett.

```
# Verificación y validación de la matriz de correlación
cortest(R, n1= nrow(datos))
```

```
## Tests of correlation matrices
## Call:cortest(R1 = R, n1 = nrow(datos))
##  Chi Square value 13780.26  with df =  435   with probability < 0
## z of differences =  0.08
## Root Mean Square Residual =  0.27
## RMSEA =  0.27
```

La prueba de Bartlett demuestra que existen correlaciones significativas entre tus 30 variables; los datos son idóneos para ser reducidos en factores. Otro análisis gráfico para observar las interconexiones entre variables desde un punto de vista neuronal.

```r
qgraph(R,
       layout = "spring",
       labels = colnames(datos),
       label.scale = FALSE,
       label.cex = 0.8,
       node.width = 1.2)
```

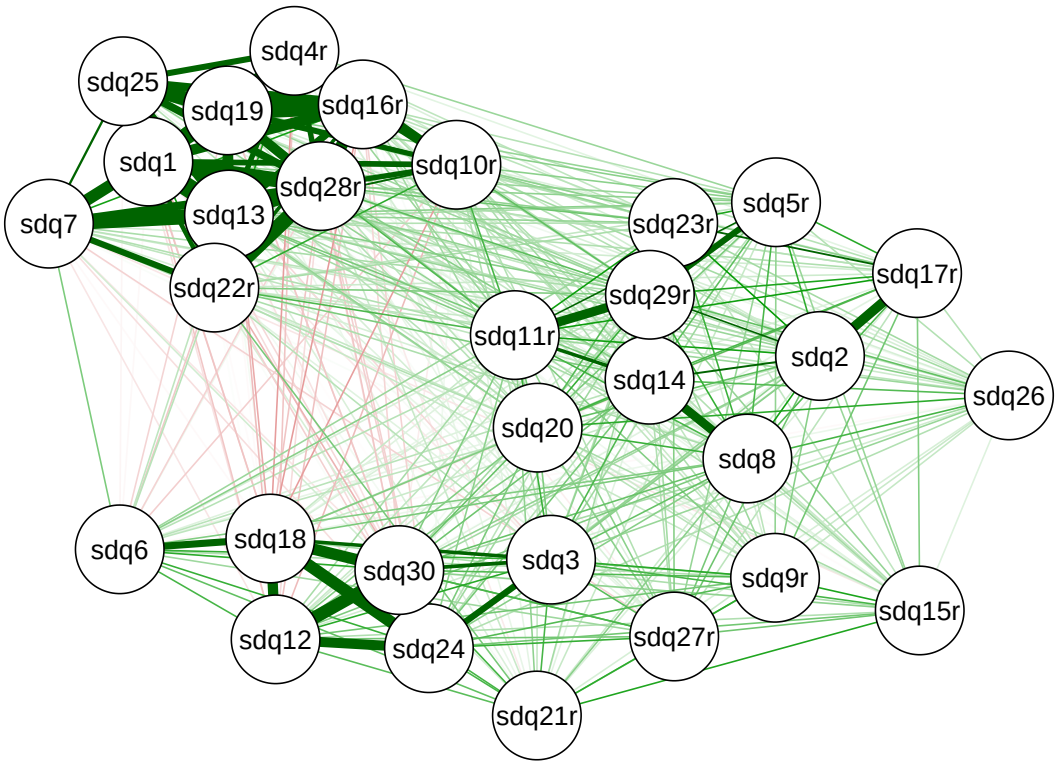

El gráfico confirma que hay muchas relaciones con poca correlación, pero también varios grupos de variables muy relacionadas entre sí.

Para acabar con el análisis previo realizaremos el Test de Kayser-Meyer-Olkin, para contrastar si el análisis factorial es significativo o no antes de realizarlo.

```r
KMO(datos)
```

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = datos)
## Overall MSA =  0.88
## MSA for each item =
##   sdq1   sdq2   sdq3  sdq4r  sdq5r   sdq6   sdq7   sdq8  sdq9r sdq10r sdq11r
##   0.91   0.88   0.89   0.92   0.89   0.79   0.89   0.85   0.84   0.91   0.89
##  sdq12  sdq13  sdq14 sdq15r sdq16r sdq17r  sdq18  sdq19  sdq20 sdq21r sdq22r
##   0.87   0.92   0.85   0.83   0.90   0.81   0.85   0.91   0.87   0.82   0.90
## sdq23r  sdq24  sdq25  sdq26 sdq27r sdq28r sdq29r  sdq30
##   0.86   0.89   0.94   0.82   0.85   0.91   0.87   0.88
```

La prueba nos confirma que los datos son sólidos y perfectamente adecuados para llevar a cabo un análisis factorial.

2.3.2 Determinación del número de factores

```
#Primero vamos a calcular los autovalores de la matriz de correlaciones
eigen(R)$values
```

```
##  [1] 6.5949496 4.8537169 2.4669326 1.5392805 1.2497182 1.0521436 0.9408342
##  [8] 0.8454873 0.8102846 0.7609676 0.7207006 0.7004143 0.6172549 0.5839796
## [15] 0.5747319 0.5403894 0.5268530 0.4964674 0.4559921 0.4445354 0.4208006
## [22] 0.3839436 0.3715222 0.3593831 0.3277529 0.3087544 0.2938909 0.2796372
## [29] 0.2570353 0.2216464
```

```
#Usando la regla de Kayser escogeriamos 6 factores ya que es el único autovalor mayor que la unidad.

# Visualización del Scree Plot
scree(R, factors= TRUE, pc=TRUE)
```

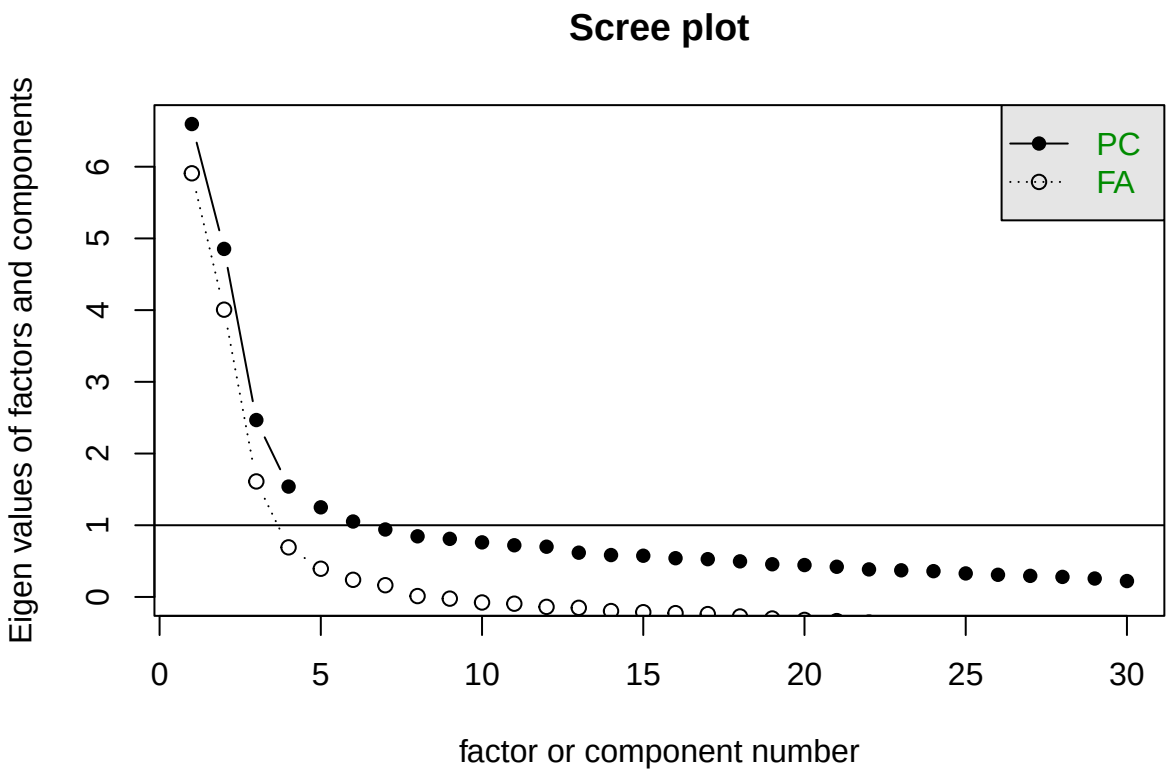


```
#También podemos verlo con el pòrcentaje de variable explicada.
fac<-prcomp(datos,scale.=TRUE,tol=NULL)
summary(fac)
```

```
## Importance of components:
##                           PC1    PC2     PC3     PC4     PC5     PC6     PC7
## Standard deviation     2.5681 2.2031 1.57065 1.24068 1.11791 1.02574 0.96997
## Proportion of Variance 0.2198 0.1618 0.08223 0.05131 0.04166 0.03507 0.03136
## Cumulative Proportion  0.2198 0.3816 0.46385 0.51516 0.55682 0.59189 0.62325
##                            PC8     PC9    PC10    PC11    PC12    PC13    PC14
## Standard deviation     0.91950 0.90016 0.87233 0.84894 0.83691 0.78566 0.76419
## Proportion of Variance 0.02818 0.02701 0.02537 0.02402 0.02335 0.02058 0.01947
```

```
## Cumulative Proportion  0.65144 0.67844 0.70381 0.72783 0.75118 0.77176 0.79122
##                           PC15    PC16    PC17    PC18   PC19    PC20    PC21
## Standard deviation     0.75811 0.73511 0.72585 0.70460 0.6753 0.66673 0.64869
## Proportion of Variance 0.01916 0.01801 0.01756 0.01655 0.0152 0.01482 0.01403
## Cumulative Proportion  0.81038 0.82839 0.84595 0.86250 0.8777 0.89252 0.90655
##                          PC22    PC23    PC24    PC25    PC26   PC27    PC28
## Standard deviation     0.6196 0.60953 0.59949 0.57250 0.55566 0.5421 0.52881
## Proportion of Variance 0.0128 0.01238 0.01198 0.01093 0.01029 0.0098 0.00932
## Cumulative Proportion  0.9194 0.93173 0.94371 0.95463 0.96493 0.9747 0.98404
##                           PC29    PC30
## Standard deviation     0.50699 0.47079
## Proportion of Variance 0.00857 0.00739
## Cumulative Proportion  0.99261 1.00000
```

```r
# Usa facCP che è l'oggetto dove hai salvato i risultati di prcomp
fviz_screeplot(fac, ncp=10, choice='eigenvalue', addlabels=TRUE) +
  geom_hline(yintercept=1, linetype="dashed", color="red") # Linea del criterio di Kaiser
```

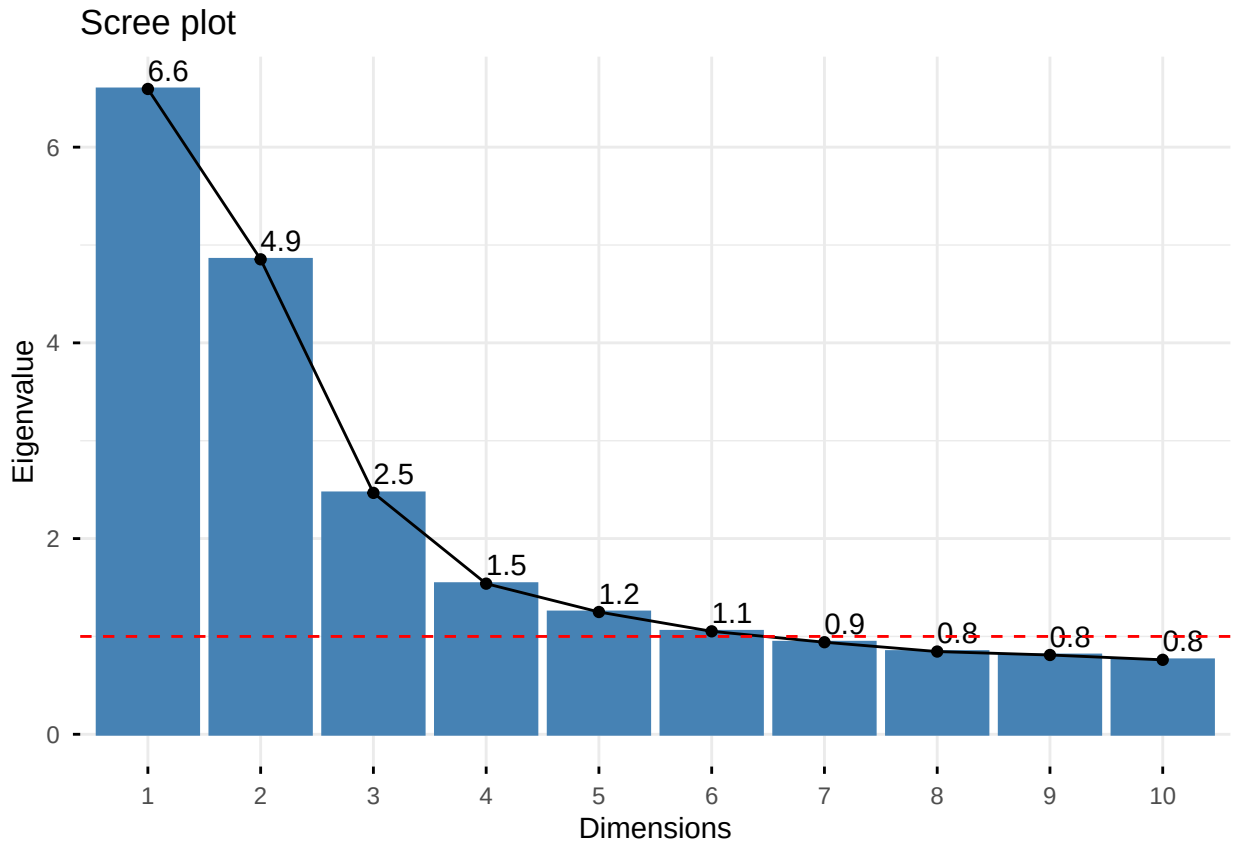

El criterio de Karsen nos sugiere seis factores; sin embargo, a menudo es impreciso, especialmente con datos ordinarios.

Utilizamos otros criterios para determinar el número de componentes que se deben emplear en el análisis factorial.

```r
#Este código realiza un análisis comparativo entre cuatro criterios diferentes (Kaiser, Parallel, OC y A

ac<-parallel(subject=nrow(datos),var=ncol(datos),rep=500,cent=.05)
nS <- nScree(x=eigen(R)$values, aparallel=ac$eigen$qevpea)
```

```r
pander(nS$Components)
```

noc	naf	nparallel	nkaiser
4	2	4	6

```r
plotnScree(nS)
```

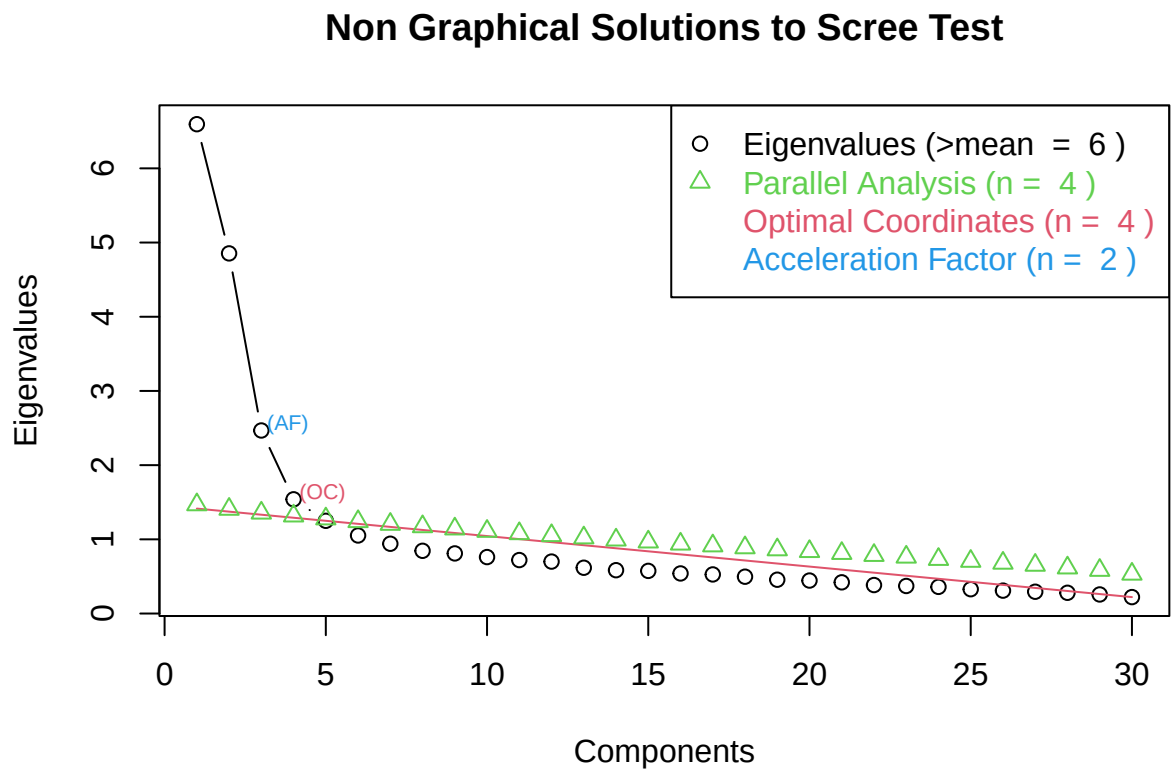

Los demás análisis nos sugieren que analicemos cuatro componentes principales para el análisis factorial.

Dado que el análisis paralelo nos ofrece, preferiblemente, una mejor estimación de los factores que debemos utilizar, emplearemos cuatro factores para nuestro análisis.

2.3.3. Análisis factorial

Comparamos los modelos para ver cuál elijo.

```r
# --- Comparación con 4 métodos ---

# mle: Máxima verosimilitud
mod_mle   <- fa(datos, nfactors = 4, rotate = "none", fm = "mle")

# minres: Residuo mínimo
mod_minres <- fa(datos, nfactors = 4, rotate = "none", fm = "minres")

# pa: Ejes principales
mod_pa   <- fa(datos, nfactors = 4, rotate = "none", fm = "pa")
```

```r
# minchi: Mínimos cuadrados
mod_minchi <- fa(datos, nfactors = 4, rotate = "none", fm = "minchi")

# Creamos un marco de datos completo con todos los índices de solidez
comparar_modelos <- data.frame(
  Método = c("MLE", "MinRes", "Ejes principales (PA)", "Mínimos cuadrados (MinChi)"),

  # Error
  RMSE = c(mod_mle$RMSEA[1], mod_minres$RMSEA[1], mod_pa$RMSEA[1], mod_minchi$RMSEA[1]),

  # Solidez Bayesiana (Más bajo/negativo es mejor)
  BIC = c(mod_mle$BIC, mod_minres$BIC, mod_pa$BIC, mod_minchi$BIC),

  # Complejidad media (Más cerca de 1 indica factores más claros y distintos)
  Complexity = c(mean(mod_mle$complexity), mean(mod_minres$complexity),
                 mean(mod_pa$complexity), mean(mod_minchi$complexity))
)


# Ordenamos por BIC porque es el indicador más severo de la solidez
comparar_modelos <- comparar_modelos[order(comparar_modelos$BIC), ]

pander(comparar_modelos,
       caption = "Comparación de la solidez: BIC (eficiencia) y Complexidad (pureza)")
```

Table 12: Comparación de la solidez: BIC (eficiencia) y Complexidad (pureza)

	Método	RMSE	BIC	Complexity
1	MLE	0.05521	-1205	1.882
4	Mínimos cuadrados (MinChi)	0.05528	-1204	1.889
3	Ejes principales (PA)	0.05638	-1187	2.208
2	MinRes	0.05639	-1187	2.208

El mejor modelo para el análisis factorial es el de **Máxima Verosimilitud**, sin embargo hemos notado antes que este método es aconsejable cuando hemos satisfecho la hipótesis de normalidad.

Por lo tanto, utilizamos el método de **Mínimos cuadrados**.

```r
modelo <- fa(R,
             nfactors = 4,
             rotate = "none",
             fm="minchi") # modelo minimos cuadrados
```

2.3.4 Comunalidades

```r
round(modelo$communality, 3)
```

```
##   sdq1   sdq2   sdq3  sdq4r  sdq5r   sdq6   sdq7   sdq8  sdq9r sdq10r sdq11r
##  0.692  0.422  0.430  0.498  0.312  0.322  0.506  0.353  0.337  0.457  0.426
##  sdq12  sdq13  sdq14 sdq15r sdq16r sdq17r  sdq18  sdq19  sdq20 sdq21r sdq22r
##  0.470  0.644  0.435  0.316  0.605  0.398  0.679  0.623  0.221  0.255  0.418
```

```
## sdq23r  sdq24  sdq25  sdq26 sdq27r sdq28r sdq29r  sdq30
##  0.425  0.542  0.493  0.113  0.220  0.606  0.530  0.557
```

```r
round(modelo$uniquenesses, 3)
```

```
##   sdq1   sdq2   sdq3  sdq4r  sdq5r   sdq6   sdq7   sdq8  sdq9r sdq10r sdq11r
##  0.308  0.578  0.570  0.502  0.688  0.678  0.494  0.647  0.663  0.543  0.574
##  sdq12  sdq13  sdq14 sdq15r sdq16r sdq17r  sdq18  sdq19  sdq20 sdq21r sdq22r
##  0.530  0.356  0.565  0.684  0.395  0.602  0.321  0.377  0.779  0.745  0.582
## sdq23r  sdq24  sdq25  sdq26 sdq27r sdq28r sdq29r  sdq30
##  0.575  0.458  0.507  0.887  0.780  0.394  0.470  0.443
```

El modelo funciona muy bien para aproximadamente la mitad de los ítems (aquellos con comunalidad >0.40).

Hay que considerar la eliminación de los ítems con comunalidad muy baja (<0.20 o 0.30).

Ítem fuertes: sdq1 (0.692), sdq18 (0.679) y sdq13 (0.644) explican aproximadamente el 64-69% de su varianza.

Item débil: sdq26 (0.113) y sdq27r (0.220) tienen valores muy bajos, lo que significa que los factores extraídos no pueden explicar casi nada de estas preguntas.

```r
load <- modelo$loadings[,1:4]
load
```

```
##               MR1        MR2          MR3          MR4
## sdq1   0.69095398 -0.4215743  0.166540554 -0.092964830
## sdq2   0.41898303  0.3179386 -0.380459700 -0.030394406
## sdq3   0.27491037  0.5468961  0.180597248  0.149745657
## sdq4r  0.56631229 -0.3616271  0.119722392  0.179883812
## sdq5r  0.42395558  0.1920604 -0.305709604  0.046967921
## sdq6   0.16212860  0.3979589  0.255204135 -0.269411264
## sdq7   0.54982692 -0.2753820  0.199741301 -0.295950929
## sdq8   0.37144518  0.3882684 -0.216310724 -0.133034330
## sdq9r  0.24451514  0.3491756  0.105603154  0.379954557
## sdq10r 0.58914070 -0.2150667 -0.002793071  0.253228793
## sdq11r 0.52218353  0.2908260 -0.262967033  0.003786415
## sdq12  0.12200160  0.5857458  0.316561313 -0.106560975
## sdq13  0.69661818 -0.2862700  0.188827451 -0.203707539
## sdq14  0.45785593  0.3300167 -0.286750665 -0.184661697
## sdq15r 0.20983548  0.2947813  0.028323901  0.429622411
## sdq16r 0.63315923 -0.3791752  0.144494872  0.199416979
## sdq17r 0.37590383  0.2237132 -0.444911441  0.094909923
## sdq18  0.08846971  0.6478172  0.459511689 -0.201902009
## sdq19  0.64930113 -0.3998878  0.160323714  0.124721704
## sdq20  0.35963082  0.2740477 -0.120139094 -0.042742482
## sdq21r 0.21222980  0.3514532  0.235223342  0.177327541
## sdq22r 0.58822201 -0.1679234  0.187561175 -0.090910972
## sdq23r 0.44047688  0.2248996 -0.402245301 -0.134650629
## sdq24  0.17682209  0.6341899  0.326740318  0.039982784
## sdq25  0.59111412 -0.3457838  0.153827651  0.004005318
## sdq26  0.25160270  0.1721153 -0.135916519 -0.038434623
## sdq27r 0.22711058  0.3613098  0.070704647  0.181472585
## sdq28r 0.69199873 -0.3267533  0.110526274 -0.091990190
## sdq29r 0.52737606  0.2811235 -0.411624056 -0.062494663
## sdq30  0.16657019  0.6476210  0.331034092 -0.022993510
```

MR1: Indica competencia y actitud hacia las matemáticas, quien tiene un puntaje alto aquí ama y logra

buenos cálculos.

MR2 : Indica habilidades verbales (inglés y lectura).

MR3 : Indica autoestima global, quien tiene un puntaje alto aquí, posee una percepción positiva de sí mismo como persona, independientemente de los votos.

MR4 : Indica dificultad y malestar escolar.

```
plot(load,type="n") # set up plot
text(load,labels=names(datos),cex=.7)
```

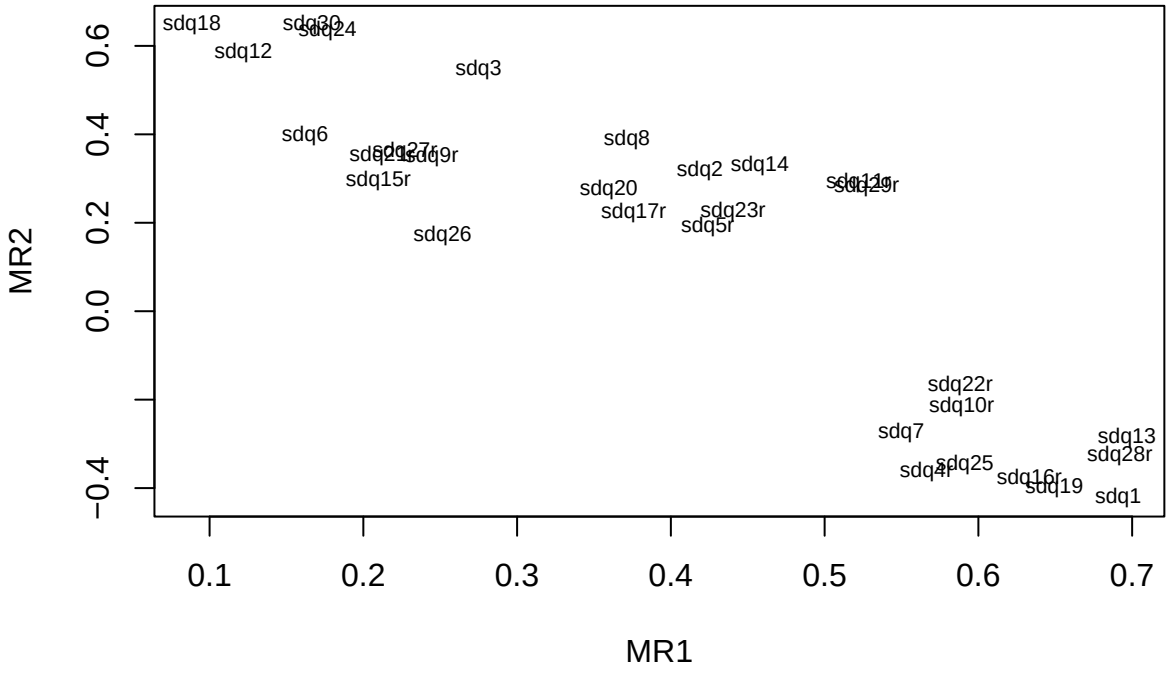

2.3.5 Rotaciones

```
rot<-c("none", "varimax", "quartimax", "Promax")

bi_mod <- function(tipo){
  biplot.psych(fa(datos, nfactors = 4, fm="minchi", rotate = tipo),
               main = paste("Biplot con rotación ", tipo),
               col=c(2,3,4), pch = c(21,18))
}
sapply(rot, bi_mod)
```

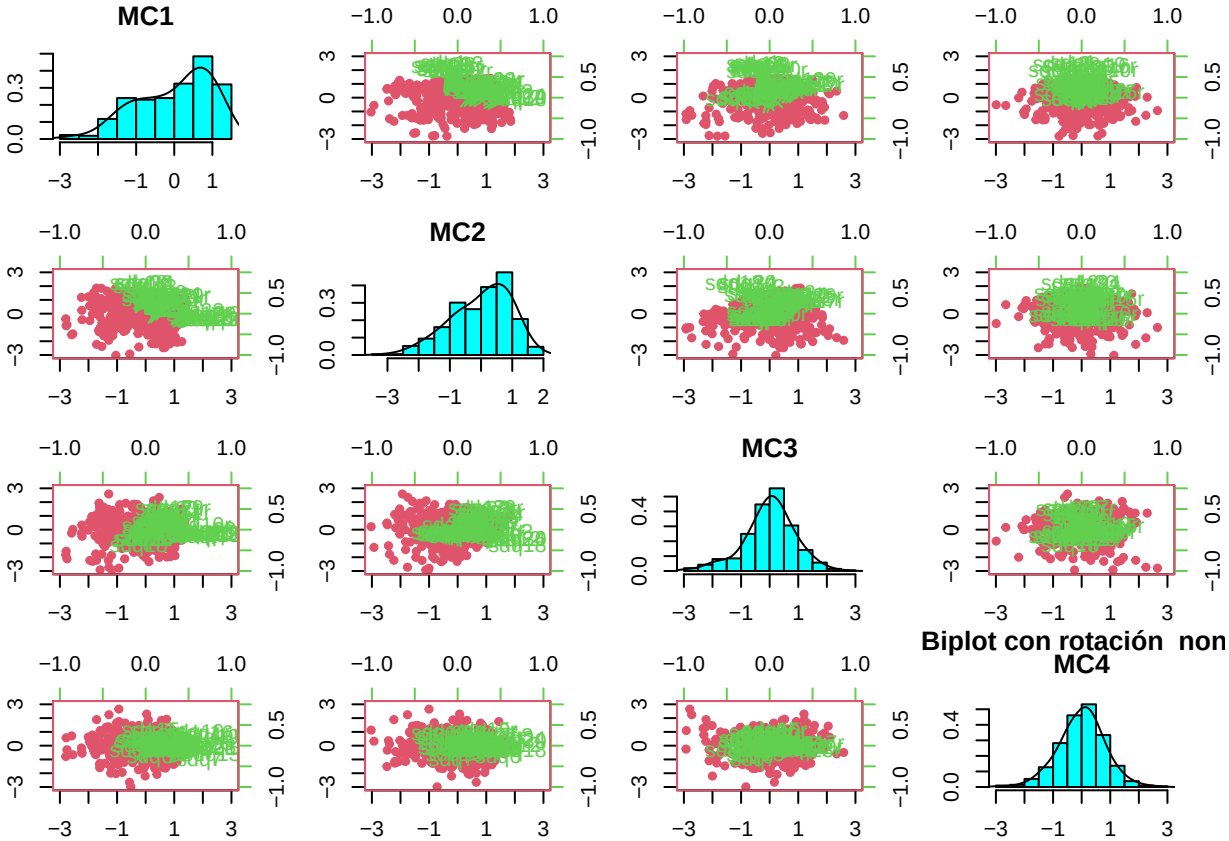
MC1
MC2
MC3
Biplot con rotación non
MC4

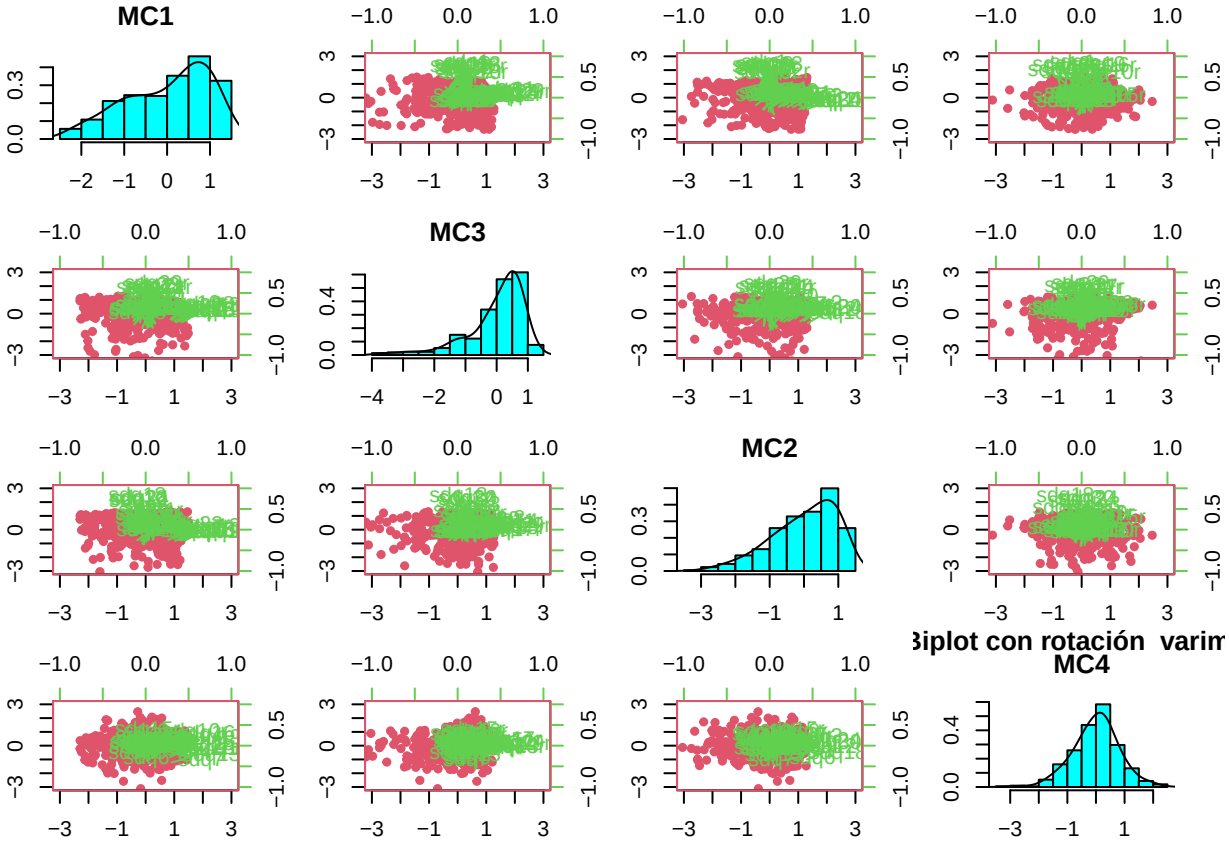
MC1
MC3
MC2
Biplot con rotación varim
MC4

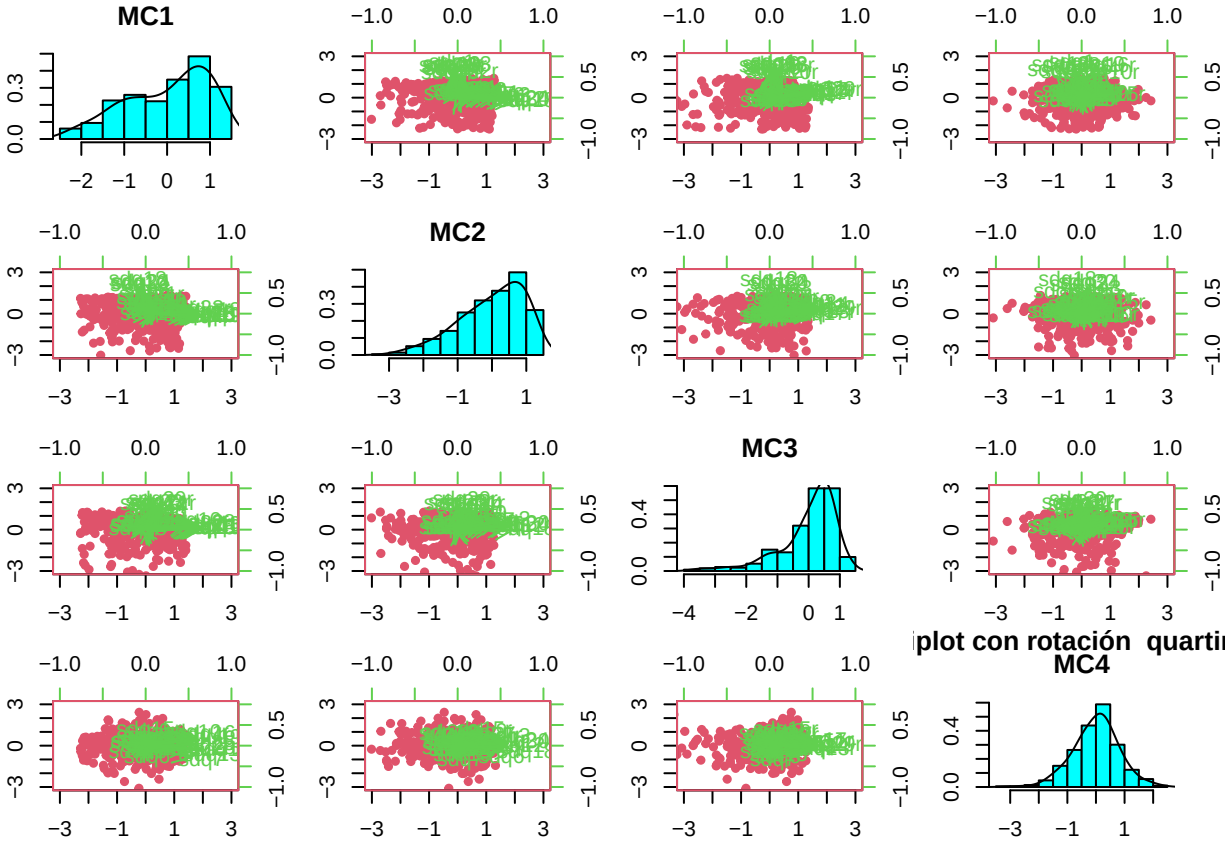
MC1
MC2
MC3
MC4
plot con rotación quarti

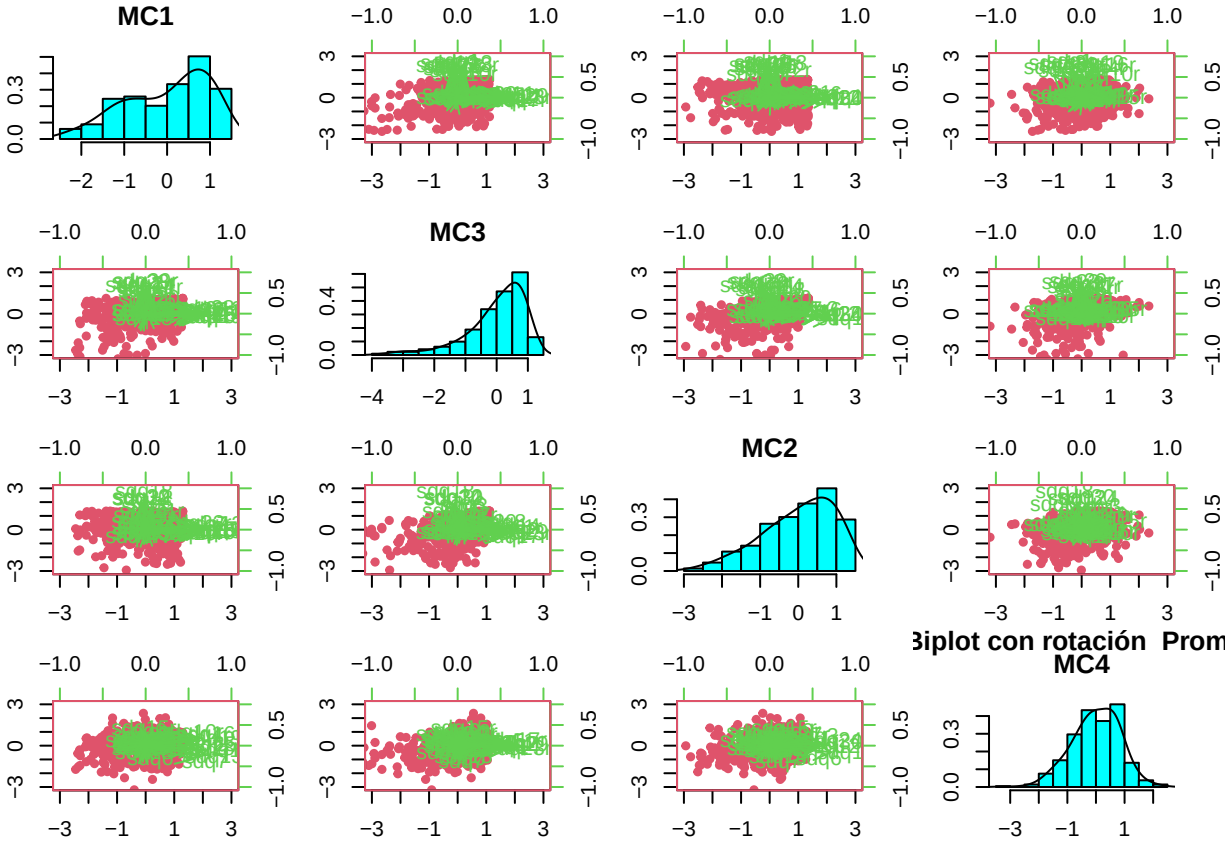


```
## $none
## NULL
##
## $varimax
## NULL
##
## $quartimax
## NULL
##
## $Promax
## NULL
```

```
gra<-function(tipo){
  fa.diagram(fa(datos,nfactors = 4, fm="minchi", rotate = tipo))
}
sapply(rot,gra)
```

Factor Analysis

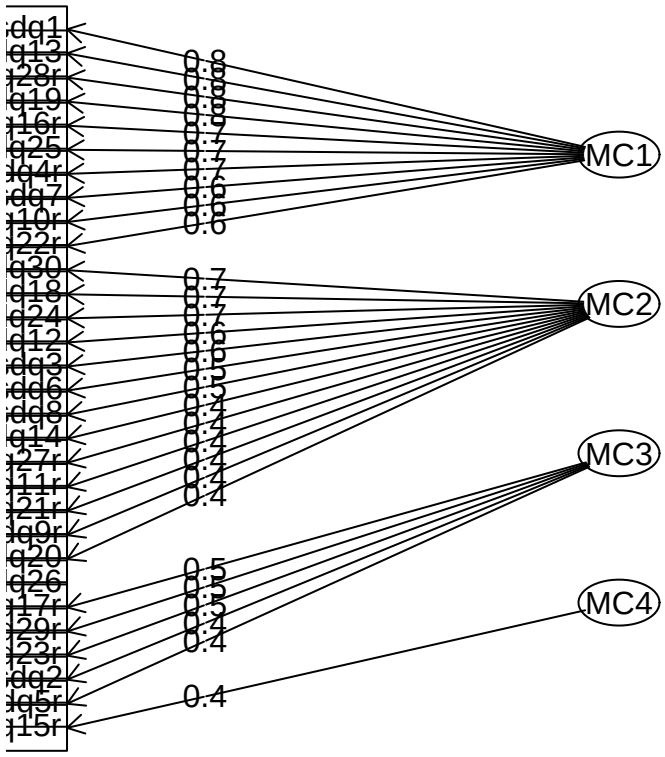

Factor Analysis

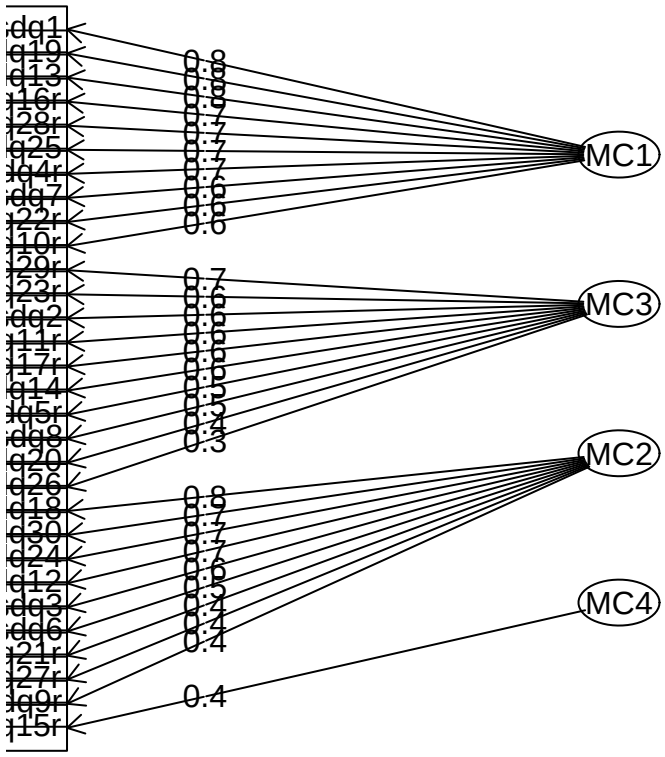

Factor Analysis

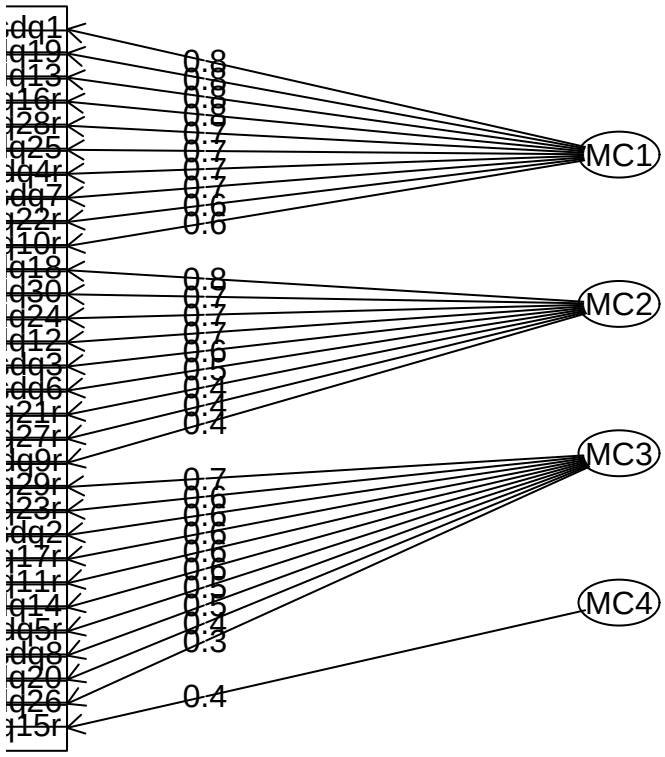

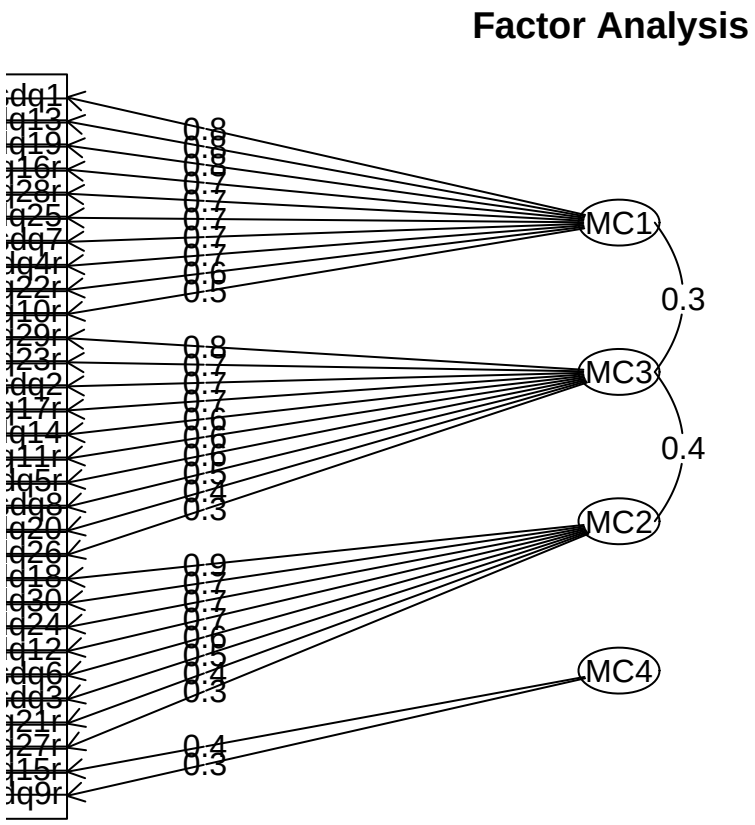


```
## $none
## NULL
##
## $varimax
## NULL
##
## $quartimax
## NULL
##
## $Promax
## NULL
```

Selección de la Rotación Factorial

Tras comparar los diferentes métodos de rotación mediante los biplots, se ha decidido optar por la rotación **Promax**.

La elección de este método se fundamenta en la naturaleza de los datos analizados. Al tratarse de **variables psicológicas** (conductas, emociones y rasgos sociales), es teóricamente poco probable que los factores sean completamente independientes entre sí. A diferencia de las rotaciones ortogonales (como *Varimax*), que obligan a los factores a no tener relación alguna, la rotación **Promax (oblicua)** permite que los factores correlacionen entre sí.

Este enfoque no solo es más coherente desde un punto de vista psicológico, sino que también facilita una **estructura simple** más clara, permitiendo que cada variable se asocie con mayor precisión a su factor correspondiente sin forzar una independencia artificial. Por lo tanto, el modelo basado en la rotación Promax nos ofrecerá la interpretación más realista y fiel a la complejidad del comportamiento humano evaluado.

```r
modelo_final <- fa(datos,
                   nfactors = 4,
                   rotate = "promax",
                   fm = "minchi")

print(modelo_final$loadings, cutoff = 0.3, sort = TRUE)
```

```
##
## Loadings:
##        MC1    MC3    MC2    MC4
## sdq1    0.841
## sdq4r   0.685
## sdq7    0.681               -0.386
## sdq10r  0.545
## sdq13   0.791
## sdq16r  0.757
## sdq19   0.795
## sdq22r  0.617
## sdq25   0.722
## sdq28r  0.739
## sdq2           0.674
## sdq5r          0.553
## sdq8           0.527
## sdq11r         0.603
## sdq14          0.623
## sdq17r         0.663
## sdq23r         0.719
## sdq29r         0.759
## sdq3                  0.548
## sdq6                  0.546
## sdq12                 0.710
## sdq18                 0.872
## sdq24                 0.741
## sdq30                 0.747
## sdq9r                 0.313  0.338
## sdq15r                       0.390
## sdq20          0.349
## sdq21r                0.430
## sdq26          0.301
## sdq27r                0.331
##
##                  MC1   MC3   MC2   MC4
## SS loadings    5.259 3.649 3.565 1.031
## Proportion Var 0.175 0.122 0.119 0.034
## Cumulative Var 0.175 0.297 0.416 0.450
```

```r
fa.diagram(modelo, main = "Diagrama factorial (Rotación Promax)")
```

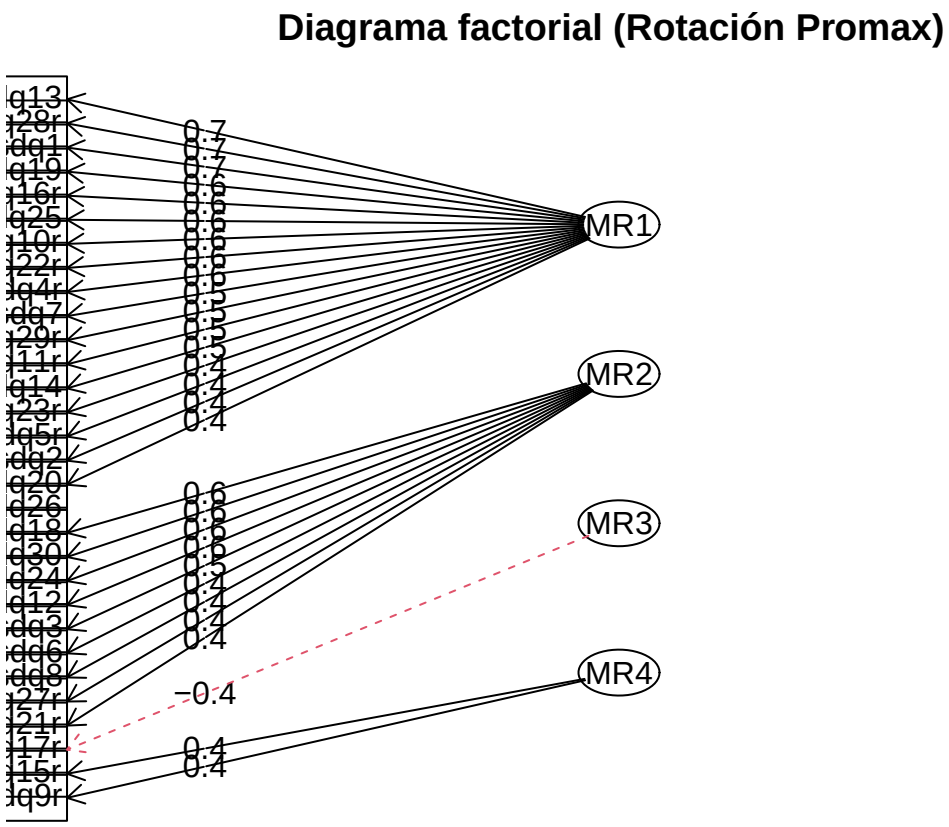

Se puede observar que al aplicar la rotación, podemos notar que los factores M3 y M4 tienen una influencia mucho menor en comparación con los otros dos.

Sería ideal omitirlos e integrar sus ítems en los dos primeros factores. Transformando el análisis factorial en una de interpretación más fácil entre los dos primeros factores claramente distintos entre sí.

```
# Factor 1 (Matematica + Autostima Generale): 18 item
factor1_cols <- c(1, 2, 4, 5, 7, 10, 11, 13, 14, 16, 17, 19, 20, 22, 23, 25, 28, 29)

# Factor 2 (Verbale/Inglese + Difficoltà di lettura): 10 item
factor2_cols <- c(3, 6, 8, 9, 12, 15, 18, 21, 24, 30)

# Creazione del vettore per i gruppi (es. per grafici o tabelle successive)
# Poiché hai 18 item nel Factor 1 e 10 nel Factor 2:
grupos_variables <- c(rep("Factor 1", 18), rep("Factor 2", 10))

# Seleccionamos solo las 28 variables que queremos analizar (excluyendo 26 y 27)
indice_variabili_finali <- c(factor1_cols, factor2_cols)
datos_filtrati <- datos[, indice_variabili_finali]

# Ejecutamos PCA solo en estas 28 variables
res.pca <- PCA(datos_filtrati, ncp = 2, graph = FALSE)

# Definimos el vector de color (ahora la longitud 28 coincide con las columnas de datos_filtrados)
grupos_variables <- c(rep("Factor 1 (Maths)", 18),
                      rep("Factor 2 (Verbal/Inglés)", 10))
```

```r
# Generemos el biplot
fviz_pca_biplot(res.pca,
                geom.ind = "point",
                col.ind = "steelblue",
                alpha.ind = 0.3,
                pointsize = 1.5,

                col.var = grupos_variables, # Ora le lunghezze corrispondono!
                palette = "jco",
                legend.title = "Dimensiones",
                arrowsize = 0.5,

                repel = TRUE,
                labelsize = 3,
                title = "Mapa Factorial: Estructura de las 28 variables",
                subtitle = "Análisis basado en 425 respuestas (Esclusi item 26 e 27)"
) +
theme_minimal() +
theme(legend.position = "right")
```

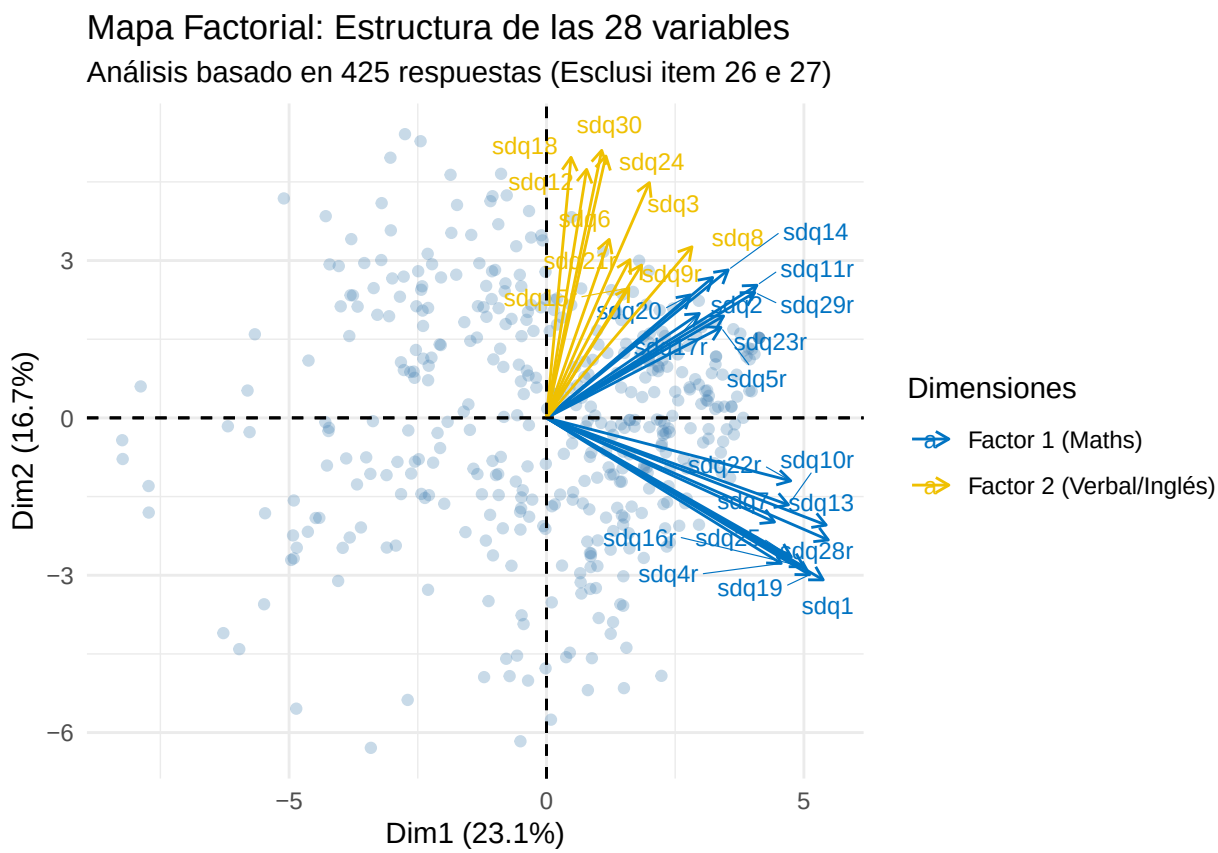

2.3.6 Alpha de Cronbach

```r
# Grupo 1: Matemática (MR1)
factor1_vars <- datos[, c(1, 4, 7, 10, 11, 13, 16, 19, 22, 25, 28, 29)]
```

```r
# Grupo 2: Verbal/Inglés (MR2 + Integración MR4)
factor2_vars <- datos[, c(3, 6, 8, 9, 12, 15, 18, 21, 24, 30)]

# Grupo 3: Autoestima General (MR3)
factor3_vars <- datos[, c(2, 5, 14, 17, 20, 23)]
```

Advertencias : sdq26 (0.113) y sdq27r (0.220) tienen valores de loading muy bajos, significa que al incluirlos vamos a empeorar lo que es el análisis de los grupos del Alpha de Cronbach, sin añadir ninguna información útil a los grupos.

Problema de M4 : Tenemos muy pocas preguntas que afectan al grupo que se basa en este factor, contiene solo sdq9r y sdq15r, mejor dirigirlas a los secundo grupo.(porque el loading es mayor respecto los otras tres)

```r
# Análisis del factor 1
rel_f1 <- alpha(factor1_vars, check.keys = TRUE)


# Análisis del factor 2
rel_f2 <- alpha(factor2_vars, check.keys = TRUE)


# Análisis del factor 3
rel_f3 <- alpha(factor3_vars, check.keys = TRUE)
```

```r
cat("Factor 1 (Matemática):   ", round(rel_f1$total$raw_alpha, 3), " ")
```

```
## Factor 1 (Matemática):    0.899
```

```r
cat("Factor 2 (Verbal/Inglés):  ", round(rel_f2$total$raw_alpha, 3), " ")
```

```
## Factor 2 (Verbal/Inglés):   0.816
```

```r
cat("Factor 3 (Autoestima):   ", round(rel_f3$total$raw_alpha, 3), " ")
```

```
## Factor 3 (Autoestima):    0.752
```

```
 El Alfa de Cronbach confirmó la fiabilidad de la estructura factorial propuesta.
```

Ejercicio 3: Análisis Factorial de dataset 'adhd.xls.'

3.3.1 Análisis previos

```r
datos <- read_xls("adhd.xls", na = "?")

# Visualización de las primeras filas con kable
head(datos)
```

```
## # A tibble: 6 x 10
##   instruct effort organize forget attention    go talks fidgets turns  runs
##      <dbl>  <dbl>    <dbl>  <dbl>     <dbl> <dbl> <dbl>   <dbl> <dbl> <dbl>
## 1        1      1        2      3         1     3     3       3     3     1
## 2        0      2        1      2         2     1     0       0     1     0
## 3        0      0        1      0         0     2     3       1     1     0
## 4        0      0        0      1         1     1     1       0     0     2
## 5        3      1        1      3         1     1     1       1     1     1
## 6        0      0        0      1         0     1     1       1     0     0
```

```r
# Analicemos la estructura de las variables
str(datos)
```

```
## tibble [500 x 10] (S3: tbl_df/tbl/data.frame)
##  $ instruct : num [1:500] 1 0 0 0 3 0 0 1 0 0 ...
##  $ effort   : num [1:500] 1 2 0 0 1 0 0 2 0 0 ...
##  $ organize : num [1:500] 2 1 1 0 1 0 1 1 0 0 ...
##  $ forget   : num [1:500] 3 2 0 1 3 1 1 2 0 0 ...
##  $ attention: num [1:500] 1 2 0 1 1 0 0 1 0 0 ...
##  $ go       : num [1:500] 3 1 2 1 1 1 0 1 0 0 ...
##  $ talks    : num [1:500] 3 0 3 1 1 1 1 1 0 0 ...
##  $ fidgets  : num [1:500] 3 0 1 0 1 1 0 2 0 0 ...
##  $ turns    : num [1:500] 3 1 1 0 1 0 0 1 0 0 ...
##  $ runs     : num [1:500] 1 0 0 2 1 0 1 1 0 0 ...
```

```r
# Verificación de valores faltantes
colSums(is.na(datos))
```

```
##  instruct    effort  organize    forget attention        go     talks   fidgets
##         0         0         0         0         0         0         0         0
##     turns      runs
##         0         0
```

El conjunto de datos se importó correctamente y no faltan valores.

Ahora deberíamos probar las hipótesis de normalidad, linealidad y correlación porque estas pruebas sirven para asegurar que los datos tengan una estructura matemática coherente y relaciones lineales robustas, sin las cuales el análisis factorial produciría resultados distorsionados o carentes de significado estadístico.

```r
test<-mvn(datos,univariate_test = "SW")
pander(test$univariate_normality)
```

Test	Variable	Statistic	p.value	Normality
Shapiro-Wilk	instruct	0.652	<0.001	Not normal
Shapiro-Wilk	effort	0.772	<0.001	Not normal
Shapiro-Wilk	organize	0.699	<0.001	Not normal
Shapiro-Wilk	forget	0.804	<0.001	Not normal
Shapiro-Wilk	attention	0.741	<0.001	Not normal
Shapiro-Wilk	go	0.773	<0.001	Not normal
Shapiro-Wilk	talks	0.83	<0.001	Not normal
Shapiro-Wilk	fidgets	0.796	<0.001	Not normal
Shapiro-Wilk	turns	0.623	<0.001	Not normal
Shapiro-Wilk	runs	0.637	<0.001	Not normal

```r
pander(test$multivariate_normality)
```

Test	Statistic	p.value	Method	MVN
Henze-Zirkler	8.197	<0.001	asymptotic	Not normal

Sin embargo, los test formales de normalidad no son necesarias porque los datos son ordinales y discretos (escala 0-3), una condición que viola la condición de continuidad requerida por estas pruebas.

Podemos comprobar a través de Skewness y Kurtosis

```r
# Selezioniamo solo Skewness e Kurtosis (colonne 11 e 12 di describe)
desc_norm <- describe(datos)[, c("skew", "kurtosis")]
pander(round(desc_norm, 2))
```

	skew	kurtosis
instruct	1.74	3.04
effort	1.04	0.36
organize	1.44	1.64
forget	0.86	0.08
attention	1.22	0.83
go	0.97	-0.2
talks	0.7	-0.3
fidgets	0.8	-0.51
turns	1.86	3.19
runs	1.77	3.11

Todas las variables son adecuadas para el análisis factorial, ya que los resultados obtenidos (Skewness entre 0,70 y 1,86 y Kurtosis entre -0,51 y 3,19) se encuentran dentro de los umbrales de tolerancia científicamente aceptados de ± 2 para la asimetría y ± 7 para la curtosi. garantizando una distribución robusta y sin distorsiones críticas.

Sin embargo, la hipótesis de normalidad no está satisfecha, es preferible no utilizar el método de máxima verosimilitud.

Calculamos la hipótesis de linealidad con la matriz de correlaciones lineales de Pearson

```r
# Cálculo de la matriz de correlación de Pearson
R <- cor(datos, method="pearson")

#Observando así la matriz vemos que las correlaciones son todas positivas y relativamente altas(>0.3)
symnum(R)
```

```
##           i e o fr a g tl fd tr r
## instruct  1
## effort    . 1
## organize  , . 1
## forget    . . . 1
## attention . . . .  1
## go        . . . .  . 1
## talks     . . . .  . . 1
## fidgets   . . . .  . , .  1
## turns     . . . .  . . .  .  1
## runs      . . . .  . . .  .  .  1
## attr(,"legend")
## [1] 0 ' ' 0.3 '.' 0.6 ',' 0.8 '+' 0.9 '*' 0.95 'B' 1
```

```r
#La maggior parte dei dati ha una correlazione buona, non abbiamo variabili che possiamo trascurare.


# Personalización del gráfico de correlación
col_custom <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD", "#4477AA"))(200)

corrplot(R,
         method = "color",
```

```
        type = "lower",
        order = "original",
        col = col_custom,
        number.digits = 2,
        addCoef.col = "black",
        tl.col = "black",
        tl.srt = 45,
        diag = TRUE,
        mar = c(0,0,2,0),
        title = "Matriz de Correlación")
```

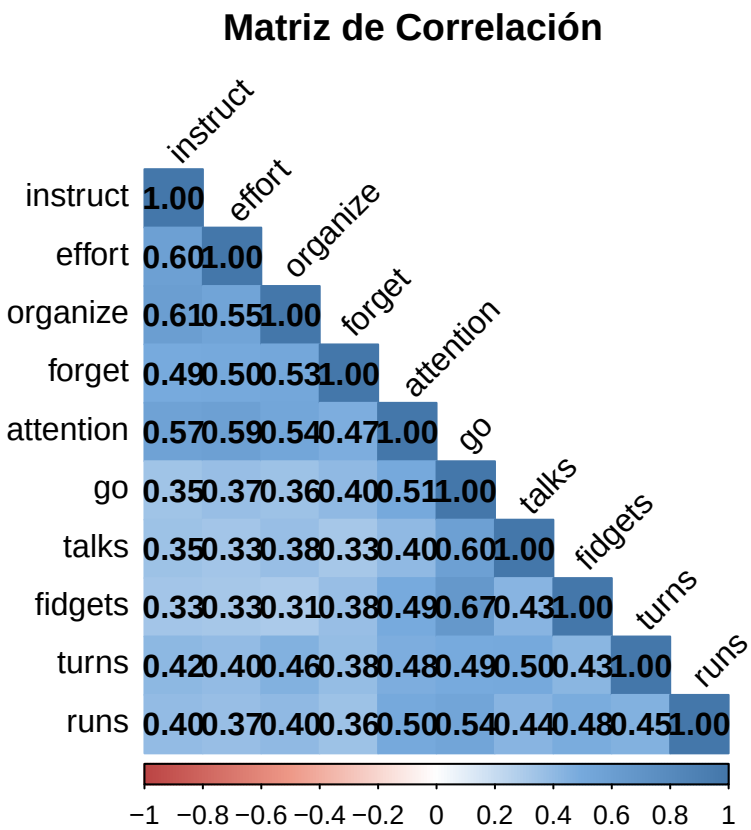

La matriz de Pearson muestra vínculos sólidos > 0,30, aceptamos que las variables tienen una correlación lineal.

Además, ninguna de las variables ha resultado ser insignificante en las correlaciones, lo que sugiere que no tenemos variables a descuidar.

Análisis de correlaciones más fuertes

Podemos distinguir los enlaces en 2 grupos diferentes:

`Impulsividad / Hiperactividad`

- **go - fidgets (0.67)**: Es la correlación más alta, indica un vínculo muy fuerte entre el impulso de moverse y la agitación motora.
- **go - talks (0.60)**: La hiperactividad motora también se refleja en la verbal .
- *__go - runs (0.54)__: Una fuerte correlación que vincula la inquietud general con la necesidad física de correr/moverse.

Desconcierto / Organización

- **instruct - organize (0.61)**: quien tiene dificultades para seguir las instrucciones suele tener problemas de organización.
- **instruct - Effort (0.60)**: indica que el esfuerzo mental y la capacidad de seguir indicaciones están fuertemente relacionados.
- **effort - attention (0.59)**: Confirma que la tenacidad en la tarea está estrechamente vinculada a la capacidad de atención.

```
#Aquí observamos las mismas conclusiones que de manera numérica, pero para verificar que son significat
det(R)
```

```
## [1] 0.0100825
```

```
#Es muy cercano a 0 por tanto es significativa

# Verificación y validación de la matriz de correlación
 cortest(R, n1= nrow(datos))
```

```
## Tests of correlation matrices
## Call:cortest(R1 = R, n1 = nrow(datos))
##  Chi Square value 5717.59  with df =  45   with probability < 0
## z of differences =  0.26
## Root Mean Square Residual =  0.51
## RMSEA =  0.5
```

El **determinante** de 0,01008 confirma que la matriz de correlación es adecuada para el análisis y no padece multicollinealidad.

La **Test de Bartlett** es ampliamente significativa (p<0.001), lo que indica que las correlaciones entre las variables son lo suficientemente fuertes como para hacer posible el análisis factorial, estadísticamente significativo.

Para terminar con el análisis previo realizaremos el test de Kayser-Meyer-Olkin, para contrastar si el análisis factorial es significativo o no antes de realizarlo.

```
#Test di Kayser-Meyer-Olkin
KMO(datos)
```

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = datos)
## Overall MSA =  0.91
## MSA for each item =
##  instruct    effort  organize    forget attention        go     talks   fidgets
##      0.91      0.91      0.91      0.94      0.93      0.85      0.90      0.88
##     turns      runs
##      0.95      0.95
```

La **Test de Kaiser-Meyer-Olkin** con un Overall MSA de 0,91 indica una excelente adecuación muestral, confirma que los datos están perfectamente estructurados para un análisis factorial robusto y que cada ítem individual contribuye de manera limpia a la medición.

`Hemos verificado todas las hipótesis, podemos proceder al análisis factorial`

3.3.2 Determinación del número de factores

```
#Primero vamos a calcular los autovalores de la matriz de correlaciones
eigen(R)$values
```

```
##  [1] 5.0675342 1.2212530 0.6664703 0.5878006 0.5186203 0.4970272 0.4290606
##  [8] 0.3735682 0.3556385 0.2830271
```

```
#Usando la regla de Kayser escogeriamos 2 factores ya que es el único autovalor mayor que la unidad.

# Visualización del Scree Plot
scree(R, factors= TRUE, pc=TRUE)
```

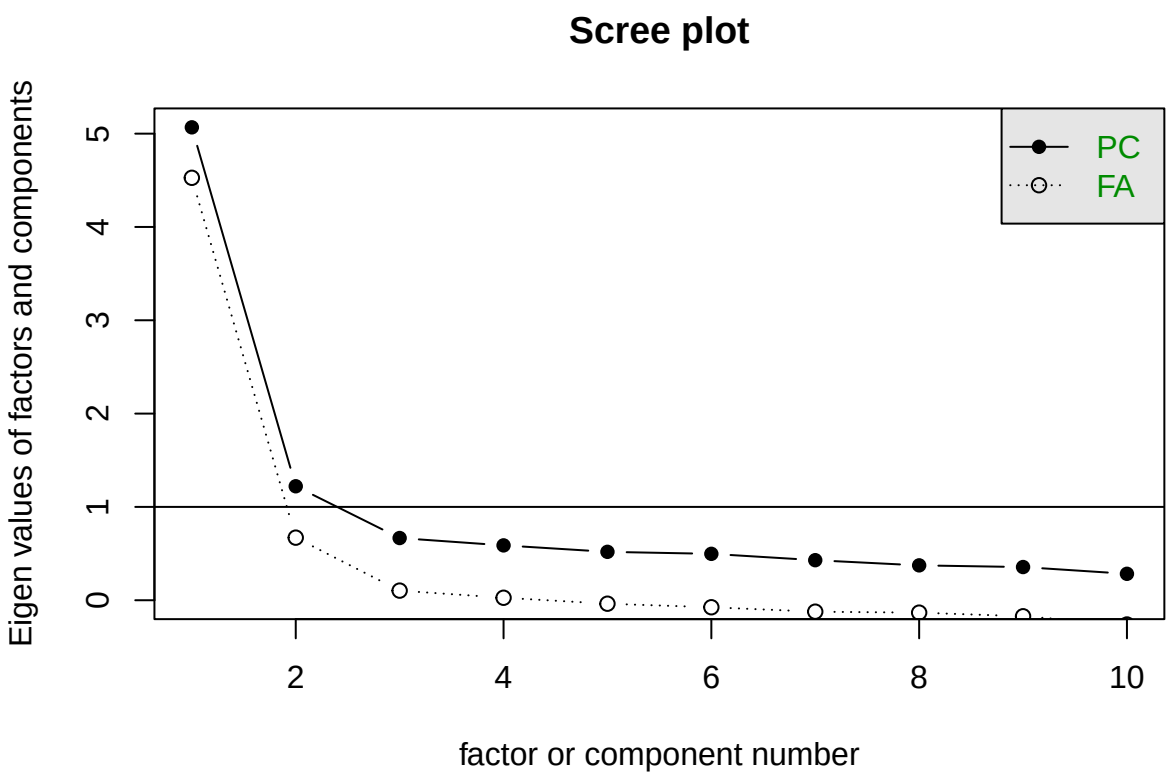


```
#También podemos verlo con el pòrcentaje de variable explicada.
fac<-prcomp(datos,scale.=TRUE,tol=NULL)
summary(fac)
```

```
## Importance of components:
##                           PC1    PC2     PC3     PC4     PC5    PC6     PC7
## Standard deviation     2.2511 1.1051 0.81638 0.76668 0.72015 0.7050 0.65503
## Proportion of Variance 0.5068 0.1221 0.06665 0.05878 0.05186 0.0497 0.04291
## Cumulative Proportion  0.5068 0.6289 0.69553 0.75431 0.80617 0.8559 0.89878
##                            PC8     PC9   PC10
## Standard deviation     0.61120 0.59635 0.5320
## Proportion of Variance 0.03736 0.03556 0.0283
## Cumulative Proportion  0.93613 0.97170 1.0000
```

```
# Usa facCP che è l'oggetto dove hai salvato i risultati di prcomp
fviz_screeplot(fac, ncp=10, choice='eigenvalue', addlabels=TRUE) +
  geom_hline(yintercept=1, linetype="dashed", color="red") # Linea del criterio di Kaiser
```

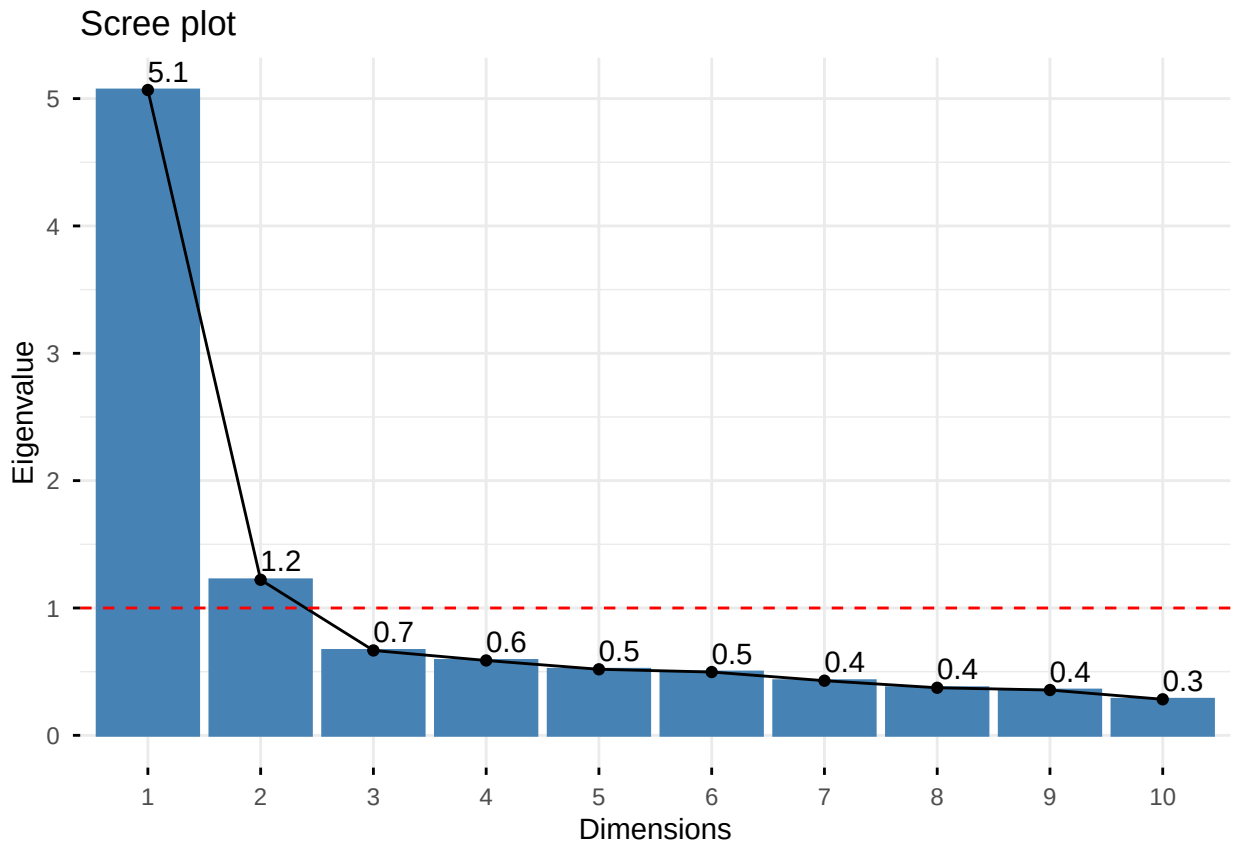

El análisis de los valores propios da lugar a dos interpretaciones:

- El salto entre el primero (5.07) y el segundo (1.22) sugiere que existe un fuerte componente común a todos los ítems.
- El hecho de que el segundo también esté por encima de 1 confirma que los datos se dividen casi con toda seguridad en dos grupos, como se ha supuesto anteriormente.

Los dos primeros componentes explican juntos el 62,89% de la varianza total, lo que confirma que una estructura bidimensional es suficiente y sólida para representar los datos.

```
#Este código realiza un análisis comparativo entre cuatro criterios diferentes (Kaiser, Parallel, OC y

ac<-parallel(subject=nrow(datos),var=ncol(datos),rep=500,cent=.05)
nS <- nScree(x=eigen(R)$values, aparallel=ac$eigen$qevpea)
pander(nS$Components)
```

noc	naf	nparallel	nkaiser
2	1	2	2

```
plotnScree(nS)
```

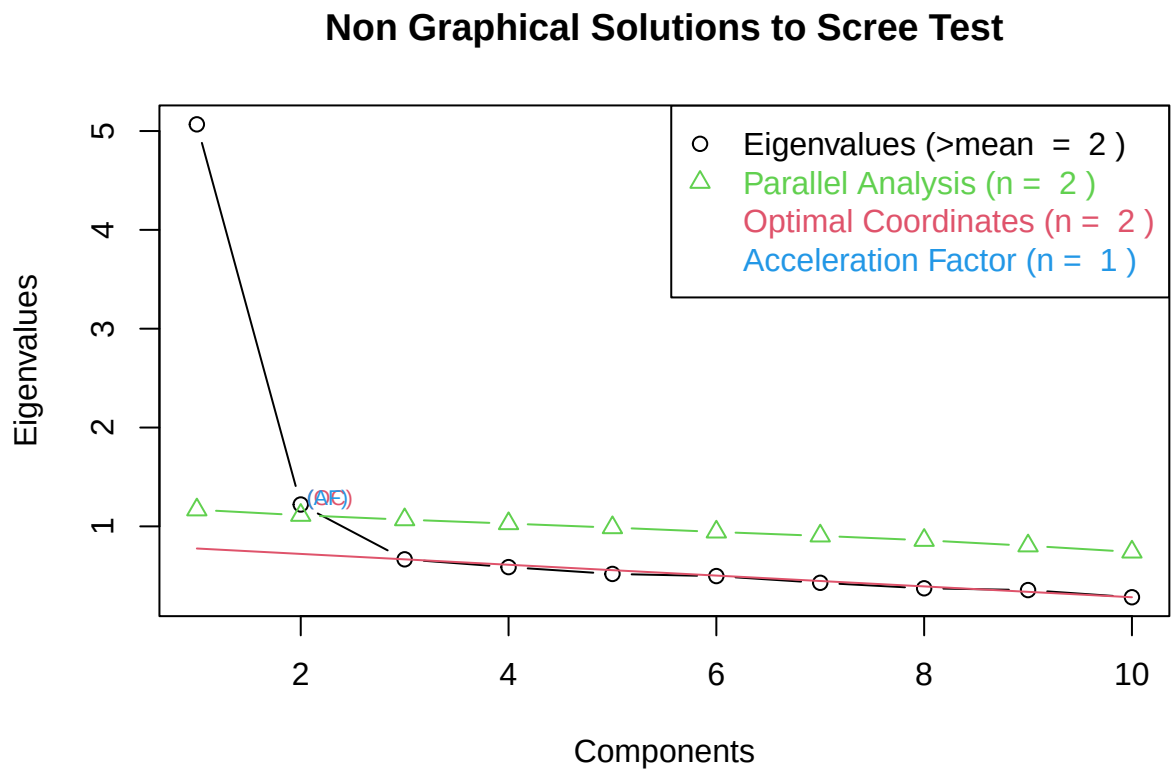

El factor de aceleración sugiere 1 porque el primer factor es dominante, pero la convergencia de todos los demás criterios a 2 confirma que existe una segunda dimensión significativa que merece ser extraída para no perder información valiosa.

También estimamos estadísticamente mediante los valores del análisis paralelo.(mas rigorosa)

```
RR <- paran(R, iterations=5000, graph=FALSE, cfa = TRUE ,color=TRUE)
```

```
##
## Computing: 10%  20%  30%  40%  50%  60%  70%  80%  90%  100%
```

```
# Comparación de vectores principales
confronto <- cbind(
  Real_Ev   = RR$Ev,
  Random_Ev = RR$RndEv,
  Adjusted  = RR$AdjEv,
  Bias      = RR$Bias
)

rownames(confronto) <- paste0("PC", 1:nrow(confronto))
pander(round(confronto, 3))
```

	Real_Ev	Random_Ev	Adjusted	Bias
PC1	3.545	2.828	0.718	2.828
PC2	0.56	2.002	-1.443	2.002
PC3	0.28	1.41	-1.13	1.41
PC4	-0.012	0.938	-0.95	0.938

	Real_Ev	Random_Ev	Adjusted	Bias
PC5	-0.064	0.558	-0.623	0.558
PC6	-0.098	0.245	-0.343	0.245
PC7	-0.195	0.028	-0.223	0.028
PC8	-0.339	-0.086	-0.253	-0.086
PC9	-0.356	-0.145	-0.211	-0.145
PC10	-0.868	-0.448	-0.42	-0.448

El análisis confirma que podemos hacer un buen análisis factorial simplemente tomando los primeros 2 componentes.

Curiosidad : PC10 indica que el análisis factorial no necesita todos los componentes para utilizar toda la información, el último componente se convierte en reindonente.

3.3.3 Análisis factorial

Comparamos los modelos para ver cuál elijo.

```r
# --- Comparación con 4 métodos ---

# mle: Máxima verosimilitud
mod_mle   <- fa(datos, nfactors = 2, rotate = "none", fm = "mle")

# minres: Residuo mínimo
mod_minres <- fa(datos, nfactors = 2, rotate = "none", fm = "minres")

# pa: Ejes principales
mod_pa   <- fa(datos, nfactors = 2, rotate = "none", fm = "pa")

# minchi: Mínimos cuadrados
mod_minchi <- fa(datos, nfactors = 2, rotate = "none", fm = "minchi")

# Creamos un marco de datos completo con todos los índices de solidez
comparar_modelos <- data.frame(
  Método = c("MLE", "MinRes", "Ejes principales (PA)", "Mínimos cuadrados (MinChi)"),

  # Error
  RMSE = c(mod_mle$RMSEA[1], mod_minres$RMSEA[1], mod_pa$RMSEA[1], mod_minchi$RMSEA[1]),

  # Solidez Bayesiana (Más bajo/negativo es mejor)
  BIC = c(mod_mle$BIC, mod_minres$BIC, mod_pa$BIC, mod_minchi$BIC),

  # Complejidad media (Más cerca de 1 indica factores más claros y distintos)
  Complexity = c(mean(mod_mle$complexity), mean(mod_minres$complexity),
                 mean(mod_pa$complexity), mean(mod_minchi$complexity))
)


# Ordenamos por BIC porque es el indicador más severo de la solidez
comparar_modelos <- comparar_modelos[order(comparar_modelos$BIC), ]

pander(comparar_modelos,
       caption = "Comparación de la solidez: BIC (eficiencia) y Complexidad (pureza)")
```

Table 18: Comparación de la solidez: BIC (eficiencia) y Complexidad (pureza)

	Método	RMSE	BIC	Complexity
1	MLE	0.04921	-104.1	1.334
4	Mínimos cuadrados (MinChi)	0.04926	-104	1.33
2	MinRes	0.05023	-102.7	1.321
3	Ejes principales (PA)	0.05024	-102.7	1.321

El mejor modelo para el análisis factorial es el de **Máxima Verosimilitud**,

Utilizamos el método de los **Mínimos Cuadrados** como mejor estimación.

Aunque con una complejidad ligeramente mayor, tiene mejores RMSE y BIC (No considerando MLE).

Sin embargo, hay que precisar que la diferencia es mínima, cualquier modelo utilizado nos da una buena estimación de los datos.

```r
#  Estraiamo i loadings (saturazioni)

cargas_matrice <- as.matrix(mod_minchi$loadings[, 1:2])

colnames(cargas_matrice) <- c("PC1", "PC2")

# Visualizzazione del risultato arrotondato
round(cargas_matrice, 3)
```

```
##             PC1    PC2
## instruct  0.672  0.411
## effort    0.662  0.362
## organize  0.666  0.376
## forget    0.618  0.212
## attention 0.750  0.166
## go        0.780 -0.427
## talks     0.637 -0.202
## fidgets   0.675 -0.307
## turns     0.647 -0.016
## runs      0.655 -0.099
```

El análisis muestra que tenemos una sólida base común representada por un factor general (PC1), para luego tener un factor que captura las especificidades de 2 subgrupos distintos (PC2).

```r
fa.diagram(cargas_matrice)
```

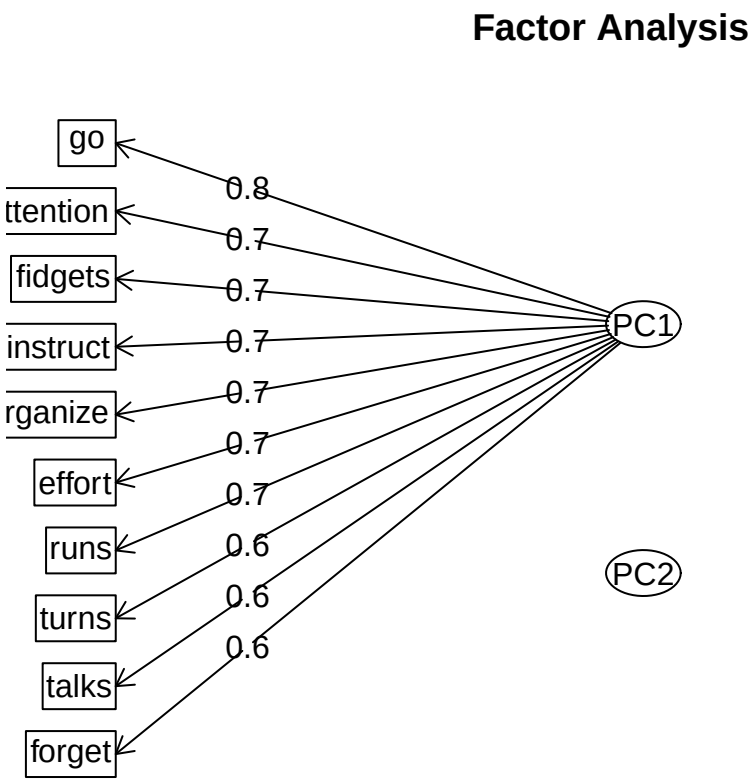

El hecho de que todas las variables estén fuertemente saturadas en el primer factor (F1) demuestra la existencia de una dimensión general del trastorno por TDAH que incide fuertemente con respecto al segundo factor (F2) que dice en qué dirección se inclina el trastorno.

3.3.4 Comunalidad

Para obtener una mejor representación, en lugar de ponderaciones analizaremos la varianza explicada (cuánta información se captura) de cada variable en los dos factores.

Ahora vamos a comparar las diversas comunalidades de los otros métodos, no para verificar más la validez del método elegido, sino para comprobar si hay variables que son muy influenciadas según el modelo elegido.

```
# Clasificación y comparación de las comunalidades

# Extraemos la comunalidad y la clasificamos de mejor a peor
c_mle   <- sort(mod_mle$communality, decreasing = TRUE)
c_minres <- sort(mod_minres$communality, decreasing = TRUE)
c_pa   <- sort(mod_pa$communality, decreasing = TRUE)
c_minchi <- sort(mod_minchi$communality, decreasing = TRUE)


# Centrarse en las mejores comunidades
tabella_comunalita <- cbind(MLE = c_mle, MinRes = c_minres, PA = c_pa, MinChi = c_minchi)
pander(round(tabella_comunalita, 3),
       caption = "Top Comunalities (h2) sorted by method")
```

Table 19: Top Comunalities (h2) sorted by method

	MLE	MinRes	PA	MinChi
go	0.801	0.793	0.789	0.792
instruct	0.621	0.617	0.617	0.621
attention	0.59	0.592	0.592	0.59
organize	0.586	0.588	0.588	0.585
effort	0.57	0.573	0.573	0.57
fidgets	0.549	0.533	0.534	0.549
talks	0.445	0.445	0.445	0.447
runs	0.437	0.443	0.443	0.439
forget	0.428	0.433	0.434	0.428
turns	0.418	0.427	0.427	0.419

No tenemos ninguna variable con una fuerte 'oscilación' dependiendo del modelo elegido.

Ahora vamos a analizar en detalle cómo está distribuida la información en los dos componentes de nuestro modelo elegido.

```r
#  Extraemos las cargas (loadings) del modelo MLE
cargas_minchi <- mod_minchi$loadings[, 1:2]

#  Elevamos al cuadrado para obtener la varianza explicada por cada componente
varianza_repartida <- cargas_minchi^2

#  Añadimos la Comunalidad Total (h2) para poder ordenar la tabla
h2_total <- rowSums(varianza_repartida)
tabla_reparticion <- cbind(varianza_repartida, h2_total)

#  Renombramos las columnas para mayor claridad
colnames(tabla_reparticion) <- c("PC1", "PC2", "Comunalidad Tot")

# Ordenamos la tabla según la Comunalidad Total (del síntoma más sólido al menos)
tabla_final <- tabla_reparticion[order(tabla_reparticion[, 3], decreasing = TRUE), ]

#  Visualización elegante con pander
pander(round(tabla_final, 3),
       caption = "Repartición de la Comunalidad entre PC1 y PC2")
```

Table 20: Repartición de la Comunalidad entre PC1 y PC2

	PC1	PC2	Comunalidad Tot
go	0.609	0.182	0.792
instruct	0.452	0.169	0.621
attention	0.562	0.027	0.59
organize	0.444	0.141	0.585
effort	0.439	0.131	0.57
fidgets	0.456	0.094	0.549
talks	0.406	0.041	0.447
runs	0.429	0.01	0.439
forget	0.383	0.045	0.428
turns	0.419	0	0.419

Se puede notar perfectamente lo que hemos dicho antes.

Ahora hacemos una visualización gráfica.

```
# Grafico delle saturazioni
plot(mod_minchi, labels = colnames(datos), cex = 0.7,
     main = "Mapa de los factores: Mínimos Cuadrados")
```

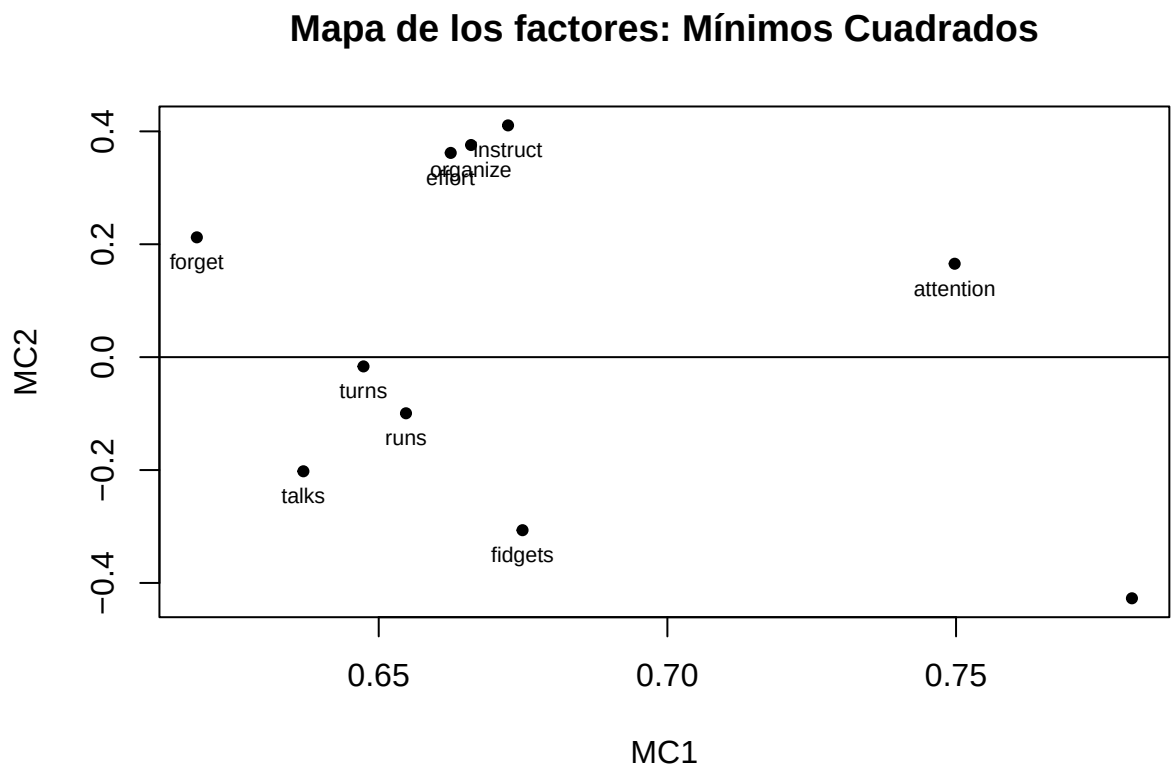

Se puede notar que la variable turns no es una variable que pertenece distintivamente a un grupo específico como por ejemplo go.

Utilizamos la PA para visualizar cómo se ubican las personas en el gráfico factorial.

```
facCP <- prcomp(datos, scale. = TRUE)

# Variables coloreadas por su calidad de representación (cos2)
fviz_pca_var(facCP, col.var = "red",
             repel = TRUE
)
```

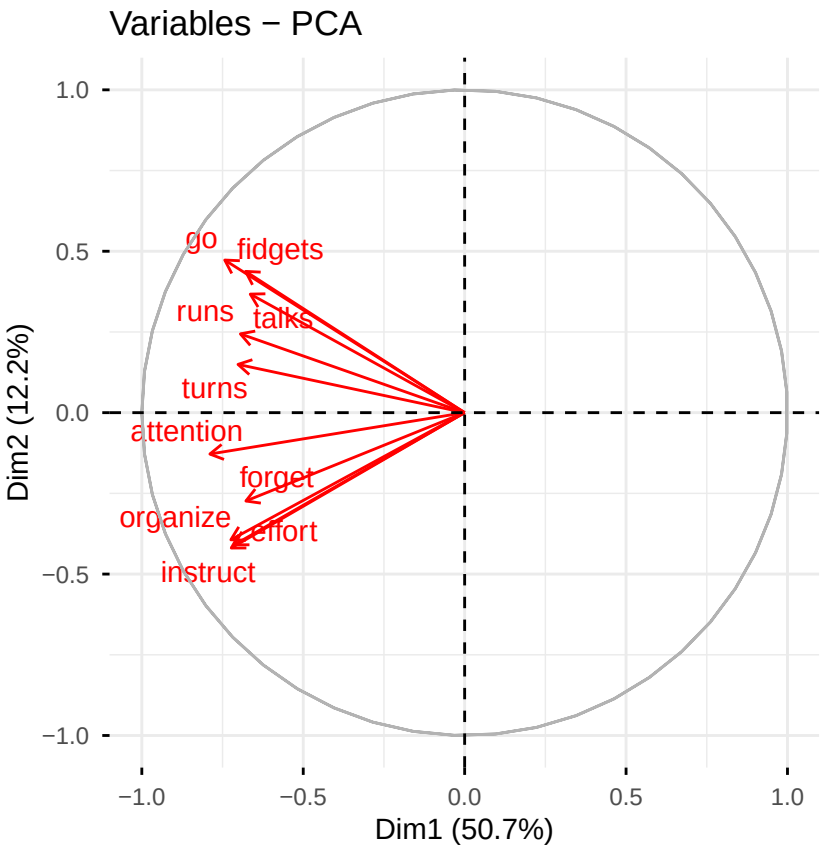


```r
# Gráfico Biplot (individuos + variables)
fviz_pca_biplot(facCP,
                # Rimuove le etichette degli individui (usa solo i punti)
                geom.ind = "point",

                #  Colori ad alta evidenza
                col.var = "red",          # Variabili in rosso acceso
                col.ind = "steelblue",        # Individui in nero
                alpha.ind = 0.3,          # Trasparenza per gestire la sovrapposizione

                #  Estetica delle frecce
                arrowsize = 0.5,
                labelsize = 5,            # Dimensione del testo delle variabili

                #  Titoli e pulizia
                title = "Mapa PCA: Variables y individuos",
                repel = TRUE              # Evita sovrapposizione nomi variabili
)
```

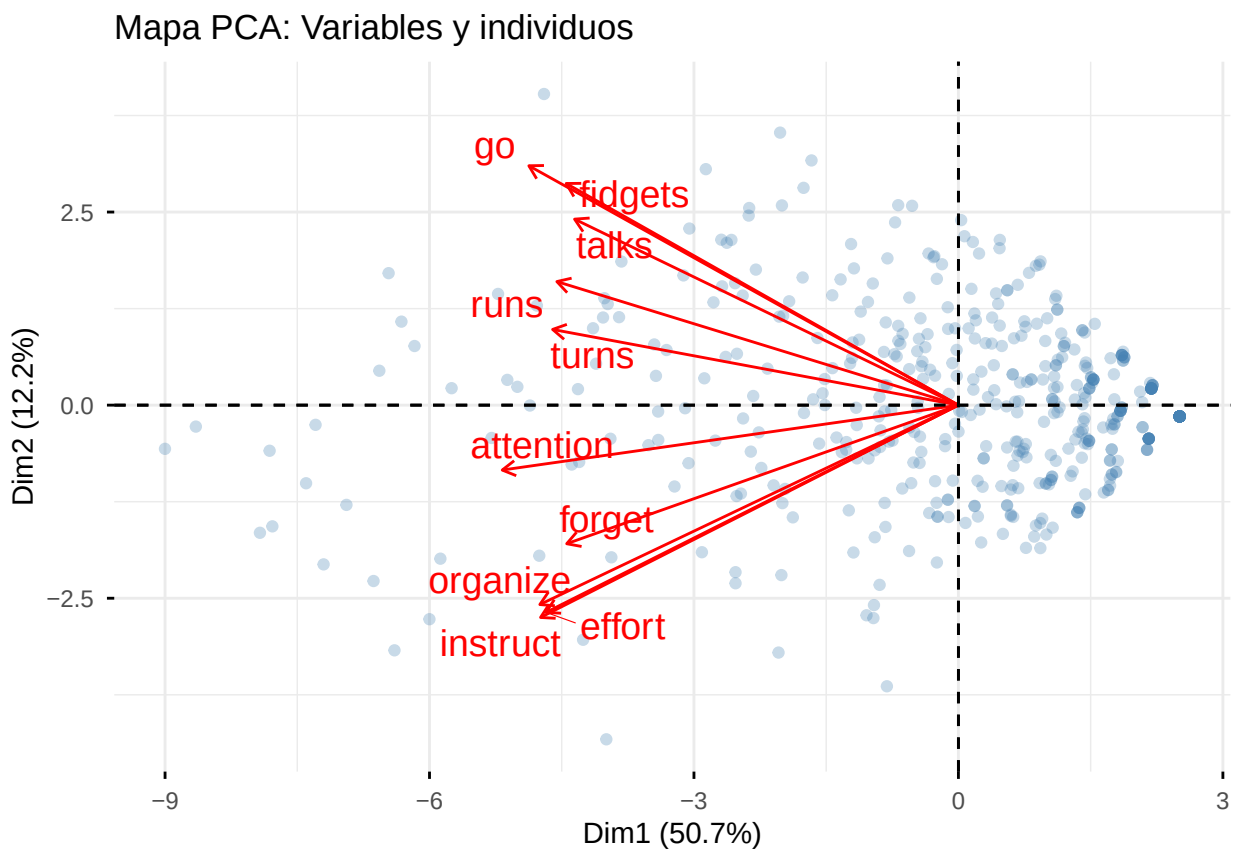

3.3.5 Rotacion

Usamos la rotación para maximizar las diferencias, mueve los ejes matemáticos para hacer que los resultados sean interpretables.

Útil cuando en nuestro caso el primer factor se toma "un poco de todo", creando confusión.

```
#Aqui podemos ver como sabemos de antes que todas las variables estan cargados negativamente y hay dife

# --- Comparación estadística de la rotación ---

rotazioni <- c("none", "varimax", "quartimax", "promax", "oblimin")

confronta_rot <- function(tipo) {
  mod <- fa(datos, nfactors = 2, fm = "minchi", rotate = tipo)

  data.frame(
    Rotazione = tipo,
    BIC = mod$BIC,
    RMSEA = as.numeric(mod$RMSEA[1]),
    Complexity_Media = mean(mod$complexity),
    Varianza_Totale = sum(mod$Vaccounted["Proportion Var",])
  )
}

risultati_statistici <- do.call(rbind, lapply(rotazioni, confronta_rot))
```

```r
# Arrotondiamo solo le colonne numeriche (dalla 2 alla 5)
risultati_statistici[, 2:5] <- round(risultati_statistici[, 2:5], 4)

# Ordiniamo per Complexity_Media (la più bassa è la migliore)
risultati_statistici <- risultati_statistici[order(risultati_statistici$Complexity_Media), ]


pander(risultati_statistici)
```

	Rotazione	BIC	RMSEA	Complexity_Media	Varianza_Totale
4	promax	-104	0.0493	1.163	0.5438
5	oblimin	-104	0.0493	1.194	0.5438
1	none	-104	0.0493	1.33	0.5438
3	quartimax	-104	0.0493	1.433	0.5438
2	varimax	-104	0.0493	1.44	0.5438

La comparación estadística entre diferentes procedimientos de rotación indica que la rotación **Promax** minimiza la complejidad de la estructura factorial (Mean Complexity = 1,163).

Los otros índices iguales sólo nos dan confirmación de la estabilidad del modelo factorial.

```r
 # Applichiamo la rotazione Promax

rot_res <- promax(cargas_matrice, m = 4)

rotacionCP <- rot_res$loadings

colnames(rotacionCP) <- c("PC1", "PC2")

print(rotacionCP, cutoff = 0.3, sort = TRUE)
```

```
##
## Loadings:
##           PC1    PC2
## go         1.007
## talks      0.631
## fidgets    0.789
## runs       0.507
## instruct          0.888
## effort            0.818
## organize          0.838
## forget            0.596
## attention         0.599
## turns      0.394  0.305
##
##                  PC1   PC2
## SS loadings    2.541 3.044
## Proportion Var 0.254 0.304
## Cumulative Var 0.254 0.558
```

```r
fa.diagram(rotacionCP, main = "Diagrama factorial (Rotación Promax)")
```

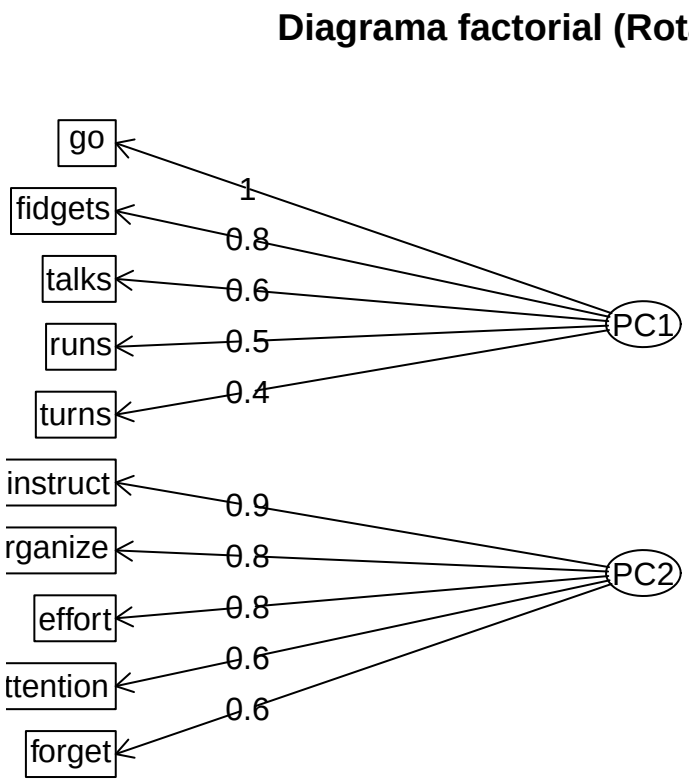

El análisis revela una estructura bipolar , el modelo dividió los 10 síntomas en dos "súper-categorías".

El PC1 agrupa los síntomas relacionados con la falta de atención y la gestión del esfuerzo.

el PC2 aísla las manifestaciones de hiperactividad motora.

La varianza explicada del 55,8% confirma la alta capacidad del modelo para representar las construcciones latentes de la perturbación.

3.3.6 Verifica della Alpha di Cronbach

```
# Gruppo 1: Disattenzione (PC1)
datos_1 <- datos[, c("instruct", "effort", "organize", "forget", "attention")]

# Gruppo 2: Iperattività (PC2)
datos_2 <- datos[, c("go", "talks", "fidgets", "turns", "runs")]

# Calcolo dell'Alfa per il primo gruppo
alpha_1 <- alpha(datos_1, check.keys = TRUE)

# Calcolo dell'Alfa per il secondo gruppo
alpha_2 <- alpha(datos_2, check.keys = TRUE)

cat("Alpha di Cronbach - Hiperactividad:", alpha_2$total$raw_alpha, "\n")
```

```
## Alpha di Cronbach - Hiperactividad: 0.8327616
```

```r
cat("Alpha di Cronbach - Inatención:", alpha_1$total$raw_alpha, "\n")
```

```
## Alpha di Cronbach - Inatención: 0.8551184
```

El Alfa nos dice cuánto los ítems de un grupo están relacionados entre sí, en nuestro caso tenemos la confirmación definía que las variables de un grupo están midiendo el mismo concepto y han sido puestas juntas por puro azar.

```r
# Agrupamos las variables de forma dinámica (5 de Inatención, 5 de Hiperactividad)
grupos_tdah <- rep(c("Inatención", "Hiperactividad"), each = 5)

# 2. Generamos el Biplot optimizado
fviz_pca_biplot(facCP,
                # --- Configuración de Pacientes ---
                geom.ind = "point",
                col.ind = "steelblue",
                alpha.ind = 0.4,

                # --- Configuración de Síntomas ---
                col.var = grupos_tdah,
                palette = c("orange", "red"),
                legend.title = "Dimensiones TDAH",

                # --- Estética y Etiquetas ---
                arrowsize = 0.6,
                repel = TRUE,
                title = "Mapa Clínico: Pacientes y Síntomas"
) +

  theme_minimal()
```

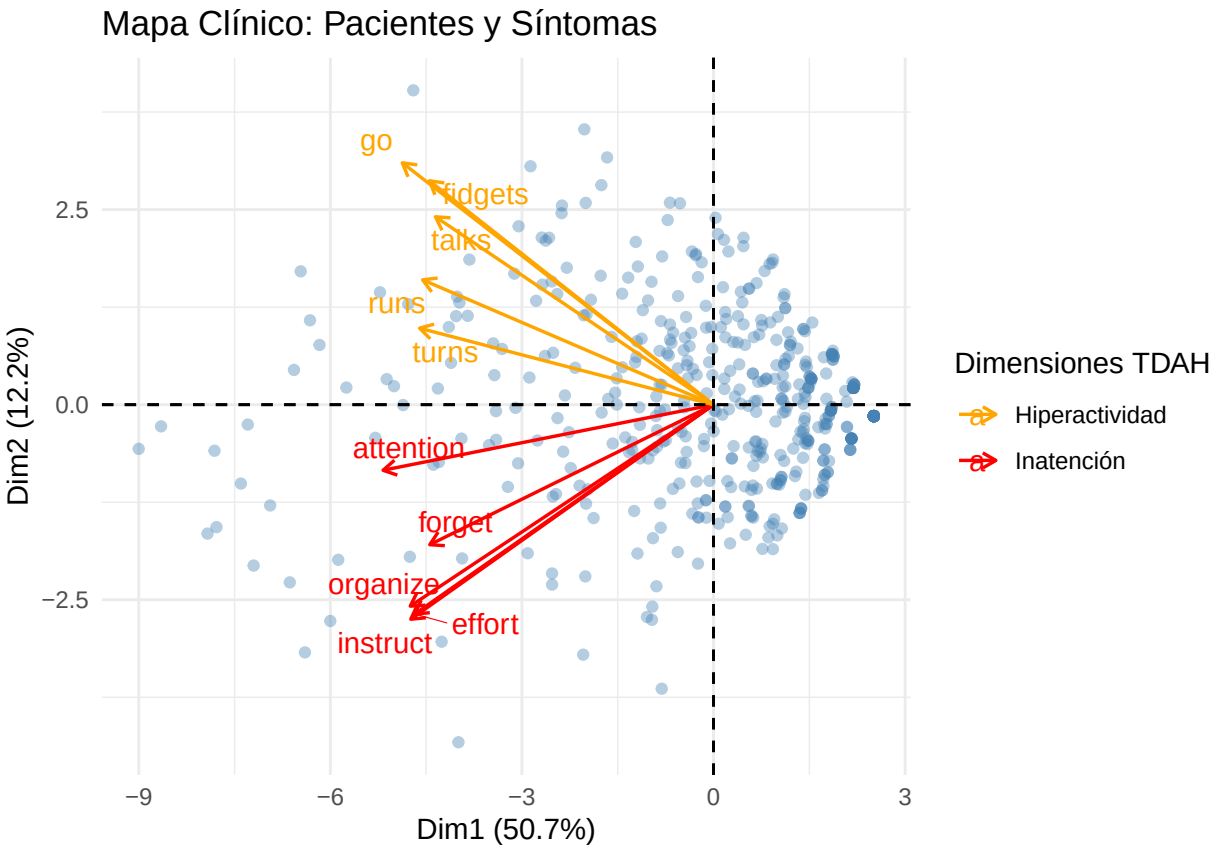

Conclusión

El análisis factorial nos permite decir con cierta seguridad estadística que las 10 variables se pueden distinguir en 2 grupos.

Los cinco primeros elementos se refieren a la dimensión de los problemas de atención, mientras que los cinco últimos elementos se refieren a la dimensión de hiperactividad/impulsividad.