Ejercicios de Clustering

Jan Żurek y Guido D'Inverno

04/2026

Contents

Ejercicio 1 **1**

1.1. Análisis previos 1

1.2. Método de clustering y validación del modelo seleccionado 4

1.3. Comparación entre dos modelos 13

1.4. Número optimo de cluster 16

Ejercicio 2: Análisis Clustering de dataset 'cluster2.txt' **20**

2.1. Análisis previos 20

2.2. Método de clustering y validación del modelo seleccionado 22

2.3. Comparación entre dos modelos 26

2.4. Selección del número de clústeres 28

Ejercicio 1

El fichero cluster.txt contiene datos económicos para 24 paises de la europeos. Se pide realizar un análisis cluster para clasificar a los países. Realizarlo por varios métodos

1.1. Análisis previos

```
#Primero procedemos a leer el fichero de datos

datos1 <- read.table("cluster.txt", sep="\t", header = T, dec = ".")
rownames(datos1) <- datos1$pais
datos_num <- datos1[, -1]

pander(head(datos_num))
```

Table 1: Table continues below

	PIB_habitante	Tasa_crecimiento_PIB
Bélgica	117.7	1.5
Replublica Checa	66.4	1.5
Dinamarca	121.6	0.5
Alemania	108.8	0.1
Estonia	45.1	7.2
Grecia	76.7	3.8

Table 2: Table continues below

	Productividad_laboral	Productividad_laboral_Hora
Bélgica	127.7	121.6
Replublica Checa	60.1	44.7
Dinamarca	102.3	96.9
Alemania	99.9	102.2
Estonia	45.8	34
Grecia	97.2	66

Table 3: Table continues below

	Tasa_crecimiento_laboral
Bélgica	-0.2
Replublica Checa	0.8
Dinamarca	-0.2
Alemania	-0.6
Estonia	1.3
Grecia	0.1

Table 4: Table continues below

	Tasa_crecimiento_lab_femenino
Bélgica	0.8
Replublica Checa	0.3
Dinamarca	-0.1
Alemania	0.5
Estonia	1.4
Grecia	1.1

Table 5: Table continues below

	Tasa_crecimiento_lab_masc	Tasa_Inflaccion
Bélgica	-0.8	1.6
Replublica Checa	1.1	1.4
Dinamarca	-0.3	2.4
Alemania	-1.4	1.3

	Tasa_crecimiento_lab_masc	Tasa_Inflaccion
Estonia	1.1	3.6
Grecia	-0.5	3.9

Table 6: Table continues below

	coste_cecimiento_laboral	consolidacion_deuda_publica
Bélgica	0.4	0
Replublica Checa	3.2	-6.8
Dinamarca	0.9	1.4
Alemania	-0.7	-3.8
Estonia	-0.2	1.5
Grecia	2	-4.9

	Deficit_publico
Bélgica	105.4
Replublica Checa	29.8
Dinamarca	47.6
Alemania	61.2
Estonia	5.8
Grecia	111.6

```r
datos_escalados <- scale(datos_num)

# Verificación de valores faltantes
pander(colSums(is.na(datos_escalados)))
```

Table 8: Table continues below

PIB_habitante	Tasa_crecimiento_PIB	Productividad_laboral
0	0	0

Table 9: Table continues below

Productividad_laboral_Hora	Tasa_crecimiento_laboral
0	0

Table 10: Table continues below

Tasa_crecimiento_lab_femenino	Tasa_crecimiento_lab_masc	Tasa_Inflaccion
0	0	0

coste_cecimiento_laboral	consolidacion_deuda_publica	Deficit_publico
0	0	0

El conjunto de datos no tiene ningún valor que falte.

```
distancias <- dist(datos_escalados, method = "euclidean")

fviz_dist(dist.obj = distancias) +
  ggtitle("Mapa de las distancias entre paises")
```

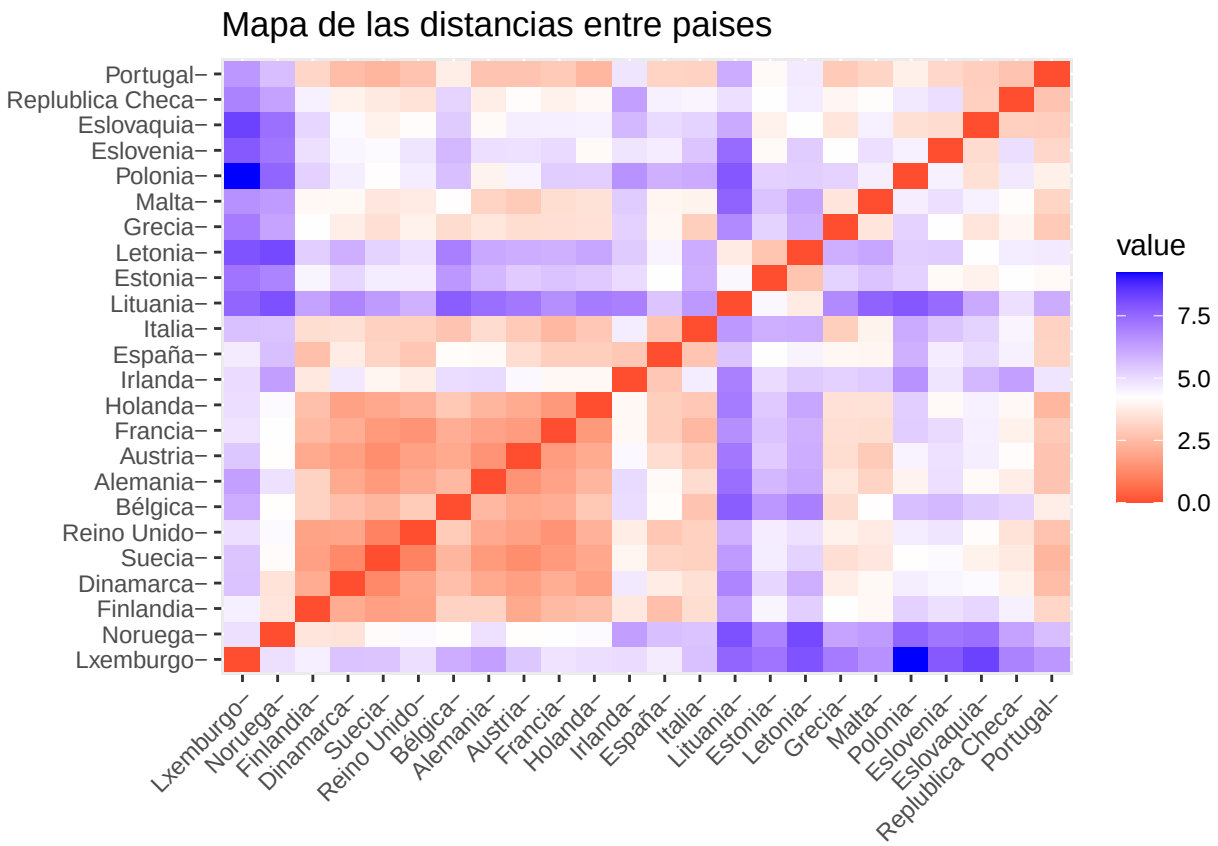

1.2. Método de clustering y validación del modelo seleccionado

```
m <- c("average", "single", "complete", "ward")
names(m) <- c("average", "single", "complete", "ward")

ac <- function(x){
  agnes(datos_escalados, method = x)$ac
}

lapply(m, ac)
```

```
## $average
```

```
## [1] 0.5118291
##
## $single
## [1] 0.4672288
##
## $complete
## [1] 0.6943841
##
## $ward
## [1] 0.7553296
```

Para seleccionar el método de agrupamiento jerárquico más adecuado, hemos calculado el Coeficiente de Aglomeración (AC) para cuatro técnicas diferentes. Este coeficiente mide la calidad de la estructura de clusters identificada, donde valores más cercanos a 1 indican una estructura de agrupamiento más fuerte y definida.

Al comparar los resultados:

- Average: 0.511
- Single: 0.467
- Complete: 0.694
- Ward: 0.755

Se observa que el método de Ward presenta el coeficiente más elevado (0.755). Esto indica que este algoritmo es el que mejor identifica la estructura natural de los datos económicos de los 24 países. Por lo tanto, utilizaremos el método de Ward para realizar el análisis de clusters definitivo y generar el dendrograma.

```r
clusterS <- hclust(distancias, method = "ward.D")

plot(clusterS, main = "Cluster Jerárquico de Países Europeos",
     sub = "Método de Ward", xlab = "Países", ylab = "Distancia")
rect.hclust(clusterS, k = 4, border = 3:6)
```

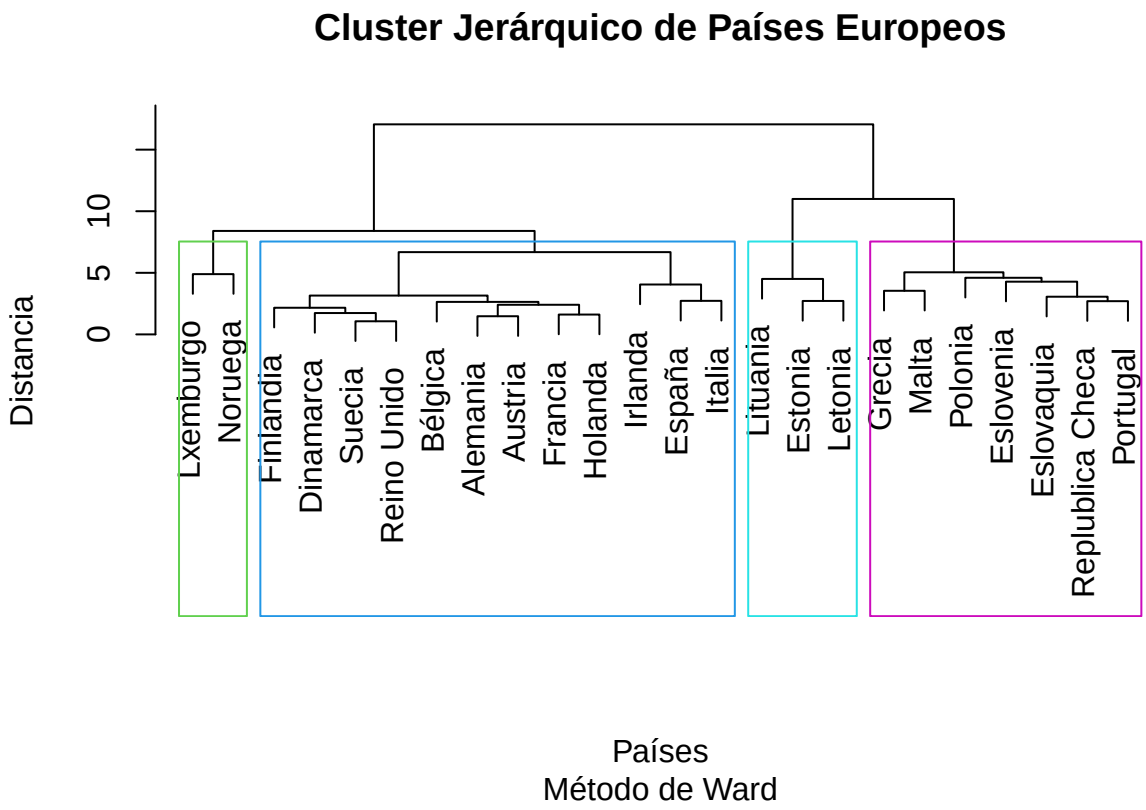


```r
fviz_dend(clusterS, k = 4,
          cex = 0.6,
          type = "phylogenic",
          repel = TRUE,
          ggtheme = theme_gray())
```

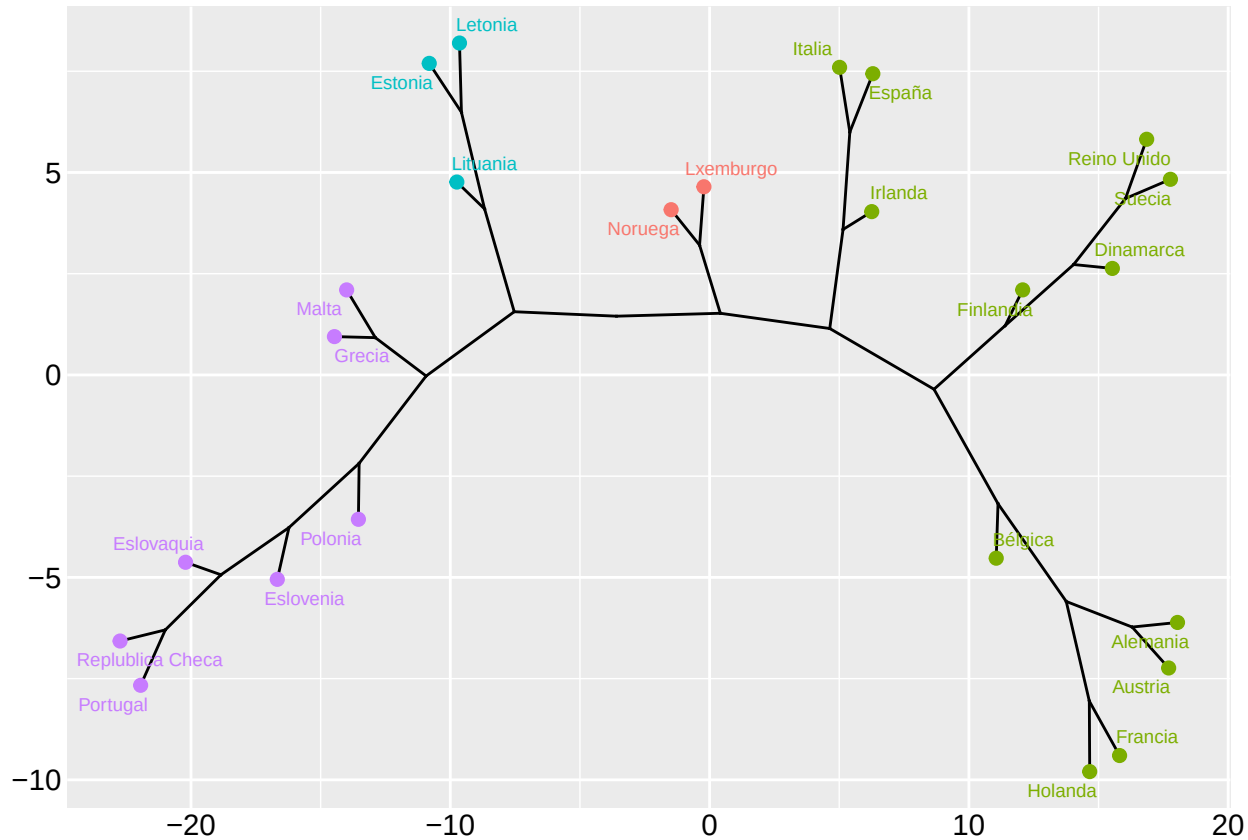


```r
grupos <- cutree(clusterS, k = 4)

print(grupos)
```

```
##          Bélgica Replublica Checa        Dinamarca         Alemania
##                1                2                1                1
##          Estonia           Grecia           España          Francia
##                3                2                1                1
##          Irlanda           Italia          Letonia         Lituania
##                1                1                3                3
##        Lxemburgo            Malta          Holanda          Austria
##                4                2                1                1
##          Polonia         Portugal        Eslovenia       Eslovaquia
##                2                2                2                2
##        Finlandia           Suecia      Reino Unido          Noruega
##                1                1                1                4
```

Análisis de la Correlación Cofenética

Para validar la fiabilidad de nuestros dendrogramas, hemos calculado el Coeficiente de Correlación Cofenética. Este índice mide la distorsión que introduce el agrupamiento con respecto a las distancias originales entre los países. Una correlación alta (cercana a 1) indica que el dendrograma es una representación fiel de las distancias reales en los datos económicos.

Como se observa en la tabla anterior, los métodos se ordenan según su capacidad para preservar estas distancias. Generalmente, el método Average suele presentar una correlación más alta, mientras que el

método de Ward, aunque es excelente para crear grupos compactos y equilibrados, puede presentar una correlación ligeramente menor debido a su naturaleza matemática.

Esta comparativa nos permite confirmar qué método es el más robusto para nuestra clasificación final.

```
dend1 <- hclust(distancias, method = "complete")
dend2 <- hclust(distancias, method = "single")
dend3 <- hclust(distancias, method = "average")
dend4 <- hclust(distancias, method = "centroid")
dend5 <- hclust(distancias, method = "ward.D2")

coecof<- cophenetic(clusterS)
coecof1<- cophenetic(dend1)
coecof2<- cophenetic(dend2)
coecof3<- cophenetic(dend3)
coecof4<- cophenetic(dend4)
coecof5<- cophenetic(dend5)

risultati_cofenetici <- data.frame(
  Metodo = c("Ward.D", "Complete", "Single", "Average", "Centroid", "Ward.D2"),
  Correlazione = c(
    cor(distancias, coecof),
    cor(distancias, coecof1),
    cor(distancias, coecof2),
    cor(distancias, coecof3),
    cor(distancias, coecof4),
    cor(distancias, coecof5)
    )
)

risultati_ordinati <- risultati_cofenetici[order(-risultati_cofenetici$Correlazione), ]

panderOptions('table.split.table', Inf)
pander(risultati_ordinati, caption = "Comparación de la correlación cofenética por método de enlace")
```

Table 12: Comparación de la correlación cofenética por método de enlace

	Metodo	Correlazione
5	Centroid	0.8433
4	Average	0.833
3	Single	0.8254
2	Complete	0.7866
6	Ward.D2	0.6116
1	Ward.D	0.5707

Interpretación de los Resultados de Correlación Cofenética

Los resultados muestran que el método de Centroide (0.8433) y el método Average (0.8330) poseen la mayor correlación cofenética. Esto significa que estos dos métodos son los que mejor preservan las distancias originales entre los países, ofreciendo una representación gráfica más fiel a la realidad de los datos.

Por otro lado, el método de Ward (0.6116) presenta una correlación significativamente menor. Esto es un comportamiento esperado, ya que el algoritmo de Ward tiende a distorsionar las distancias originales para priorizar la creación de clusters compactos y con una varianza interna mínima.

Conclusión de la comparativa:

Aunque el método Average es más fiel geométricamente, para objetivos de clasificación socioeconómica solemos preferir el método de Ward (que obtuvo el mejor Coeficiente de Aglomeración AC anteriormente). Ward permite identificar grupos de países más equilibrados y claramente diferenciados, lo cual es más útil desde el punto de vista del análisis económico, a pesar de su menor correlación cofenética.

Comparación con el Método Divisivo (DIANA)

Además de los métodos aglomerativos vistos anteriormente, existe el algoritmo DIANA (Divisive Analysis). A diferencia de agnes, que construye los grupos desde abajo hacia arriba, DIANA comienza con todos los países en un único gran cluster y los divide sucesivamente hasta que cada objeto es independiente.

Este enfoque es especialmente útil para identificar grandes estructuras jerárquicas en los datos económicos.

```r
cluster_top_down <- diana(datos_escalados, metric = "euclidean" ) #se introduce la matriz de datosprint
print(cluster_top_down)
```

```
## Merge:
##       [,1] [,2]
##  [1,]  -22  -23
##  [2,]   -4  -16
##  [3,]   -8  -15
##  [4,]   -3    1
##  [5,]    4    2
##  [6,]    5    3
##  [7,]   -2  -18
##  [8,]   -5  -11
##  [9,]   -7   -9
## [10,]    6  -21
## [11,]   -1   10
## [12,]  -19  -20
## [13,]   11  -10
## [14,]    7   -6
## [15,]   14  -14
## [16,]    8  -12
## [17,]  -17   12
## [18,]  -13  -24
## [19,]   13   15
## [20,]   19    9
## [21,]   20   17
## [22,]   18   16
## [23,]   21   22
## Order of objects:
##  [1] Bélgica          Dinamarca        Suecia           Reino Unido
##  [5] Alemania         Austria          Francia          Holanda
##  [9] Finlandia        Italia           Replublica Checa Portugal
## [13] Grecia           Malta            España           Irlanda
## [17] Polonia          Eslovenia        Eslovaquia       Lxemburgo
## [21] Noruega          Estonia          Letonia          Lituania
## Height:
##  [1] 3.083774 1.911458 1.064630 2.033260 1.474983 2.337109 1.609879 3.083774
##  [9] 3.426206 5.148651 2.697290 3.996833 4.172329 6.258528 2.803780 6.567093
## [17] 4.553474 3.304638 9.221073 4.893572 9.221073 2.714035 4.395176
## Divisive coefficient:
## [1] 0.6848313
```

```
##
## Available components:
## [1] "order"     "height"    "dc"        "merge"     "diss"      "call"
## [7] "order.lab" "data"
```

```r
plot(cluster_top_down)
```

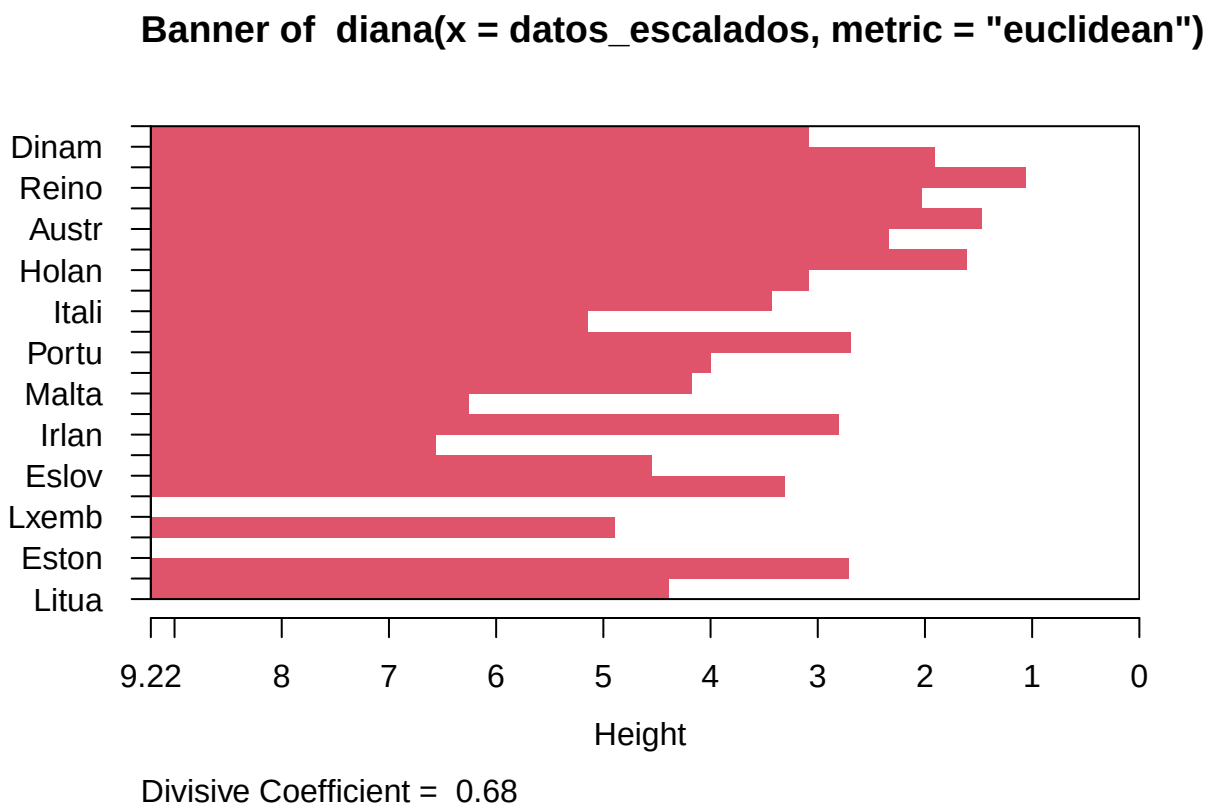

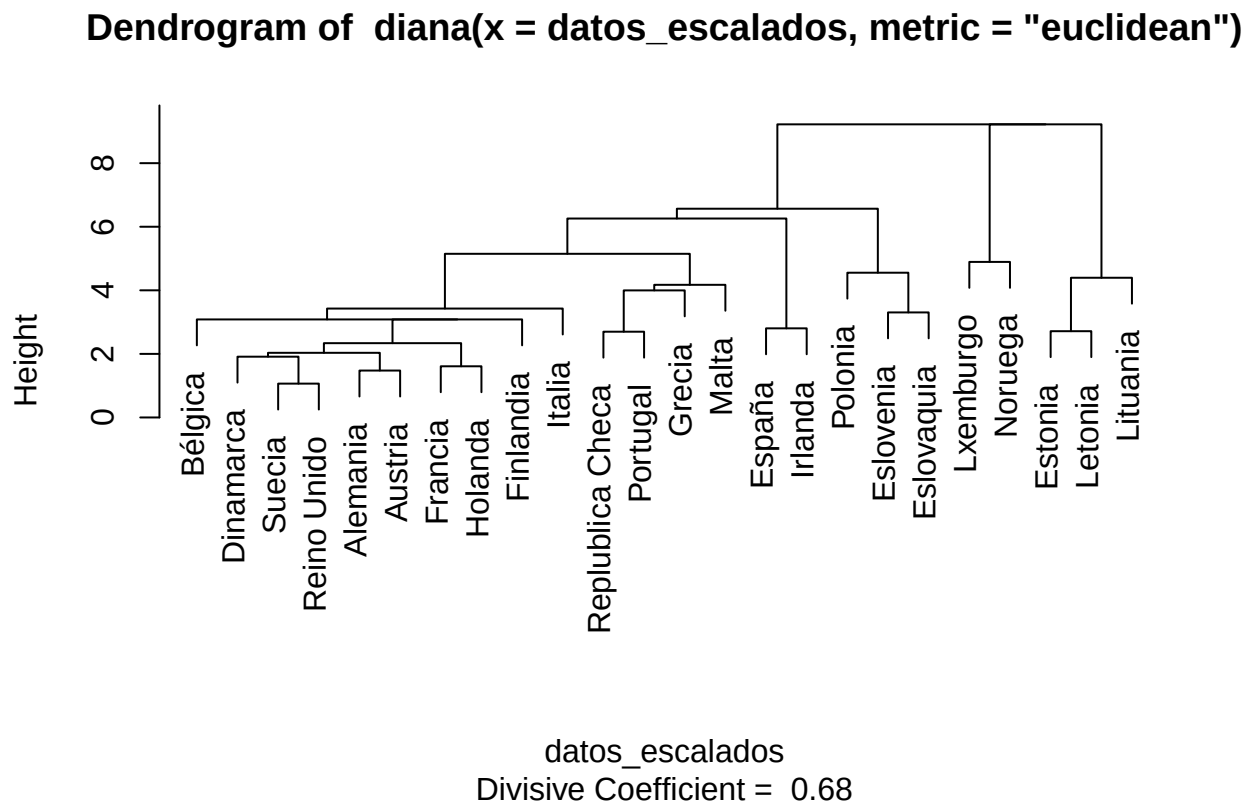


```r
fviz_dend(cluster_top_down, cex = 0.5,
          k = 4, # grupos
          palette = "jco" # Color
          )
```

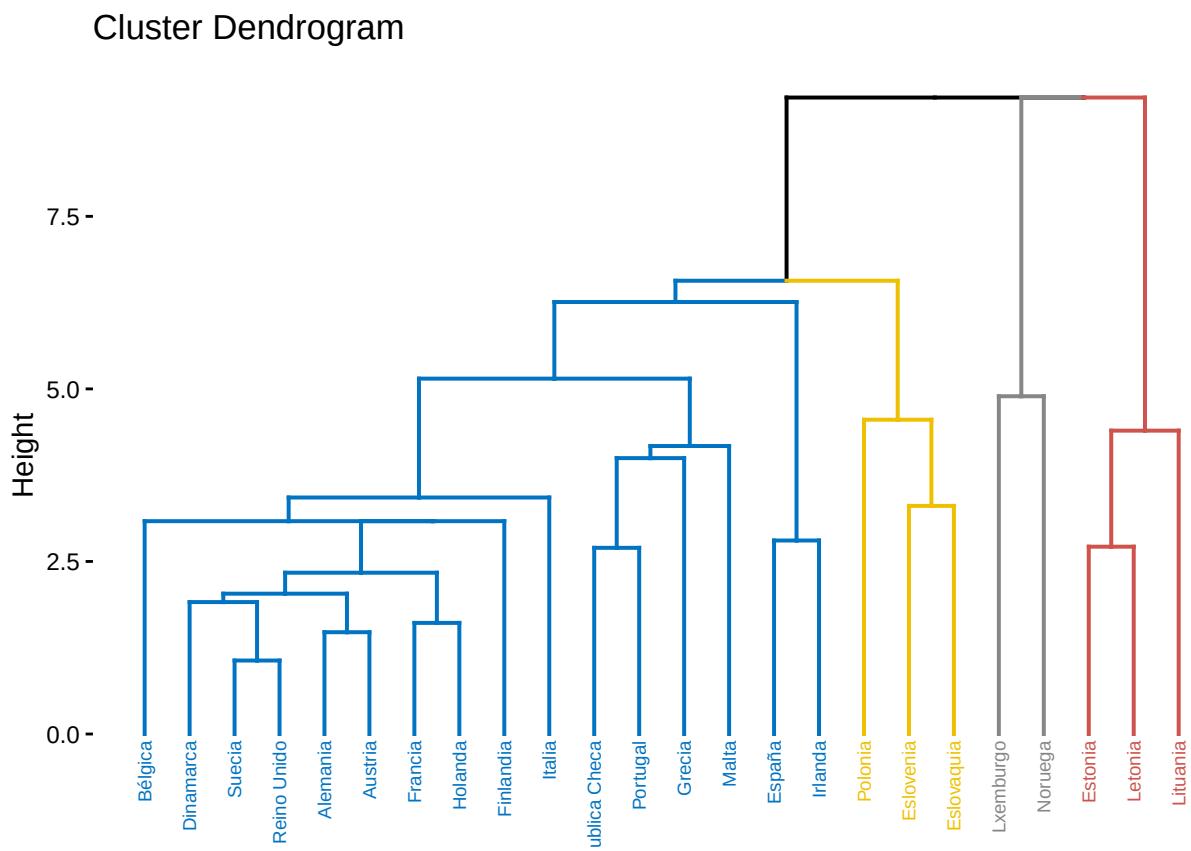


```r
grp <- cutree(clusterS, k = 4)

fviz_cluster(list(data = datos_escalados, cluster = grp))
```

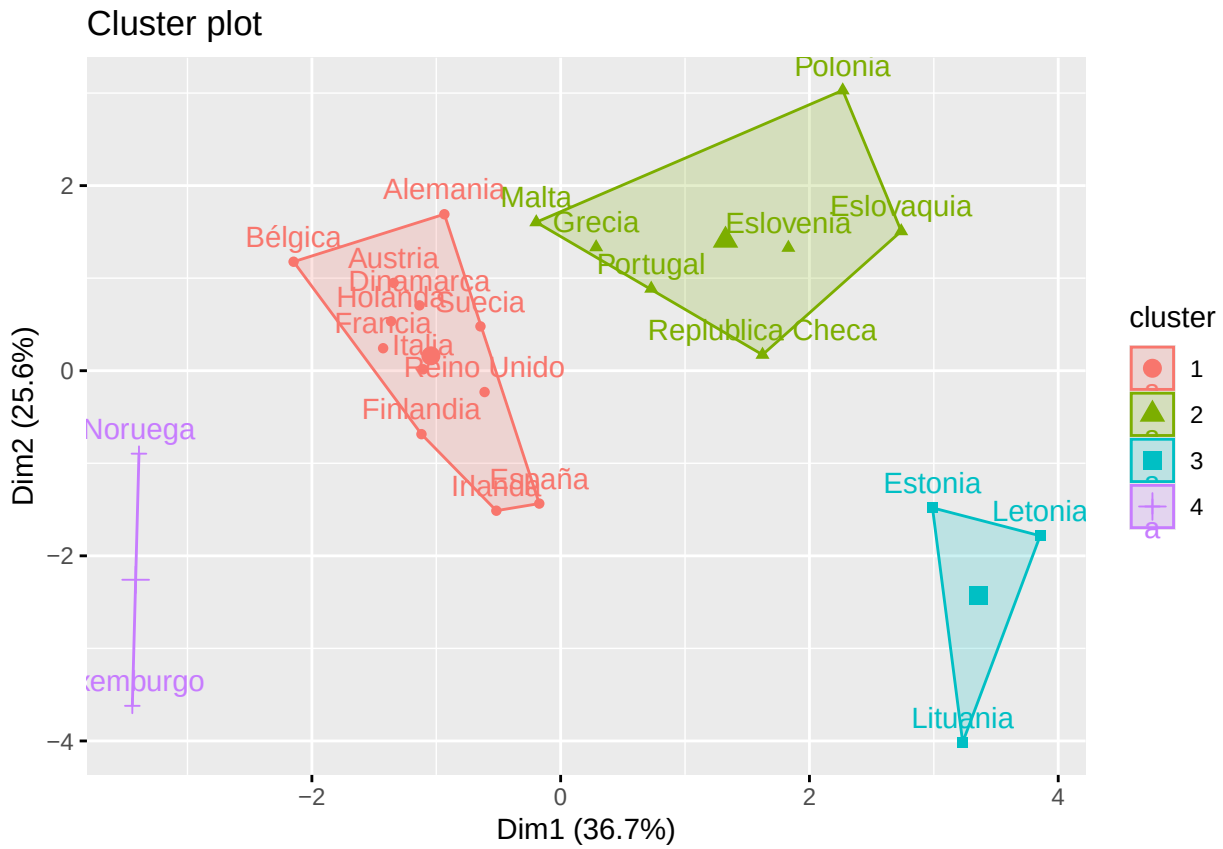

1.3. Comparación entre dos modelos

```
clustercentroid<- hclust(distancias, method = "centroid")
clusterward.D <- hclust(distancias, method = "ward")
plot(clustercentroid)
```

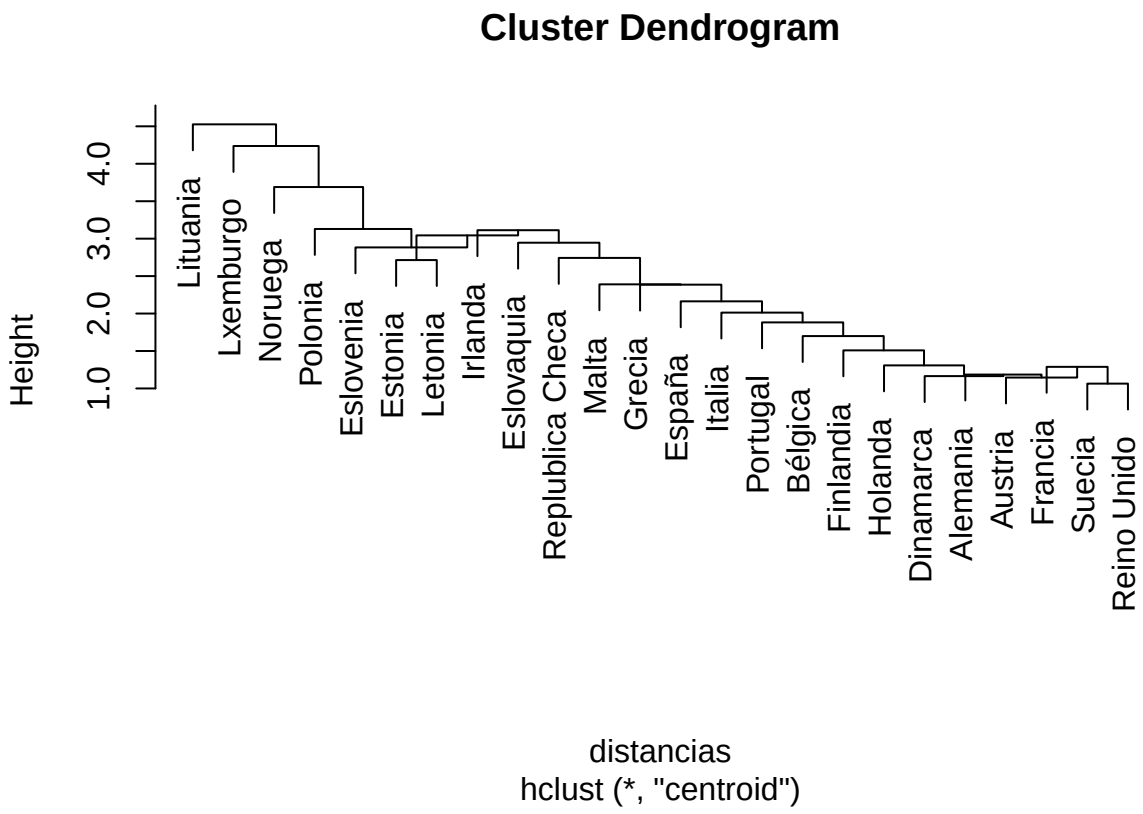


```
plot(clusterward.D)
```

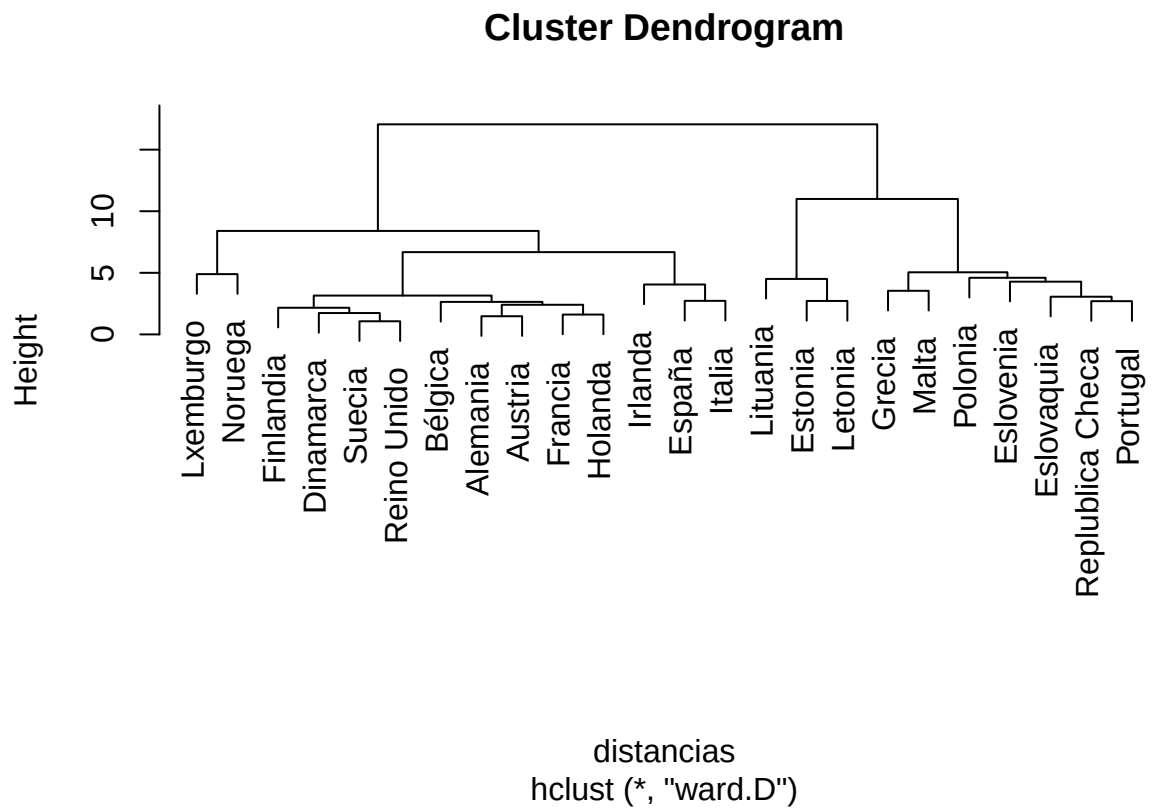


```r
# creamos los 2 dendogramas
dendograma1 <- as.dendrogram (clustercentroid)
dendograma2 <- as.dendrogram (clusterward.D)

#lista con los dos dendogramas
listadendogramas <- dendlist(dendograma1, dendograma2)
dendlist(dendograma1, dendograma2) %>%
  untangle(method = "step1side") %>% #
  tanglegram()
```

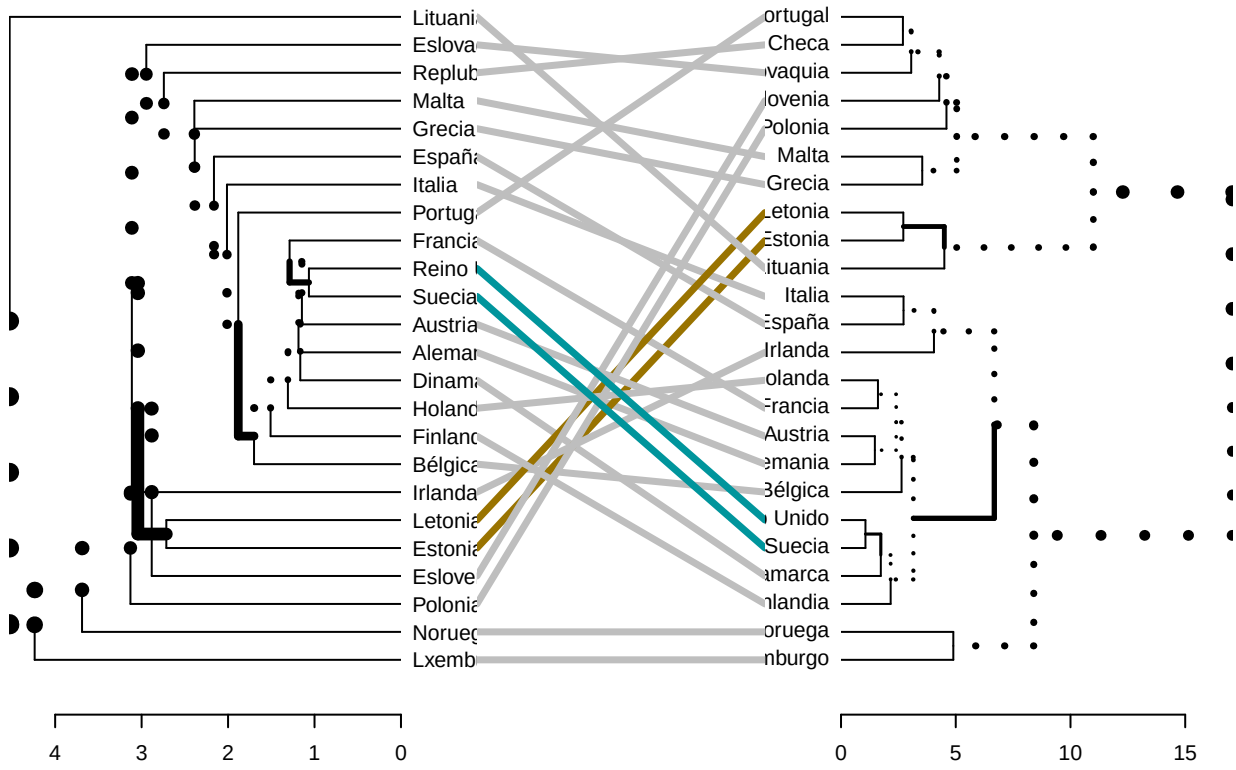


```r
dendlist(dendograma1, dendograma2) %>%
  untangle(method = "step1side") %>%
  entanglement()
```

```
## [1] 0.372581
```

1.4. Número optimo de cluster

Para garantizar que nuestra clasificación no depende del azar o de una sola variable, realizamos una validación de estabilidad utilizando el paquete `clValid`. Este análisis compara simultáneamente cuatro algoritmos (`hierarchical`, `kmeans`, `pam` y `diana`) para un rango de 2 a 6 clusters.

El objetivo es identificar qué método produce grupos más robustos cuando se elimina una variable del análisis de forma sucesiva. Las métricas calculadas (APN, AD, ADM y FOM) nos indicarán la consistencia de los grupos. Una puntuación más baja en estas métricas representa una mayor estabilidad, lo que nos permite elegir con rigor científico el número óptimo de grupos y el mejor algoritmo para estos datos económicos.

```r
comparar <- clValid(datos_escalados, nClust = 2:6,
                    clMethods = c("hierarchical","kmeans","pam", "diana"),
                    method = "ward",
                    validation = "stability")

pander(optimalScores(comparar))
```

	Score	Method	Clusters
APN	0.0535	kmeans	2
AD	2.373	kmeans	6
ADM	0.2582	kmeans	2
FOM	0.7395	hierarchical	6

Interpretación de la Validación de Estabilidad

Los resultados de la validación cruzada mediante clValid aportan información fundamental sobre la robustez de nuestra clasificación: Predominio de K-means: El algoritmo K-means se muestra como el más estable para este conjunto de datos, liderando tres de las cuatro métricas evaluadas (APN, AD y ADM). Esto sugiere que la partición basada en centroides es muy consistente frente a variaciones en las variables económicas.

Número de Clusters: Los índices APN y ADM sugieren que la estructura más sólida y estable se logra con 2 clusters, lo que indica una división macroeconómica primaria muy clara en la muestra de países. Por otro lado, los índices AD y FOM (donde destaca el método jerárquico) favorecen una solución de 6 clusters, lo que permitiría una clasificación más detallada y con menor error de predicción. Conclusión: Dado que los extremos de estabilidad y precisión se sitúan entre 2 y 6 grupos, la elección de un modelo de 4 clusters (utilizado en los análisis anteriores) representa un equilibrio óptimo. Permite capturar la diversidad económica de los 24 países europeos sin perder la estabilidad estadística que exigen los modelos de clasificación.

```r
plot(comparar)
```

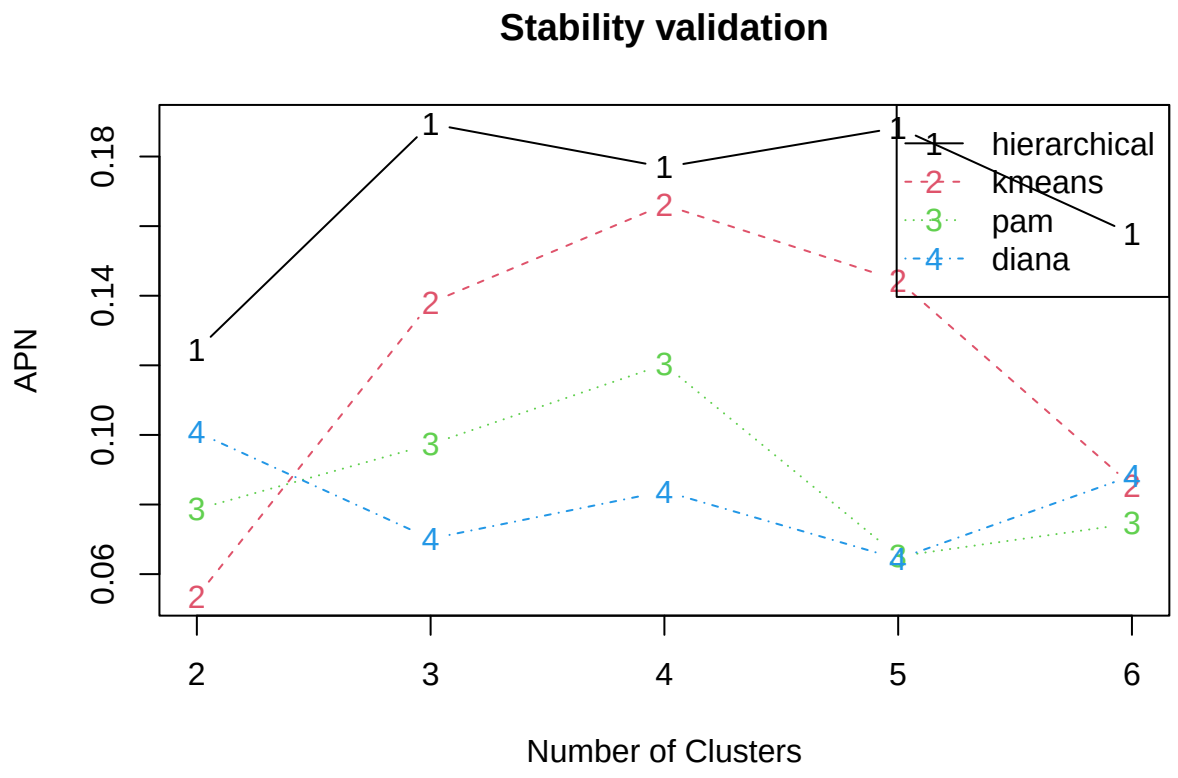

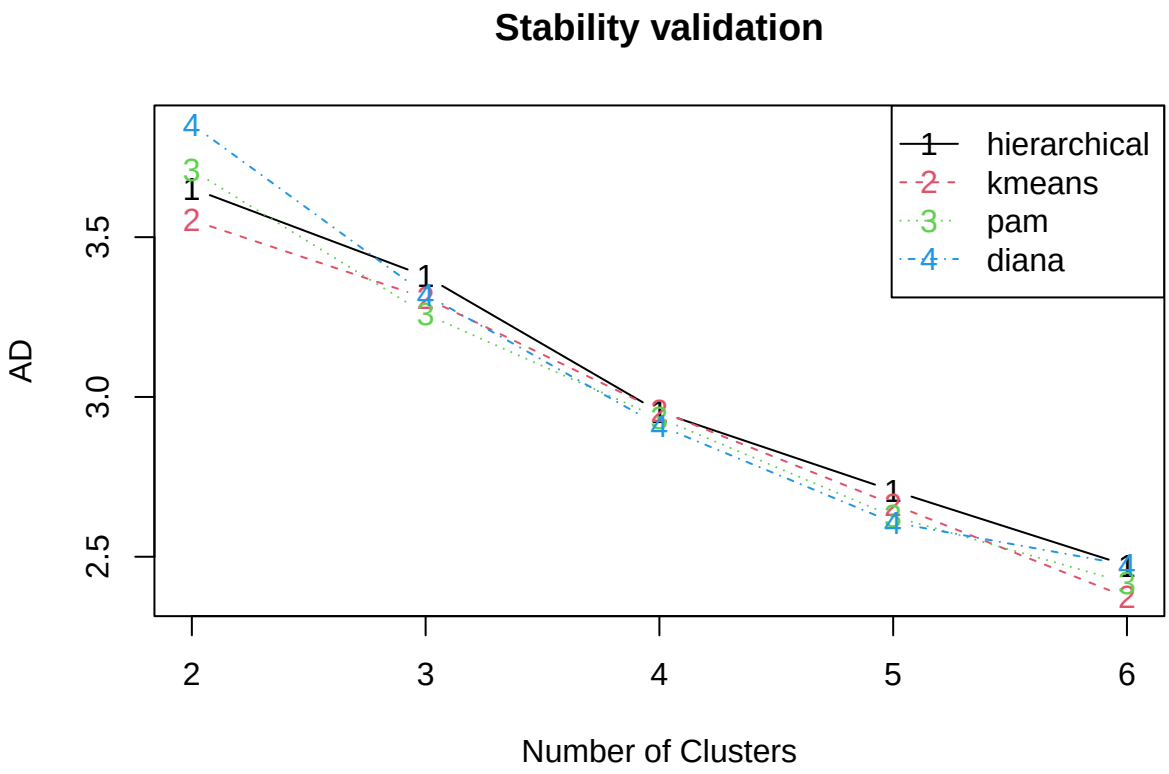
Stability validation
AD
3.5
3.0
2.5
2
3
4
5
6
Number of Clusters
1 hierarchical
2 kmeans
3 pam
4 diana

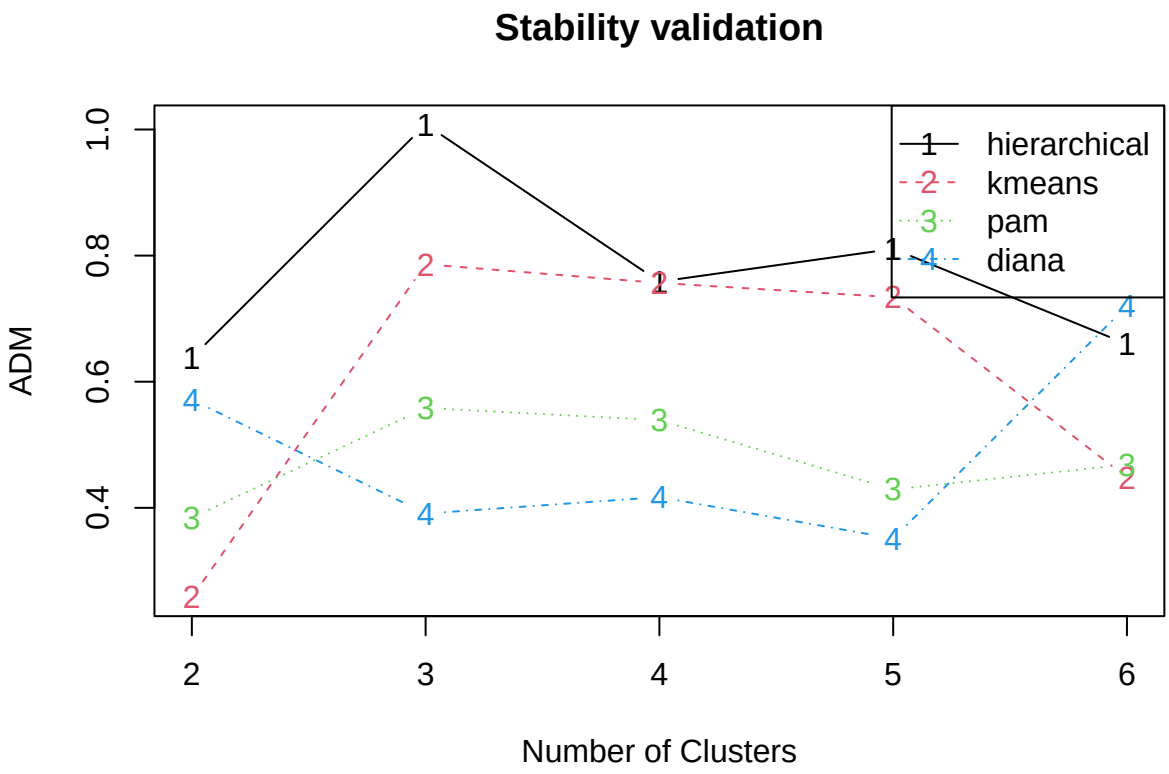
Stability validation
ADM
1.0
0.8
0.6
0.4
2
3
4
5
6
Number of Clusters
hierarchical
kmeans
pam
diana

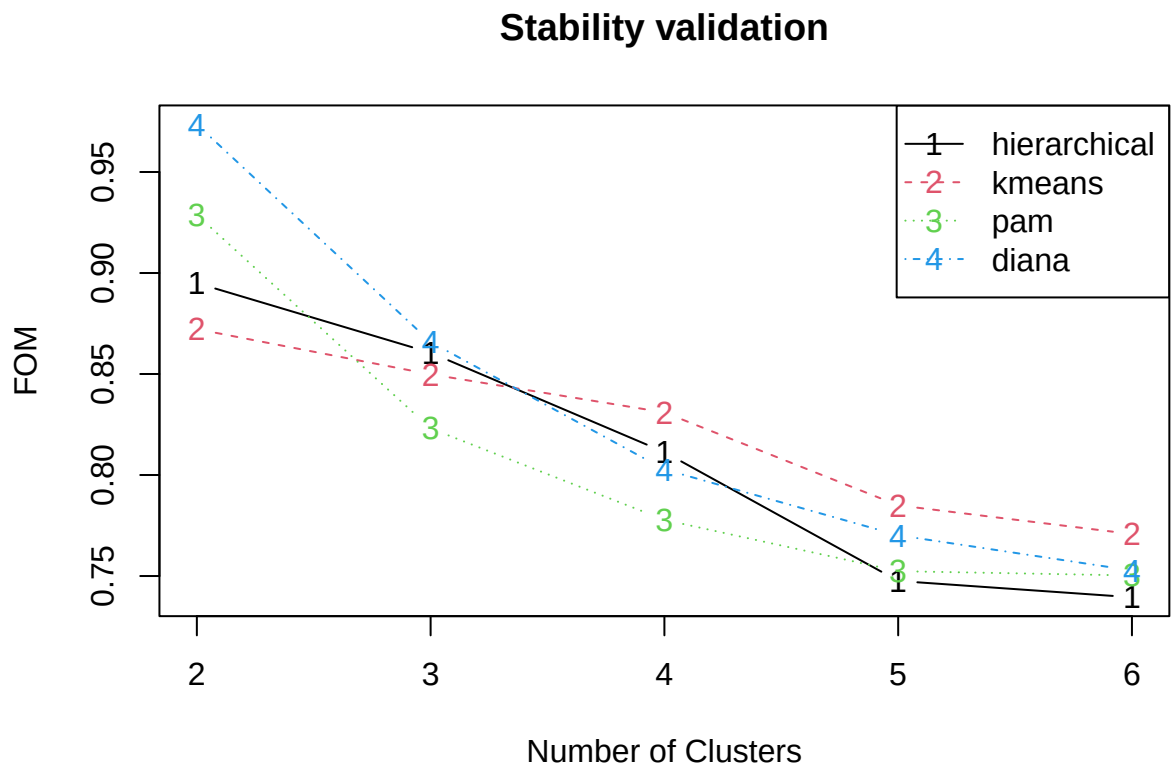

Ejercicio 2: Análisis Clustering de dataset 'cluster2.txt'

2.1. Análisis previos

Antes de hacer un análisis de clúster, debemos verificar los datos recopilados y estandarizarlos para evitar que las variables medidas en diferentes escalas dominen el cálculo de distancias.

```
#Primero procedemos a leer el fichero de datos

datos <-read.table("cluster2.txt",sep="\t",header = T)

pander(head(datos))
```

provincia	alimentacion	vestidoycalzado	vivienda	mobiliario	gastossanitarios	transporte	enseñanzaycultura	turismoyocio
Almeria	618957	295452	522128	167067	58288	280035	129219	307967
Cadiz	683940	203619	426690	124162	60657	285888	127792	313238
Cordoba	590770	265604	487143	113386	37131	237320	116764	247536
Granada	547353	238822	458338	119540	40340	236694	103901	272308
Huelva	649225	245722	570631	99250	61953	253286	123244	238880
Jaen	556210	183295	332662	86364	37160	136992	57607	189811

```r
# Converti la prima colonna (provincia) in fattore
datos$provincia <- as.factor(datos$provincia)

#Converti tutte le altre colonne in numeriche
datos[, -1] <- lapply(datos[, -1], as.numeric)

# Verifica il risultato
str(datos)
```

```
## 'data.frame':    51 obs. of  9 variables:
##  $ provincia        : Factor w/ 51 levels "Alava","Albacete",..: 4 12 17 20 23 25 33 41 24 45 ...
##  $ alimentacion     : num  618957 683940 590770 547353 649225 ...
##  $ vestidoycalzado  : num  295452 203619 265604 238822 245722 ...
##  $ vivienda         : num  522128 426690 487143 458338 570631 ...
##  $ mobiliario       : num  167067 124162 113386 119540 99250 ...
##  $ gastossanitarios : num  58288 60657 37131 40340 61953 ...
##  $ transporte       : num  280035 285888 237320 236694 253286 ...
##  $ enseñanzaycultura: num  129219 127792 116764 103901 123244 ...
##  $ turismoyocio     : num  307967 313238 247536 272308 238880 ...
```

Hemos cambiado la estructura de las variables para evitar complicaciones futuras.

```r
# Verificación de valores faltantes
pander(colSums(is.na(datos)))
```

provincia	alimentacion	vestidoycalzado	vivienda	mobiliario	gastossanitarios	transporte	enseñanzaycultura	turismoyocio
0	0	0	0	0	0	0	0	0

El conjunto de datos no tiene ningún valor que falte.

```r
distancias<-dist(scale(datos[,-1]),method = "euclidean")

# Visualizza solo le prime 10 righe e colonne, arrotondate a 2 decimali
round(as.matrix(distancias)[1:10, 1:10], 2)
```

```
##       1    2    3    4    5    6    7    8    9   10
## 1  0.00 3.20 2.86 3.06 3.19 6.01 3.08 2.72 3.55 4.15
## 2  3.20 0.00 3.01 2.87 2.45 4.71 1.37 1.85 3.10 3.12
## 3  2.86 3.01 0.00 1.17 2.07 3.73 2.72 2.43 1.99 2.44
## 4  3.06 2.87 1.17 0.00 2.52 3.32 2.34 2.17 2.00 1.64
## 5  3.19 2.45 2.07 2.52 0.00 4.37 2.14 2.48 2.80 3.38
## 6  6.01 4.71 3.73 3.32 4.37 0.00 4.46 4.76 4.04 2.35
## 7  3.08 1.37 2.72 2.34 2.14 4.46 0.00 1.54 3.19 2.89
## 8  2.72 1.85 2.43 2.17 2.48 4.76 1.54 0.00 2.69 2.96
## 9  3.55 3.10 1.99 2.00 2.80 4.04 3.19 2.69 0.00 2.47
## 10 4.15 3.12 2.44 1.64 3.38 2.35 2.89 2.96 2.47 0.00
```

La matriz convierte variables complejas en un solo número que resume cuánto se parecen dos sujetos.

Análisis gráfico de la matriz de distancias.

```r
# Visualizzazione grafica della matrice
fviz_dist(distancias,
          gradient = list(low = "#00AFBB", mid = "white", high = "#FC4E07"),
          lab_size = 8) +
  ggtitle("Mapa de las distancias entre provincias")
```

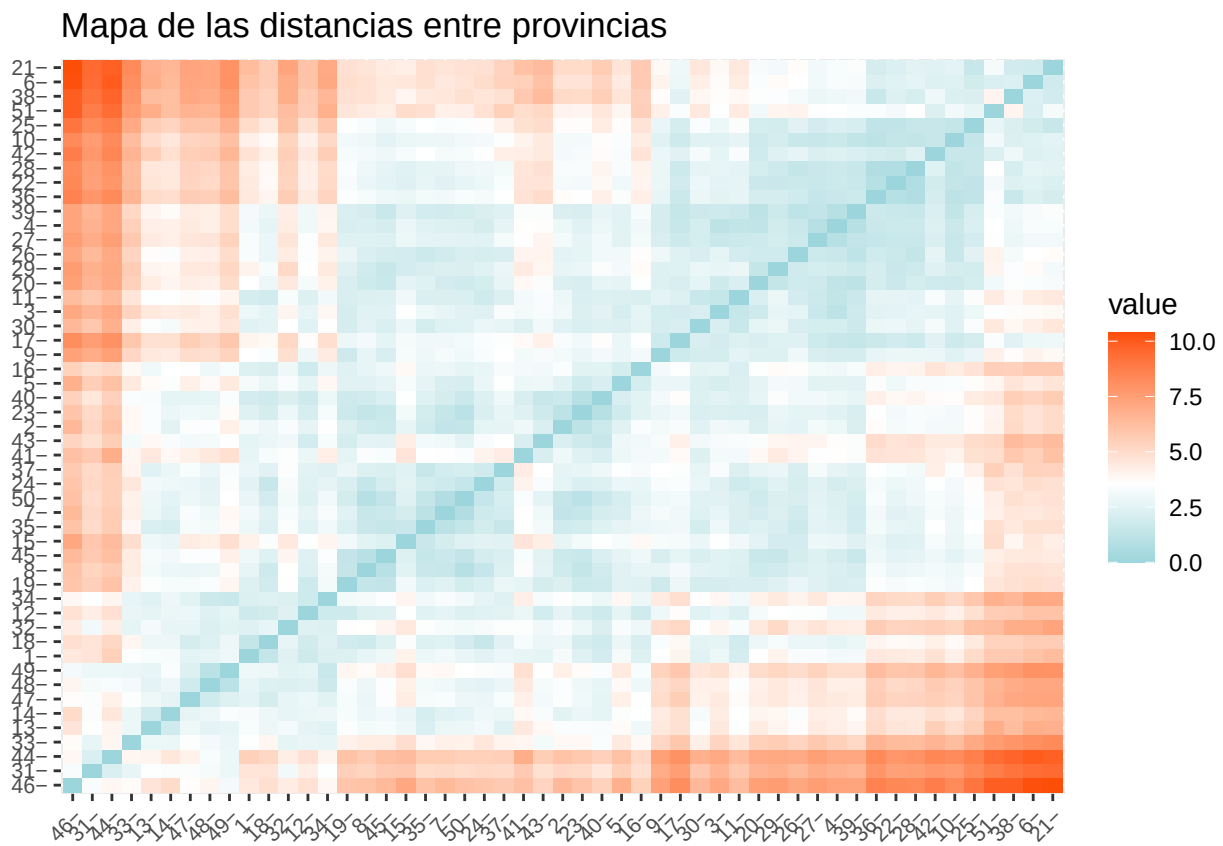

Ahora con la matriz de distancias podemos hacer el Analisis Cluster.

2.2. Método de clustering y validación del modelo seleccionado

Para ello, empezaremos por identificar el mejor método de selección de clústeres.

```r
m <-c("average","single", "complete","ward")
names(m)<-c("average","single", "complete","ward")
ac <-function(x){
  agnes(datos, method= x)$ac
}
lapply(m,ac)
```

```
## $average
## [1] 0.7170983
##
## $single
## [1] 0.5913664
```

```
##
## $complete
## [1] 0.8741794
##
## $ward
## [1] 0.9205254
```

El AC de 0.92 nos asegura que las diferencias en los gastos entre provincias no son aleatorias, sino que siguen patrones lógicos que Ward logra captar casi perfectamente.

Usaremos el método de Ward.

```
clusterS <-hclust(distancias, method="ward.D")
plot(clusterS)
```

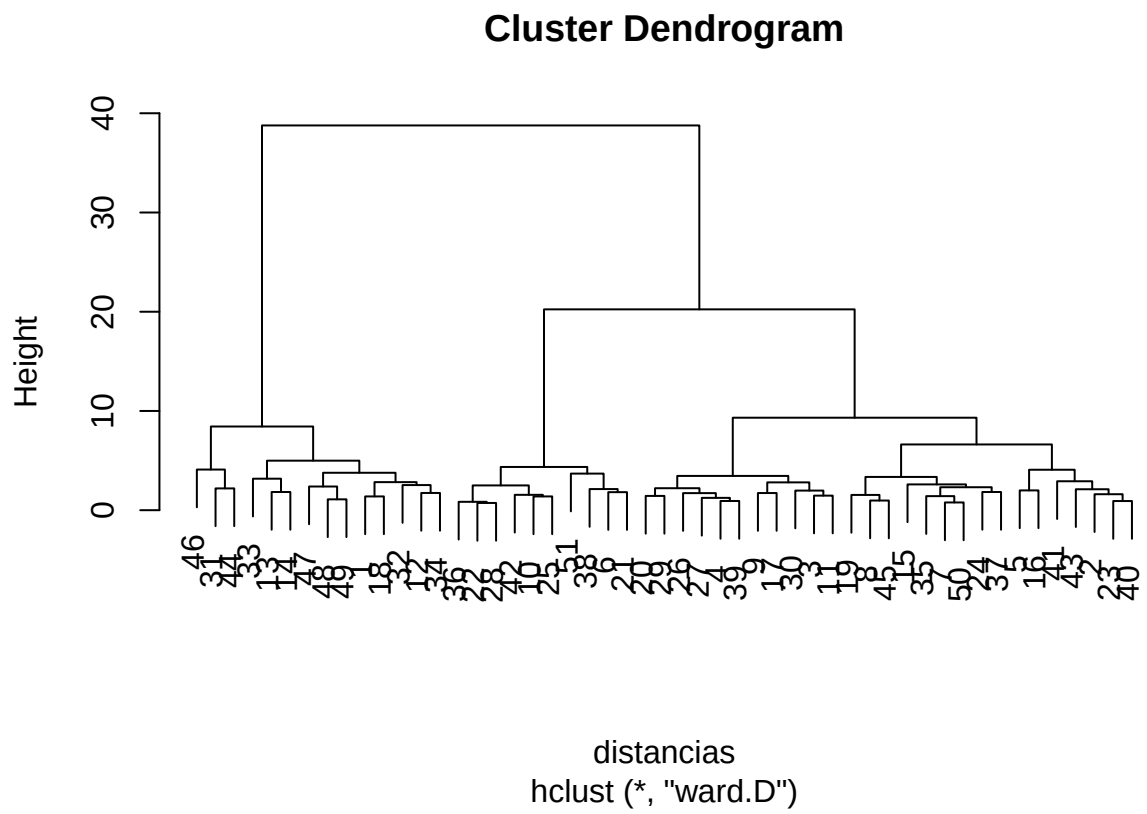

Sin embargo, verificamos si es el método correcto mediante otro procedimiento, la **Correlación Cofenética**.

Vamos a ver qué tipo de "conexión" (ward, soltero, promedio, etc.) deforma menos la realidad matemática original.

```
dend1 <- hclust(distancias, method = "complete")
dend2 <- hclust(distancias, method = "single")
dend3 <- hclust(distancias, method = "average")
dend4 <- hclust(distancias, method = "centroid")
dend5 <- hclust(distancias, method = "ward.D2")
```

```r
coecof<- cophenetic(clusterS)
coecof1<- cophenetic(dend1)
coecof2<- cophenetic(dend2)
coecof3<- cophenetic(dend3)
coecof4<- cophenetic(dend4)
coecof5<- cophenetic(dend5)

# Creiamo un data frame con i risultati (estraendo i valori numerici dalla tua lista)
risultati_cofenetici <- data.frame(
  Metodo = c("Ward.D", "Complete", "Single", "Average", "Centroid", "Ward.D2"),
  Correlazione = c(
    cor(distancias, coecof),
    cor(distancias, coecof1),
    cor(distancias, coecof2),
    cor(distancias, coecof3),
    cor(distancias, coecof4),
    cor(distancias, coecof5)
  )
)

# Ordiniamo il data frame in base alla correlazione (decrescente)
risultati_ordinati <- risultati_cofenetici[order(-risultati_cofenetici$Correlazione), ]

# Rappresentazione grafica della tabella con pander
panderOptions('table.split.table', Inf) # Impedisce alla tabella di spezzarsi
pander(risultati_ordinati, caption = "Comparación de la correlación cofenética por método de enlace")
```

Table 16: Comparación de la correlación cofenética por método de enlace

	Metodo	Correlazione
5	Centroid	0.7131
4	Average	0.6978
3	Single	0.6726
2	Complete	0.6535
1	Ward.D	0.6019
6	Ward.D2	0.5957

En este tipo de comparación, Ward ya no es el método más representativo.

```r
plot(dend4)
```

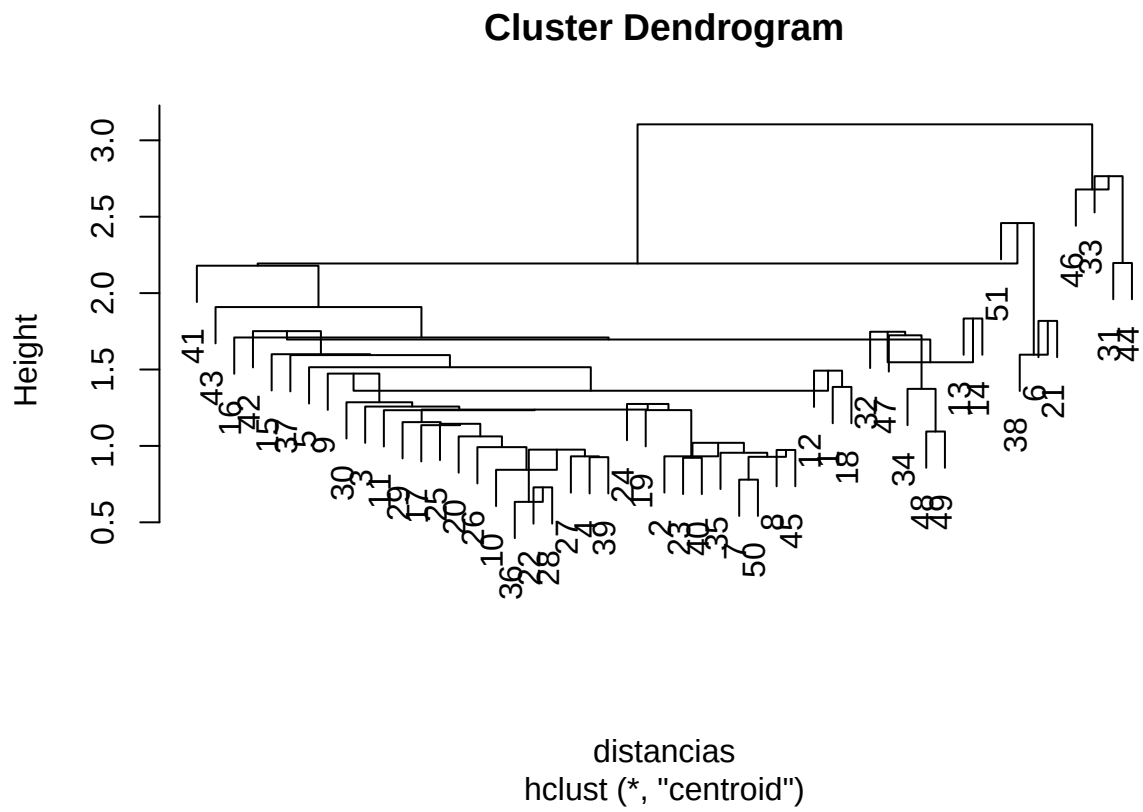

El mejor resultado en este caso es 'Centroid', esto porque Ward no intenta preservar las distancias originales, sino minimizar la varianza interna a los grupos.

Ahora vamos a hacer una correlación adicional, **Inter-Dendrogram Correlation**, comparando los 6 árboles entre sí, midiendo cuán similar es la topología de los árboles.

```
d <- as.dendrogram(hclust(distancias, method = "ward.D2") )
d1 <- as.dendrogram(hclust(distancias,method = "complete") )
d2 <- as.dendrogram(hclust(distancias,method = "single") )
d3 <- as.dendrogram(hclust(distancias,method = "average") )
d4 <- as.dendrogram(hclust(distancias,method = "centroid"))
d5 <- as.dendrogram(hclust(distancias,method = "ward.D"))
dend_list <- dendlist("ward.d"=d, "Complete" = d1, "Single" = d2,
                      "Average" = d3, "Centroid" = d4, "ward.D"=d5)
corelaciones <- cor.dendlist(dend_list)
pander(round(corelaciones, 2))
```

	ward.d	Complete	Single	Average	Centroid	ward.D
ward.d	1	0.78	0.41	0.67	0.32	0.93
Complete	0.78	1	0.55	0.88	0.46	0.7
Single	0.41	0.55	1	0.65	0.88	0.4
Average	0.67	0.88	0.65	1	0.63	0.67
Centroid	0.32	0.46	0.88	0.63	1	0.33
ward.D	0.93	0.7	0.4	0.67	0.33	1

Los métodos Ward, Complete y Average coinciden ampliamente en la clasificación de las provincias mientras que métodos como Single y Centroid se diferencian marcadamente siguiendo una lógica de agrupación alternativa.

```
# Miglioramento del grafico delle correlazioni tra dendrogrammi
corrplot(corelaciones,
         method = "color",
         type = "lower",
         addCoef.col = "black",
         tl.col = "black",
         tl.srt = 45,
         diag = FALSE,
         col = COL2("RdBu", 10),
         title = "\n Similitud de los métodos de agrupación",
         mar = c(0,0,1,0))
```

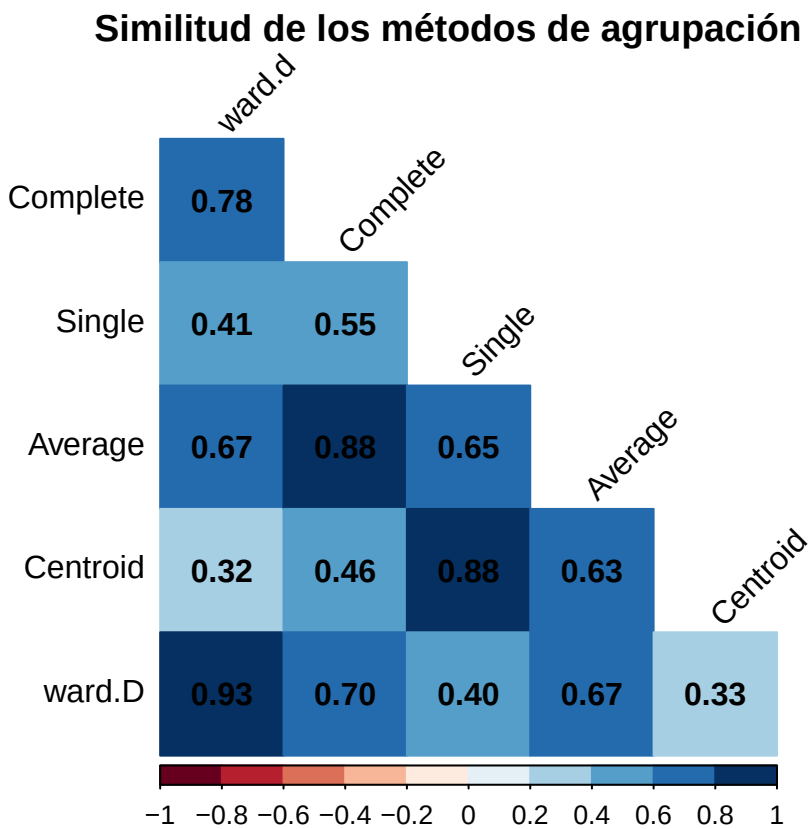

2.3. Comparación entre dos modelos

Comparamos los dos modelos propuestos para ver si tienen alguna divergencia estructural.

```
set.seed(136) # Seme aggiornato al tuo anno attuale

# Estrazione del campione
indici_campione <- sample(1:nrow(datos), 31)
muestra_datos <- datos[indici_campione, -1] # Prendiamo le righe e togliamo la colonna 1
```

```r
distancias2 <- dist(scale(muestra_datos), method = "euclidean")


clustermuestra1 <- hclust(distancias2, method = "centroid")
clustermuestra2 <- hclust(distancias2, method = "ward.D2")

#  Conversione in dendrogrammi
dend_centroid <- as.dendrogram(clustermuestra1)
dend_ward     <- as.dendrogram(clustermuestra2)


# Creazione della lista e ottimizzazione

dl_optimized <- dendlist(dend_centroid, dend_ward) %>%
  untangle(method = "step1side")


#  Miglioramento Grafico del Tanglegram (Versione Ordinata)
dl_optimized %>%
  tanglegram(
    main_left = "Metodo Centroide",
    main_right = "Metodo Ward",
    col_lines = c("#1B9E77", "#D95F02", "#7570B3"), # Palette ColorBrewer pulita

    highlight_distinct_edges = FALSE,
    common_subtrees_color_branches = TRUE, # Mantieni i rami comuni colorati
    lab.cex = 0.65,                     # Leggermente più piccolo per non sovrapporsi
    lwd = 1.6,                          # Linee un po' più spesse per visibilità
    margin_inner = 6,                   # Più spazio centrale per nomi lunghi
    edge.lwd = 0.8                      # Rende i rami degli alberi più sottili
  )
```

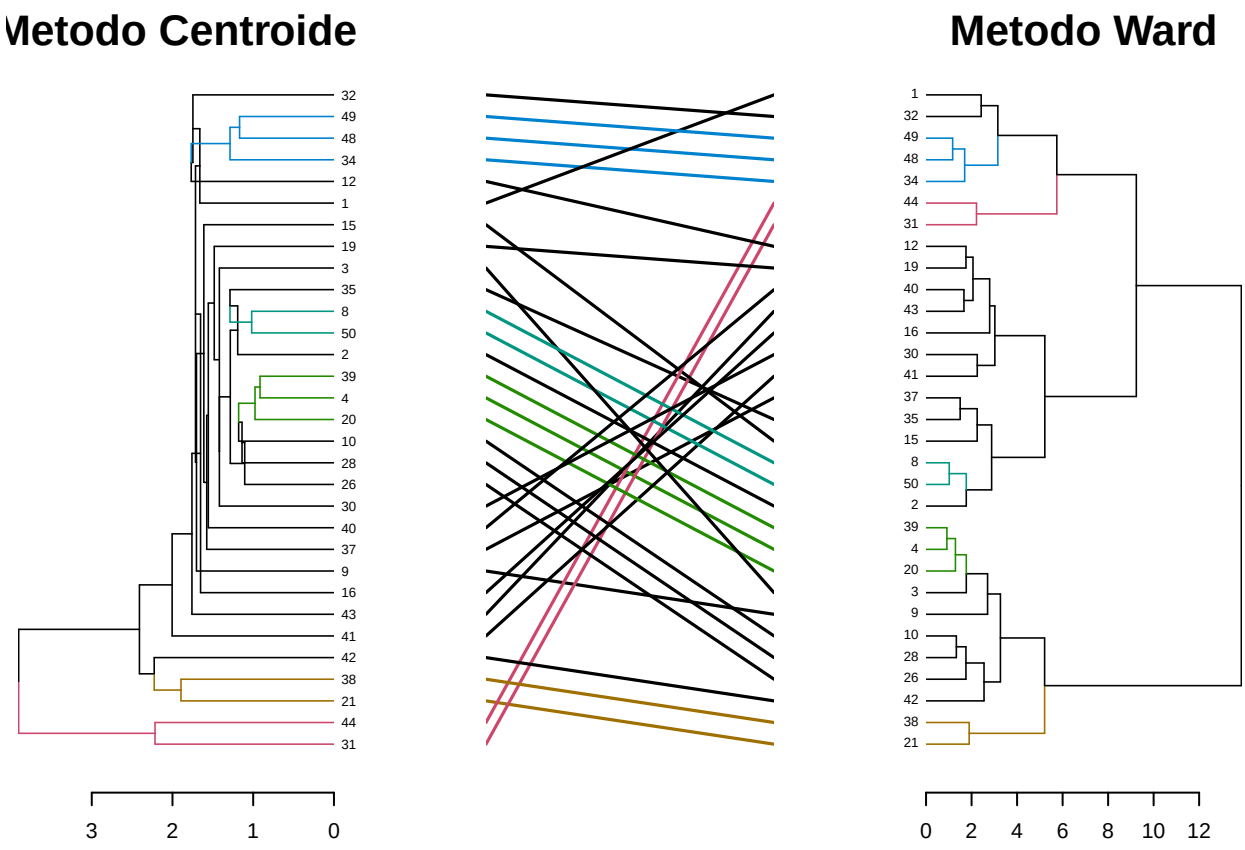


```
# Cálculo de Entanglement (en un objeto ya optimizado)
entang_val <- dl_optimized %>% entanglement()

# Imprimimos el resultado de manera limpia
cat("El nivel de Entanglement es:", round(entang_val, 3))
```

```
## El nivel de Entanglement es: 0.362
```

```
Aproximadamente el 64% de la estructura jerárquica es idéntica en los dos modelos
```

Este valor indica una consistencia estructural moderada: aunque los dos algoritmos identifican los macrogrupos principales de manera similar, están observando los datos de diferentes maneras.

La conclusión a la que podemos llegar es que los clústeres principales, independientemente del algoritmo (o método) utilizado, nos dan un resultado similar.

2.4. Selección del número de clústeres

Buscaremos el número óptimo de clústeres comparando varios métodos.

```
datos_final <- datos
rownames(datos_final) <- datos_final[, 1]
datos_numeric <- datos_final[, -1] # Teniamo solo i dati numerici
```

```r
# Standardizzazione
datos_scaled <- scale(datos_numeric)

comparar <- clValid(datos_scaled,
                    nClust = 2:6,
                    clMethods = c("hierarchical", "kmeans", "pam", "diana"),
                    method = "average",
                    validation = "stability")

pander(optimalScores(comparar))
```

	Score	Method	Clusters
APN	0.04715	kmeans	2
AD	2.197	pam	6
ADM	0.2324	kmeans	2
FOM	0.6597	kmeans	6

El análisis indica que la estructura de las provincias es extremadamente sólida si se divide en 2 clústeres (máxima estabilidad según APN y ADM), mientras que una subdivisión en 6 clústeres permite describir mejor los detalles específicos aunque resulte estadísticamente más frágil.

Gráfico del resultado obtenido

```r
plot(comparar)
```

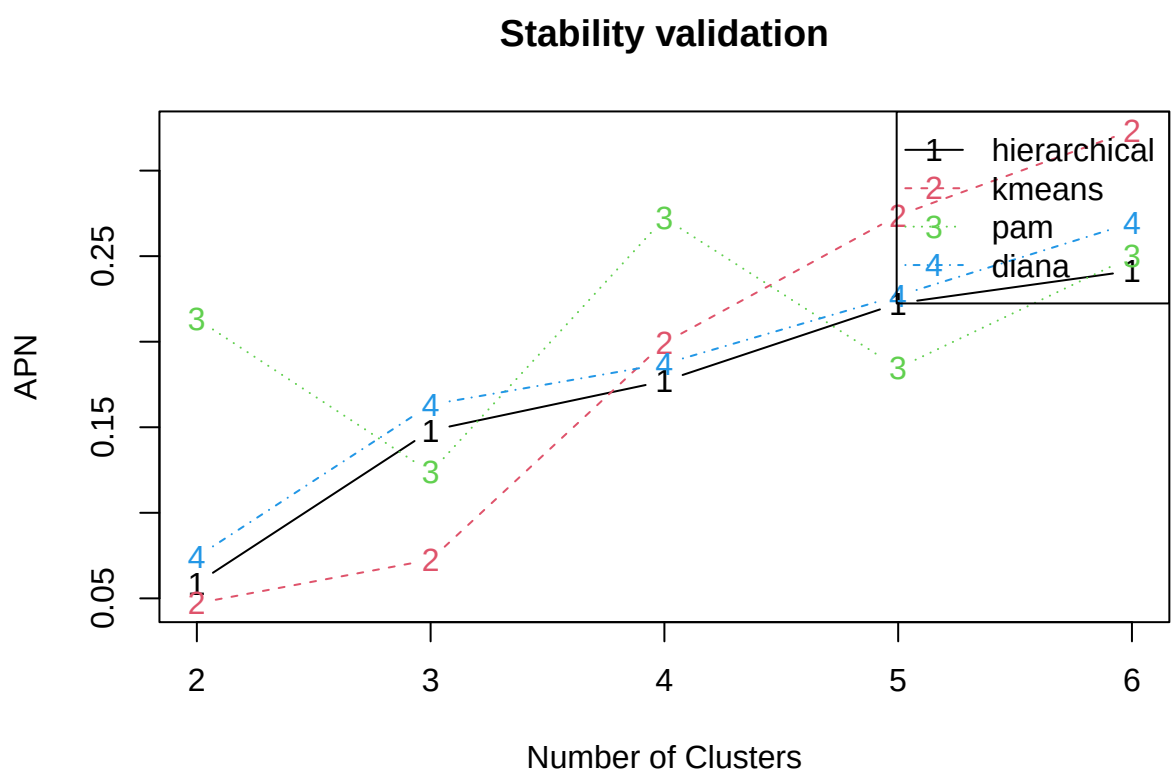

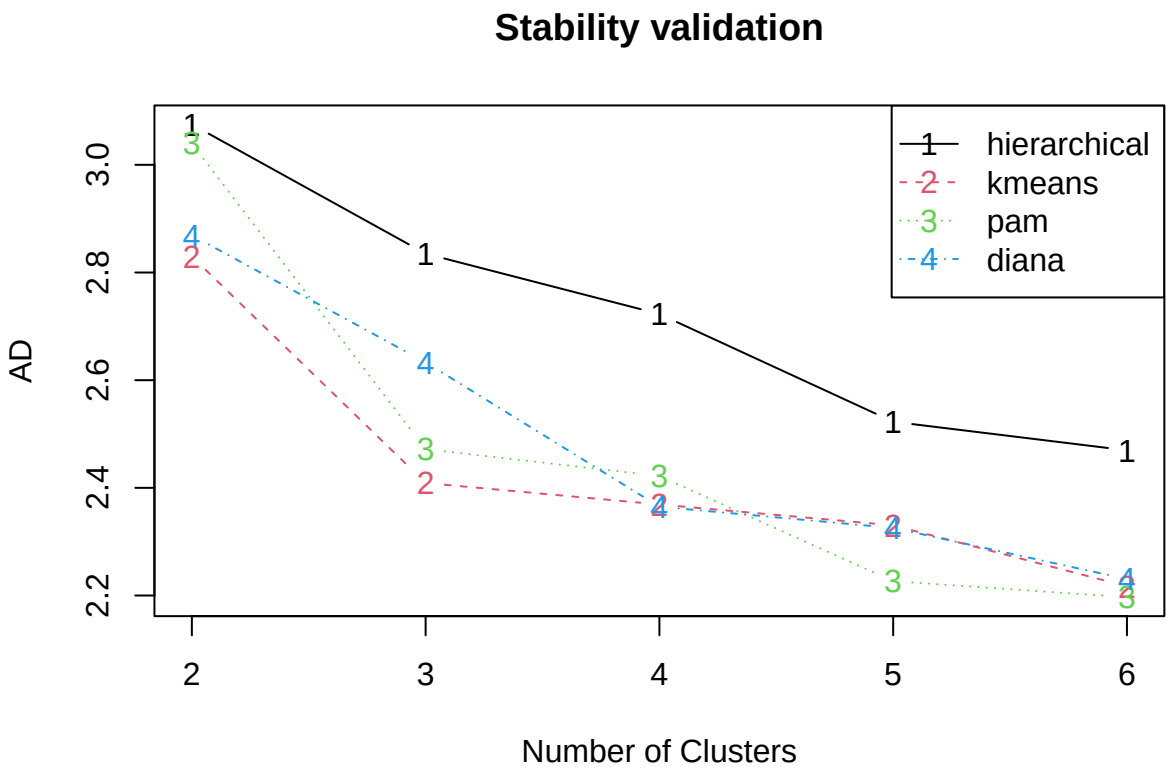
Stability validation
AD
Number of Clusters
hierarchical
kmeans
pam
diana
2.2
2.4
2.6
2.8
3.0
2
3
4
5
6

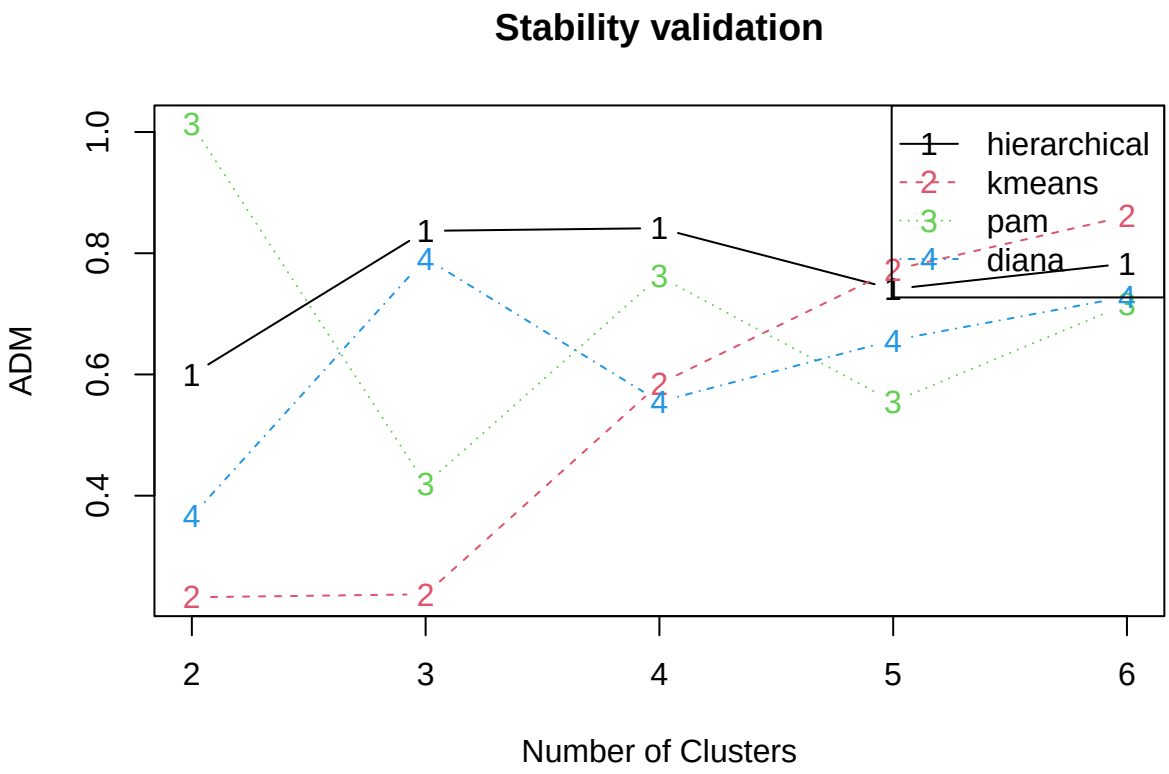
Stability validation
ADM
1.0
0.8
0.6
0.4
2
3
4
5
6
Number of Clusters
hierarchical
kmeans
pam
diana

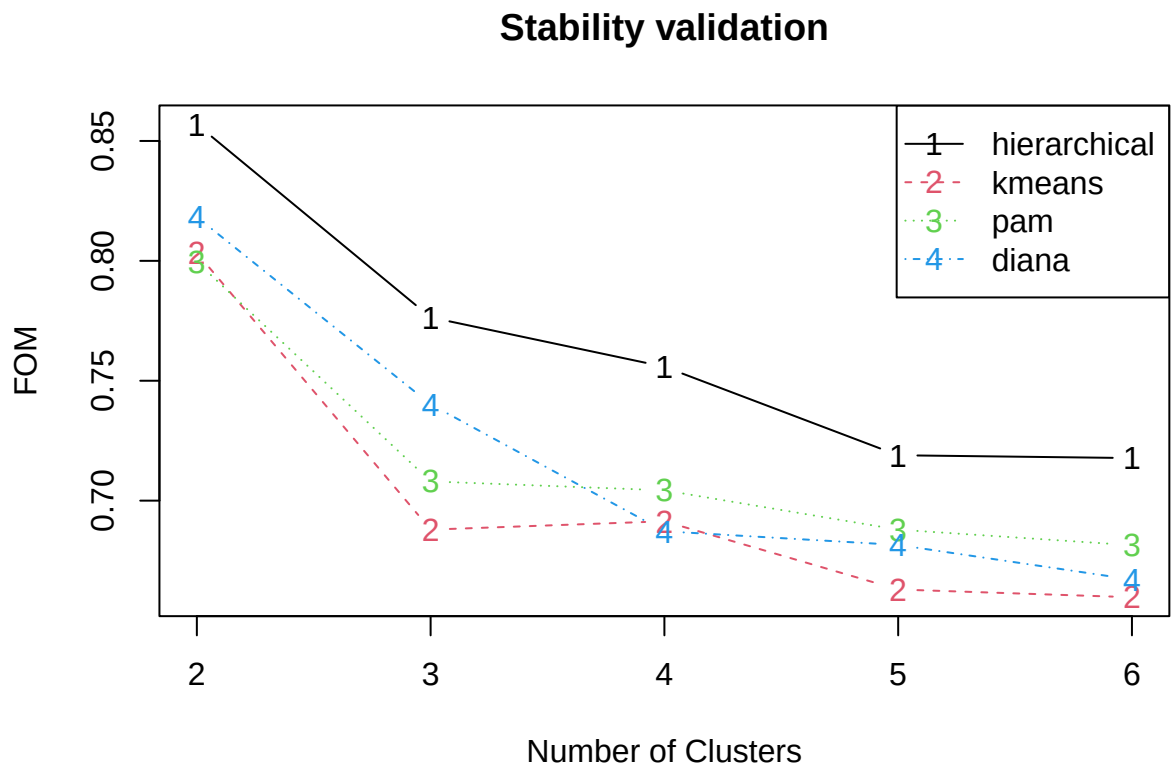

Todavía utilizamos otro método para elegir el número óptimo de clústeres, '**Criterio del Gap**'.

```
# Metodo dell'Elbow (Gomito)
p1 <- fviz_nbclust(datos_scaled,
                   FUNcluster = kmeans,
                   method = "wss",
                   k.max = 7) +
      ggtitle("Metodo Elbow (WSS)")

# Metodo della Silhouette
p2 <- fviz_nbclust(datos_scaled,
                   FUNcluster = hcut,
                   method = "silhouette",
                   k.max = 7) +
      ggtitle("Metodo Silhouette")

# Metodo del Gap Statistic
p3 <- fviz_nbclust(datos_scaled,
                   FUNcluster = hcut,
                   method = "gap_stat",
                   k.max = 7,
                   ) +
      ggtitle("Metodo Gap Statistic")

# Visualizzazione dei grafici
```

```r
print(p1)
```

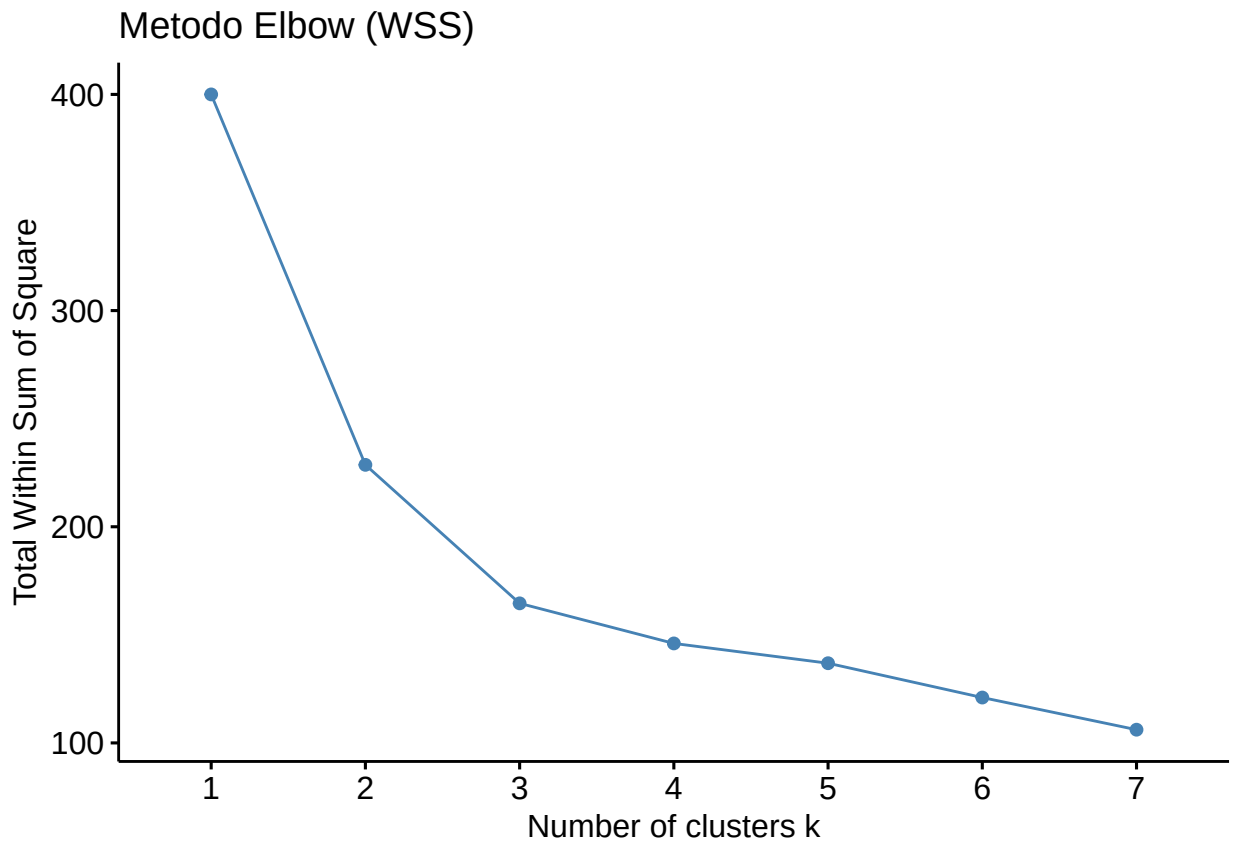


```r
print(p2)
```

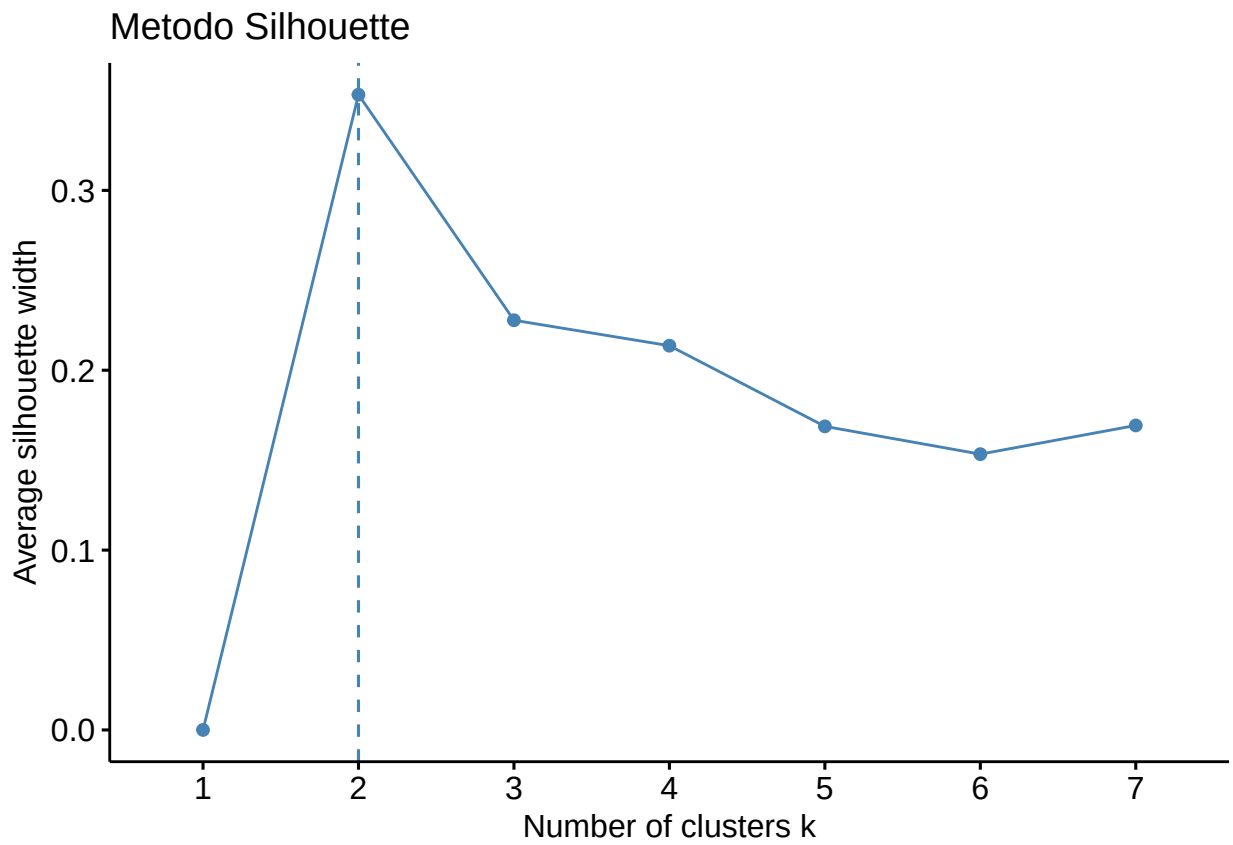
Metodo Silhouette
Average silhouette width
0.0
0.1
0.2
0.3
1
2
3
4
5
6
7
Number of clusters k

```
print(p3)
```

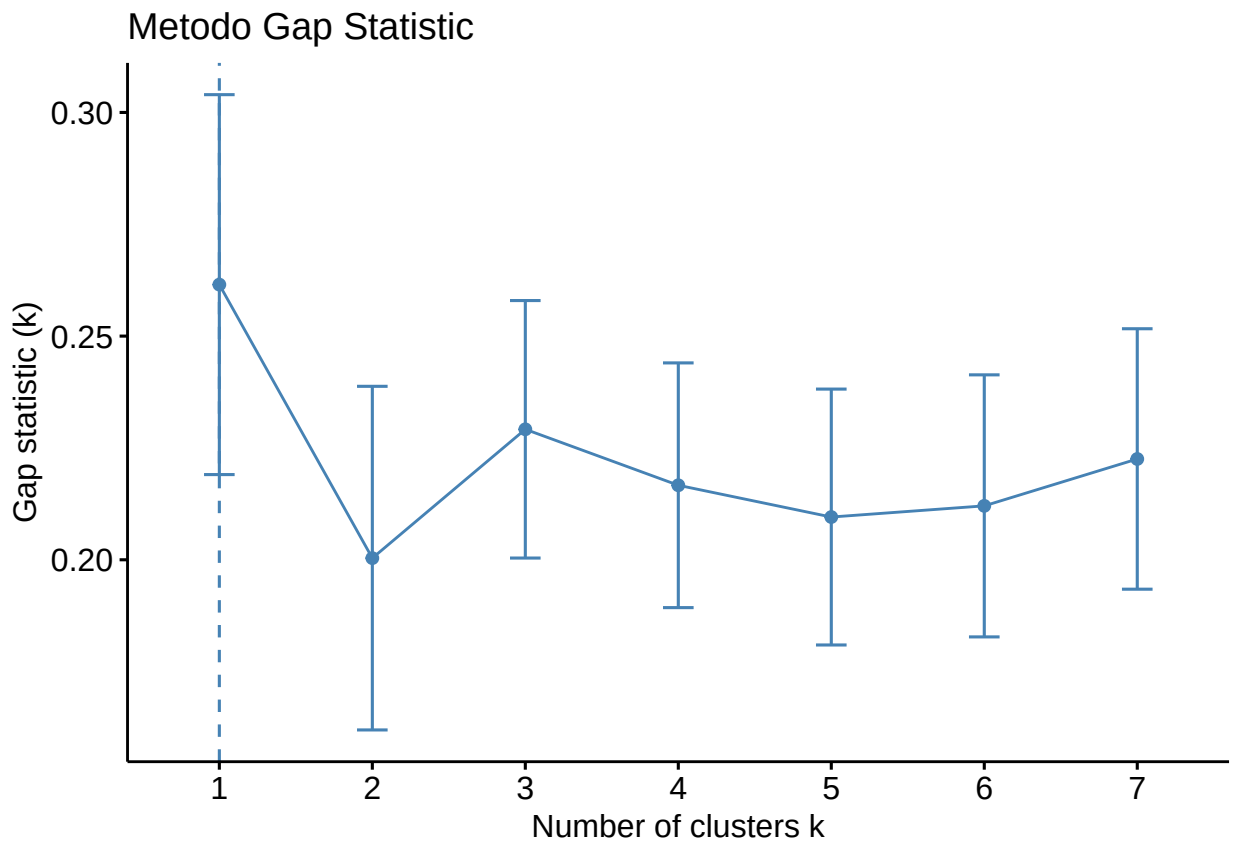

Todas las mediciones sugieren 2 clústeres como el primer método utilizado.

Visualizamos cómo sería el clustering con k=2

```
grp<-cutree(clusterS,k= 2)

# Prendi tutte le 51 province, ordinale e mostrane 5

completo <- data.frame(Provincia = datos[, 1], Cluster = grp)


pander(head(completo[completo$Cluster == 1, ], 5))
```

	Provincia	Cluster
1	Almeria	1
12	Asturias	1
13	Baleares	1
14	Las-Palmas	1
18	Burgos	1

```
pander(head(completo[completo$Cluster == 2, ], 5))
```

	Provincia	Cluster
2	Cadiz	2
3	Cordoba	2
4	Granada	2
5	Huelva	2
6	Jaen	2

```r
# Creiamo un piccolo data frame per una resa estetica migliore
riepilogo <- data.frame(
  Cluster = c("1", "2"),
  `N Provincias` = as.numeric(table(grp))
)

pander(riepilogo, justify = "left")
```

Cluster	N.Provincias
1	14
2	37

Podemos observar que las provincias en el clúster 2 son más del doble que en el clúster 1.

Análisis gráfico

```r
# Fondamentale: assegniamo i nomi delle province all'oggetto cluster
clusterS$labels <- datos[, 1]

fviz_dend(clusterS, k = 2,
          cex = 0.6,
          type = "rectangle",
          k_colors = c("#E41A1C", "#377EB8"),
          rect = TRUE,
          rect_border = "cluster",
          rect_fill = TRUE,
          ggtheme = theme_minimal(),
          main = "Dendrograma rectangular")
```

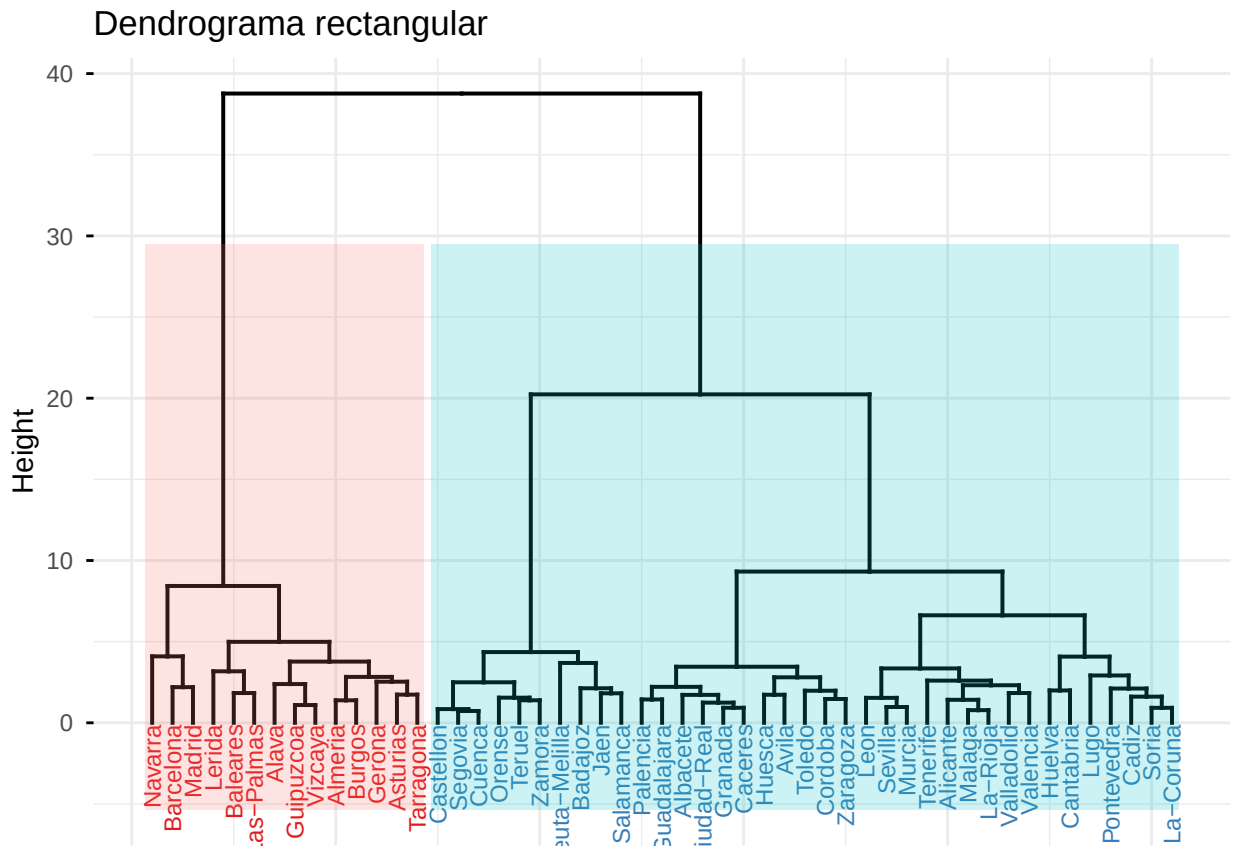


```
fviz_dend(clusterS, k = 2,
          cex = 0.7,
          type = "circular",
          k_colors = c("#E41A1C", "#377EB8"),
          ggtheme = theme_gray(),
          main = "Dendrograma Circular")
```

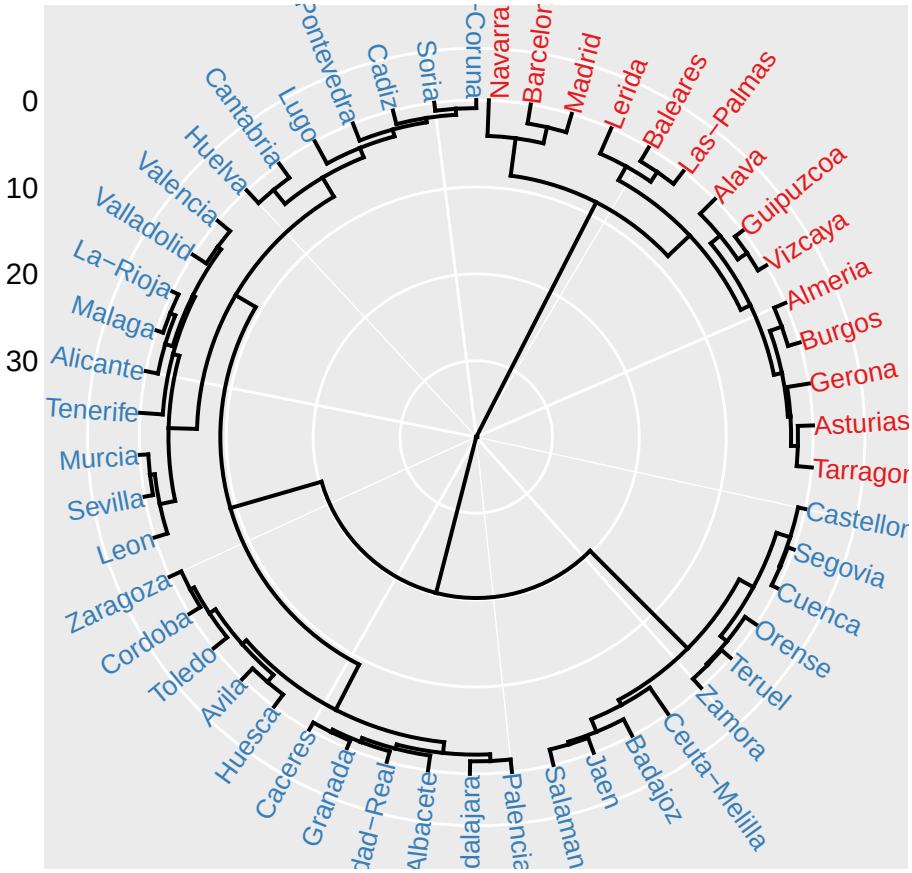


```
fviz_dend(clusterS, k = 2,
          cex = 0.8,
          type = "phylogenic",
          ggtheme = theme_gray(),
          k_colors = c("#E41A1C", "#377EB8"),
          main = "Dendrograma filogenético")
```

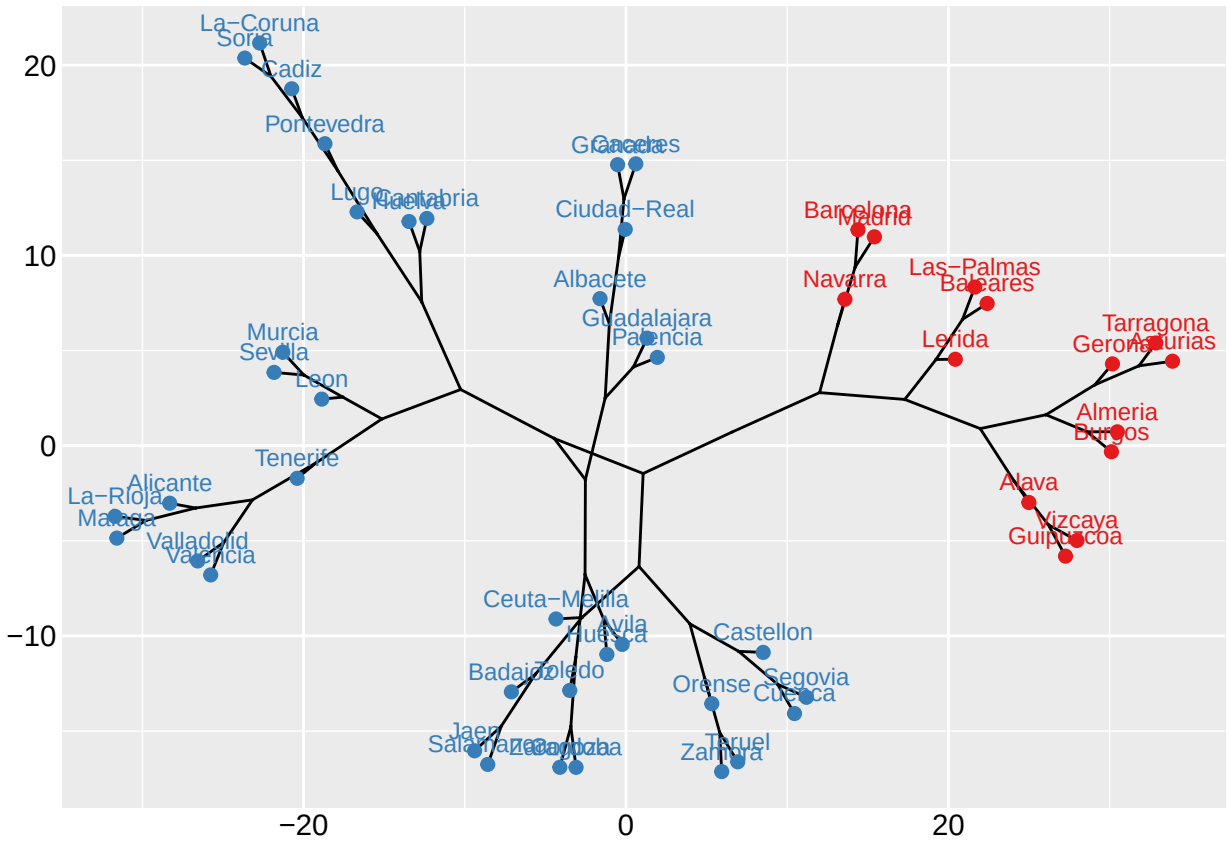


```r
# Generiamo il grafico dei cluster
  rownames(datos_numeric) <- datos[, 1]


fviz_cluster(list(data = datos_numeric , cluster = grp),
             geom = c("point", "text"), # Mostra sia il punto che il nome
             repel = TRUE,              # FONDAMENTALE: evita che i nomi si sovrappongano
             ellipse.type = "convex",   # Crea un perimetro attorno ai gruppi
             palette = "Set1",          # Colori Rosso/Blu coerenti con il dendrogramma
             ggtheme = theme_minimal(),
             main = "Mapa de las provincias españolas")
```

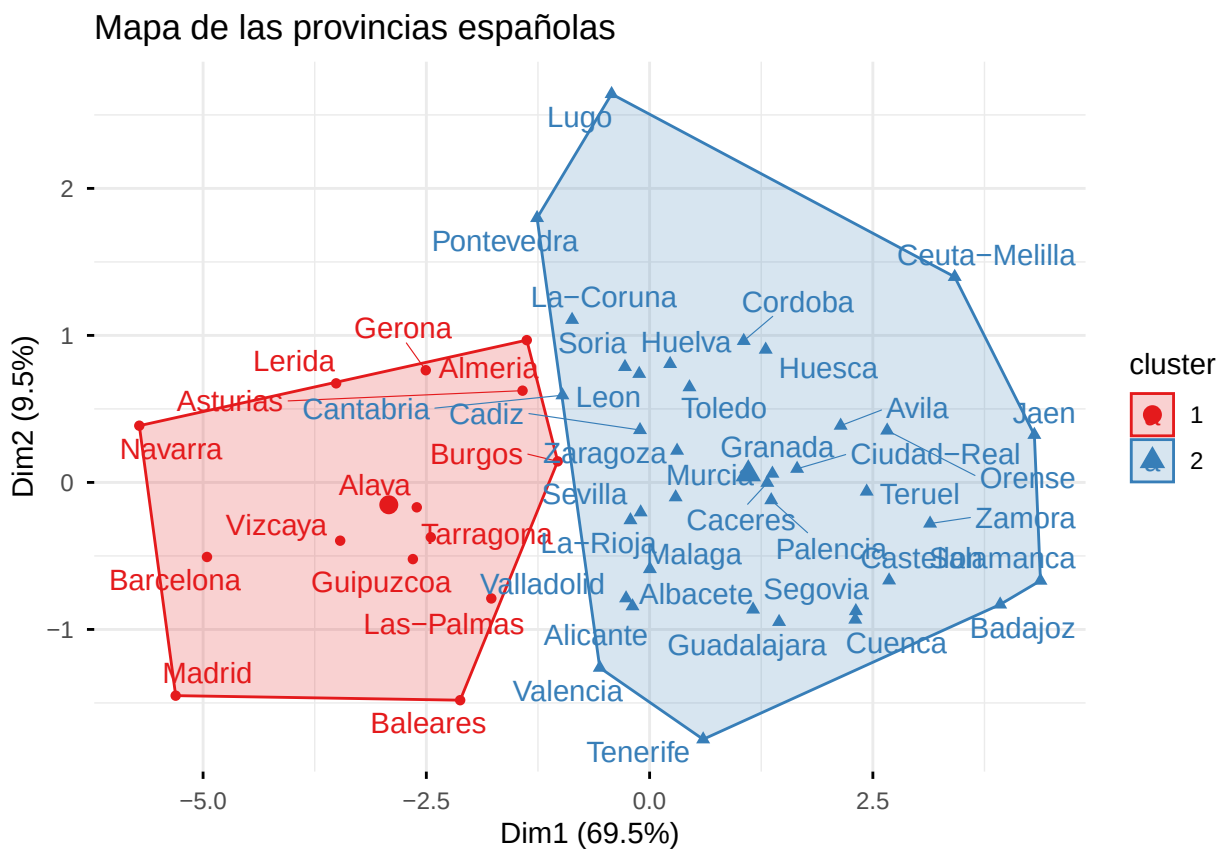

Podemos concluir que el Cluster 1 representa las provincias que representan el Motor Económico e Industrial, mientras que el Cluster 2 representa la norma del territorio español (españa rural y de servicios).

Ahora busquemos cuántos clústeres a través de un método más preciso, que confunda 30 índices matemáticos diferentes para encontrar el mejor 'k'.

```
NC<-NbClust(datos_scaled,distance="euclidean",min.nc=2,max.nc=6,method="average",index="kl")


pander(round(NC$All.index, 3))
```

2	3	4	5	6
4.22	7.705	0.632	4.284	0.021

```
pander(round(NC$Best.nc, 3))
```

Number_clusters	Value_Index
3	7.705

El valor más alto está en el clúster 3, lo que significa que la comparación nos lleva a preferir k=3

```r
print(NC$Best.partition)
```

```
##       Almeria         Cadiz       Cordoba       Granada        Huelva
##             1             1             1             1             1
##          Jaen        Malaga       Sevilla        Huesca        Teruel
##             2             1             1             1             1
##      Zaragoza      Asturias      Baleares    Las-Palmas      Tenerife
##             1             1             3             3             1
##     Cantabria         Avila        Burgos          Leon      Palencia
##             1             1             1             1             1
##     Salamanca       Segovia         Soria    Valladolid        Zamora
##             2             1             1             1             1
##      Albacete   Ciudad-Real        Cuenca   Guadalajara        Toledo
##             1             1             1             1             1
##     Barcelona        Gerona        Lerida     Tarragona      Alicante
##             3             3             3             3             1
##     Castellon      Valencia       Badajoz       Caceres     La-Coruna
##             1             1             2             1             1
##          Lugo        Orense    Pontevedra        Madrid        Murcia
##             1             1             1             3             1
##       Navarra         Alava     Guipuzcoa       Vizcaya      La-Rioja
##             3             3             3             3             1
## Ceuta-Melilla
##             2
```

Podemos observar cómo se subdividen los tres grupos:

- **Cluster 1** –> Es el grupo más numeroso, representa la estructura económica y social estándar de la nación.
- **Cluster 2** –> (Jaén, Salamanca, Badajoz y Ceuta-Melilla) Estas provincias están "diferenciadas" del grupo principal porque tienen valores extremos o muy diferentes.
- **Cluster 3** –> (Madrid, Barcelona, el País Vasco, Cataluña y las islas) Representa el "viejo" Cluster 1 de antes, es decir, las zonas más ricas, industriales y turísticas.

Visualizamos cómo sería el clustering con k=3

```r
grpp<-cutree(clusterS,k= 3)

# Prendi tutte le 51 province, ordinale e mostrane 3

completo <- data.frame(Provincia = datos[, 1], Cluster = grpp)


pander(head(completo[completo$Cluster == 1, ], 3))
```

	Provincia	Cluster
Almeria	Almeria	1
Asturias	Asturias	1
Baleares	Baleares	1

```r
pander(head(completo[completo$Cluster == 2, ], 3))
```

	Provincia	Cluster
Cadiz	Cadiz	2
Cordoba	Cordoba	2
Granada	Granada	2

```r
pander(head(completo[completo$Cluster == 3, ], 3))
```

	Provincia	Cluster
Jaen	Jaen	3
Teruel	Teruel	3
Salamanca	Salamanca	3

Aquí podemos notar cómo la clasificación ha intercambiado el número de los clústeres de la partición anterior, pero su tipo de caracterización permanece.

```r
# Creiamo un piccolo data frame per una resa estetica migliore
riepilogo <- data.frame(
  Cluster = c(" 1 ", " 2 "," 3 "),
  `N Provincias` = as.numeric(table(grpp))
)

pander(riepilogo, justify = "left")
```

Cluster	N.Provincias
1	14
2	27
3	10

Al dividirlos en tres grupos, tenemos una mejor partición de elementos en cada grupo.

Análisis gráfico

```r
fviz_dend(clusterS, k = 3,
          cex = 0.6,
          type = "rectangle",
          k_colors = c("#E41A1C", "#377EB8","green"),
          rect = TRUE,
          rect_border = "cluster",
          rect_fill = TRUE,
          ggtheme = theme_minimal(),
          main = "Dendrograma rectangular")
```

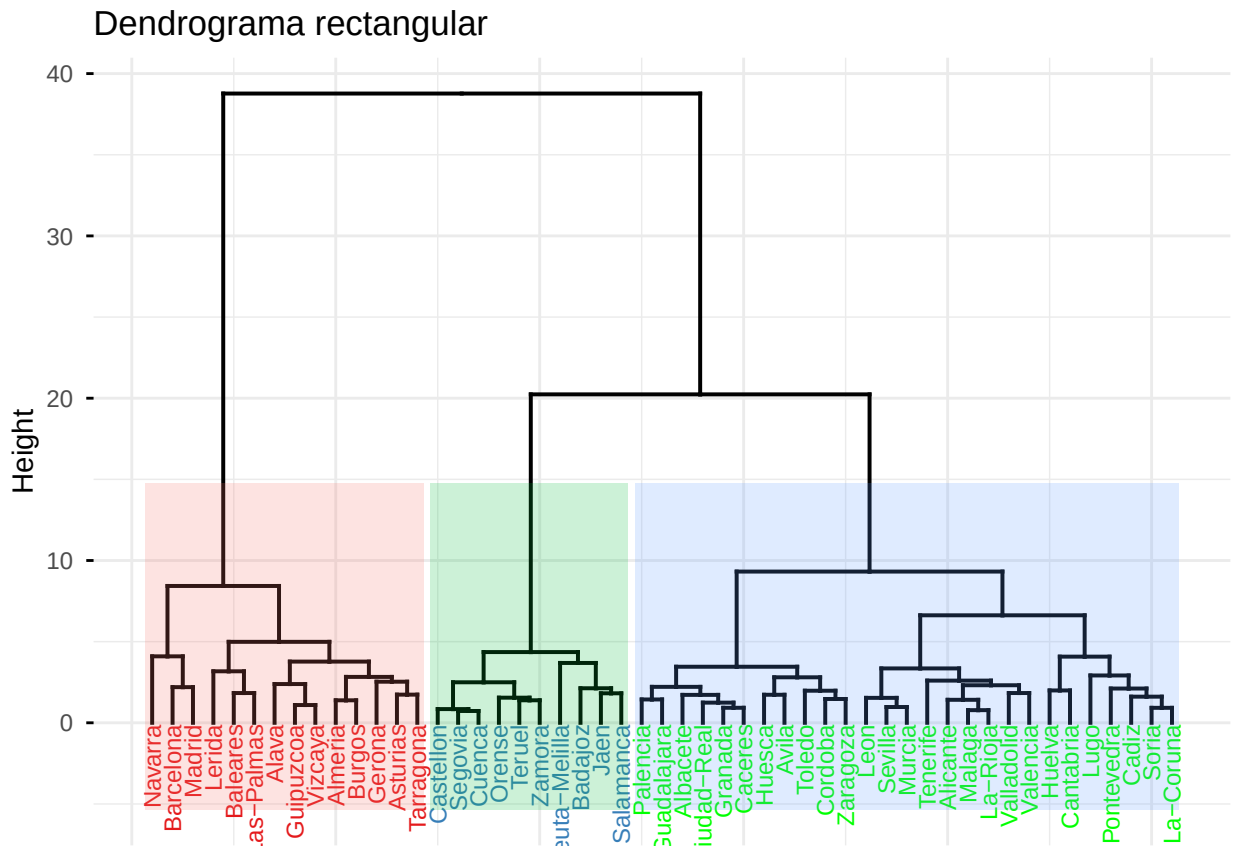


```
fviz_dend(clusterS, k = 3,
          cex = 0.7,
          type = "circular",
          k_colors = c("#E41A1C", "#377EB8","green"),
          ggtheme = theme_gray(),
          main = "Dendrograma Circular")
```

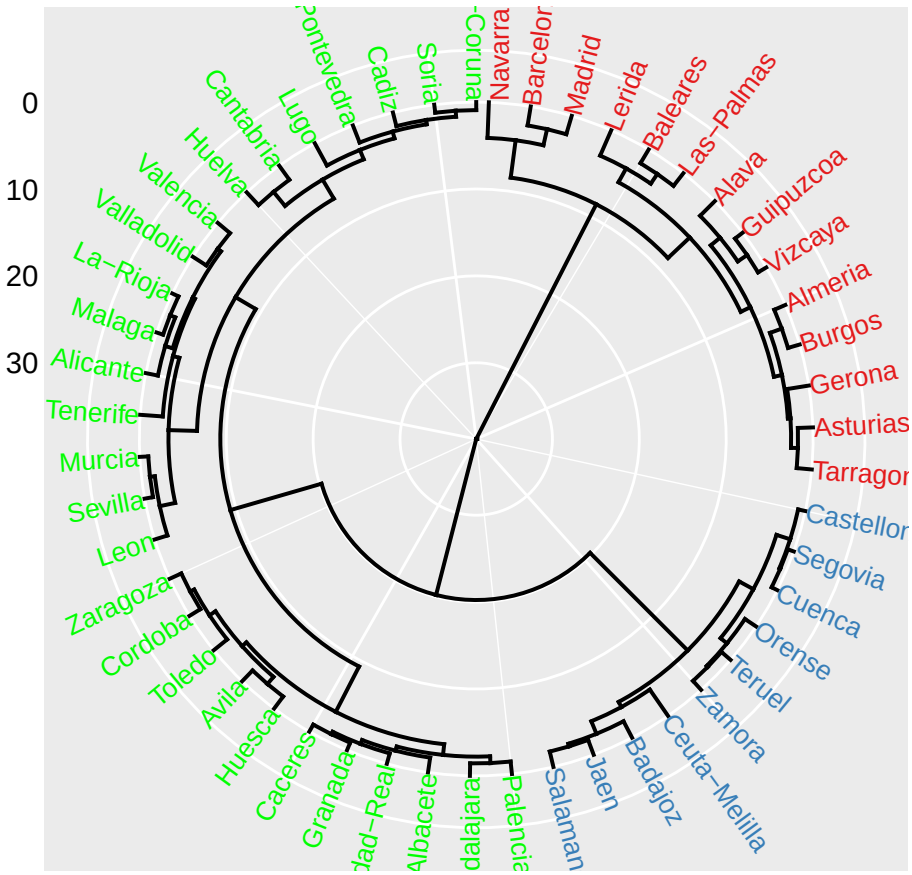


```
fviz_dend(clusterS, k = 3,
          cex = 0.7,
          type = "phylogenic",
          ggtheme = theme_gray(),
          k_colors = c("#E41A1C", "#377EB8","green"),
          main = "Dendrograma filogenético")
```

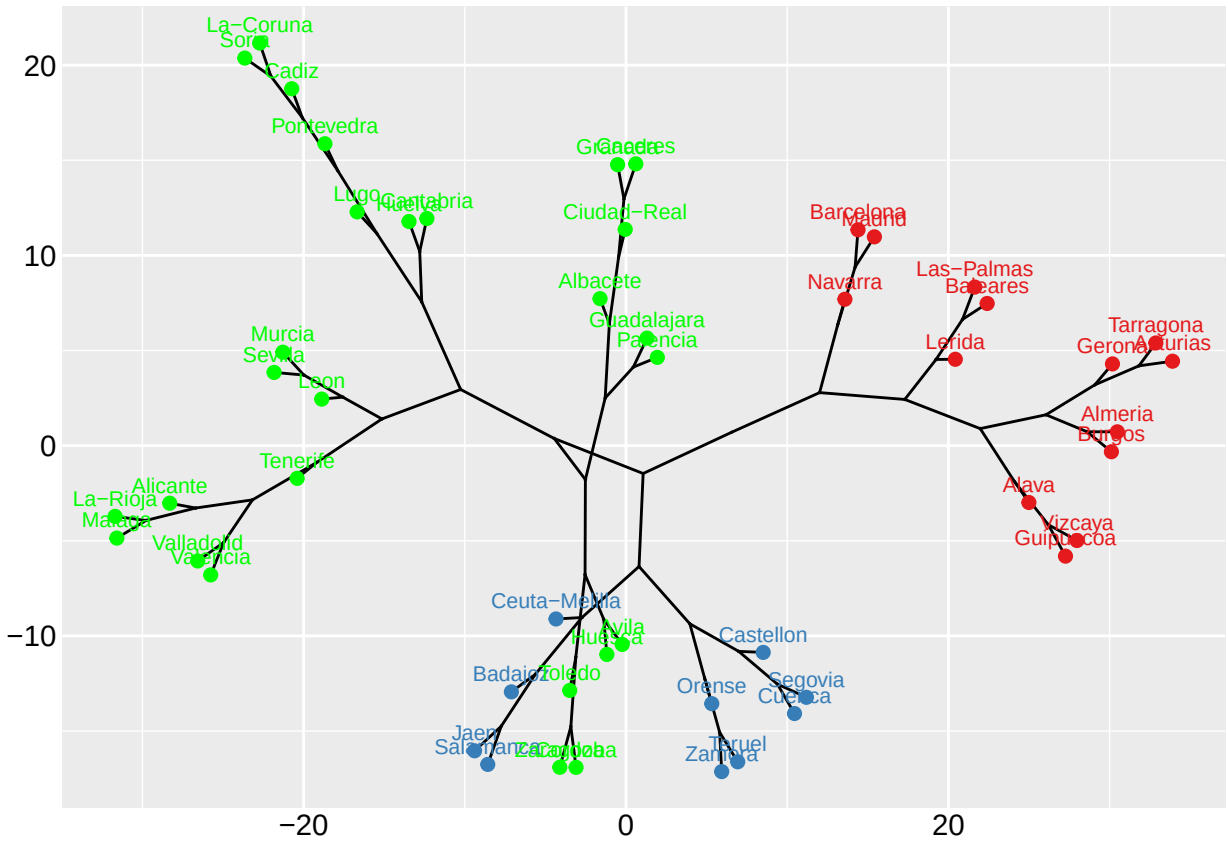


```
fviz_cluster(list(data = datos_numeric , cluster = grpp),
             geom = c("point", "text"), # Mostra sia il punto che il nome
             repel = TRUE,              # FONDAMENTALE: evita che i nomi si sovrappongano
             ellipse.type = "convex",   # Crea un perimetro attorno ai gruppi
             palette = "Set1",          # Colori Rosso/Blu/Verde coerenti con il dendrogramma
             ggtheme = theme_minimal(),
             main = "Mapa de las provincias españolas")
```

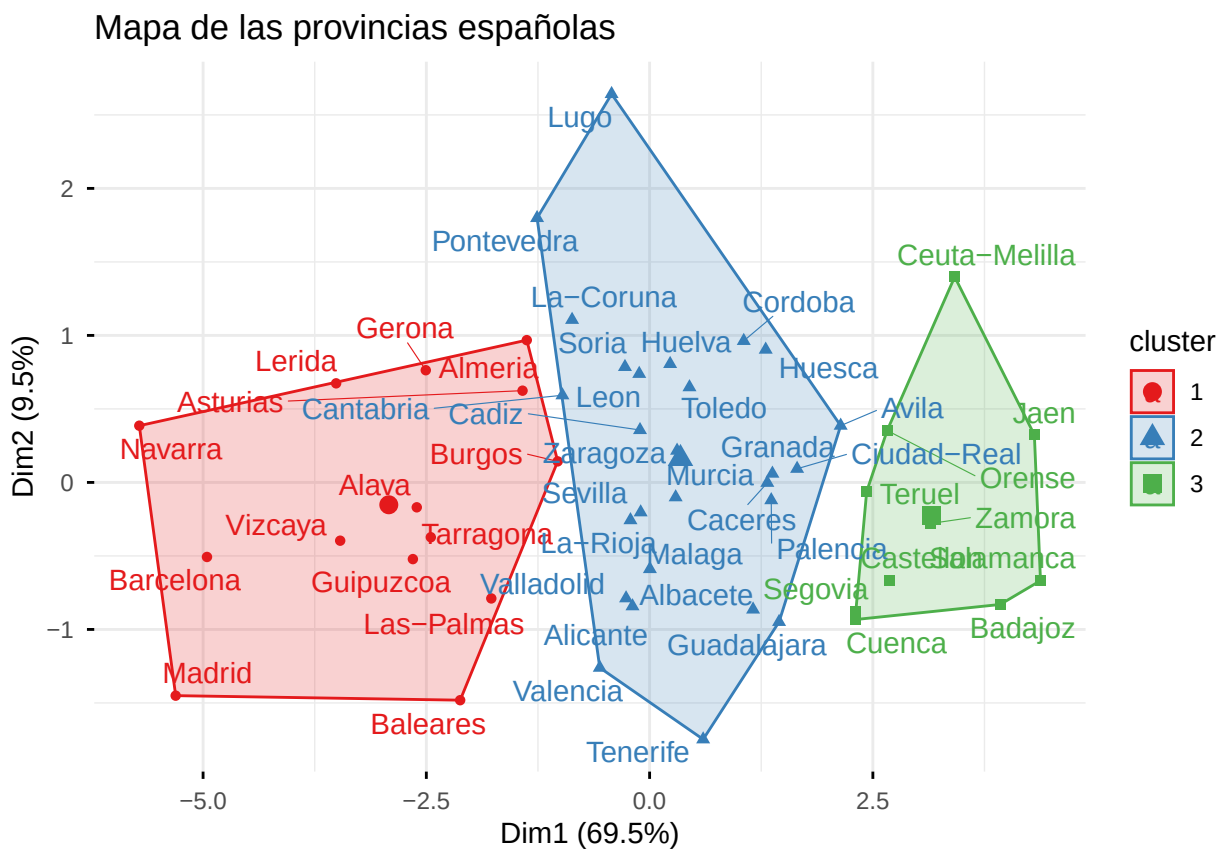

Otro método para elegir k clúster, cálculo del **índice de Dunn** (evalúa si los grupos creados son compactos y están bien separados entre sí).

```
grp2 <- cutree(clusterS, k = 2) # Crea il vettore di appartenenza dividendo l'albero iniziale di Ward i
grp3 <- cutree(clusterS, k = 3) # Lo divide in 3.
grp4 <- cutree(clusterS, k = 4) # Lo divide in 4.
grp5 <- cutree(clusterS, k = 5) # Lo divide in 5.
grp6 <- cutree(clusterS, k = 6) # Lo divide in 6.

d2<-dunn(distancias,grp2) # Calcula l'Indice di Dunn (valuta densità vs separazione esterna) per k=2.
d3<-dunn(distancias,grp3) # Calcula l'Indice di Dunn por k=3.
d4<-dunn(distancias,grp4) # Calcula l'Indice di Dunn por k=4.
d5<-dunn(distancias,grp5) # Calcula l'Indice di Dunn por k=5.
d6<-dunn(distancias,grp6) # Calcula l'Indice di Dunn por k=6.

datos_dum <-cbind(d2,d3,d4,d5,d6) # Unisce i 4 risultati in colonna (cbind = column bind) creando una m

datos_dummy <- datos_dum[, order(datos_dum, decreasing = TRUE)]

pander(t(datos_dummy), caption = "Clasificación del índice de Dunn")
```

Table 28: Clasificación del índice de Dunn

d5	d6	d2	d3	d4
0.2903	0.2696	0.2447	0.2435	0.2435

Según el índice de Dunn la mejor subdivisión sería la de k=5, sin embargo es muy sensible a los “puntos aislados”.

Podemos tener casos límite que Dunn quisiera aislar, además hay que considerar que la diferencia entre d5 y d2 es irrisoria.

En este punto podemos aceptar los anteriores clústeres k=2 y k=3.

Conclusión

El número óptimo de clústeres depende de lo que queremos encontrar en nuestra investigación.

Si quisiéramos una distinción clara y clara, entonces k=2 sería la mejor opción.

Si quisiéramos una separación más caracterizada, yendo más al detalle, entonces k=3 es el ideal.