Ejercicios de LDA

Jan Żurek y Guido D'Inverno

04/2026

Contents

1. Ejercicio 1 **1**
1.0. Presentación del problema. . . . 1
1.1. Carga y presentación de datos . . . 1
1.2. Normalidad . . . 3
1.3 Análisis Discriminante . . . 4
1.4. Visualizaciones - resultos . . . 6

2. Ejercicio 2 **7**
2.0 Presentación del problema. . . . 7

1. Ejercicio 1

1.0. Presentación del problema.

Los datos del fichero `Wisconsin18.RData` proceden de un estudio sobre diagnóstico del cáncer de mama por imagen. Mediante una punción con aguja fina se extrae una muestra del tejido sospechoso de la paciente. La muestra se tiñe para resaltar los núcleos de las células y se determinan los límites exactos de los núcleos. Las vari

El fichero contiene un `data.frame`, llamado `Wisconsin` cuyas variables son:

- Las 10 variables explicativas medidas en pacientes cuyos tumores fueron diagnosticados posteriormente.
- La variable tipo que contiene el tipo de tumor (benigno o maligno).

Se pide realizar un análisis de discriminante y realizar una predicción para dos valores elegidos por el investigador.

1.1. Carga y presentación de datos

Comenzamos con la carga y exploración inicial de los datos. Verificamos la existencia de valores ausentes (nulos) y el tipo de variable de cada columna. Por último, analizamos las estadísticas descriptivas.

```r
cat("Datos faltantes en cada columna:\n")
```

```
## Datos faltantes en cada columna:
```

```r
pander(colSums(is.na(Wisconsin)), split.table = Inf)
```

Table 1: Table continues below

radius	texture	perimeter	area	smoothness	compactness	concavity
0	0	0	0	0	0	0

concavepoints	symmetry	fractal	tipo
0	0	0	0

```r
cat("Tipos de columnas\n")
```

```
## Tipos de columnas
```

```r
str(Wisconsin)
```

```
## 'data.frame':    569 obs. of  11 variables:
##  $ radius       : num  13.5 13.1 9.5 13 8.2 ...
##  $ texture      : num  14.4 15.7 12.4 18.4 16.8 ...
##  $ perimeter    : num  87.5 85.6 60.3 82.6 51.7 ...
##  $ area         : num  566 520 274 524 202 ...
##  $ smoothness   : num  0.0978 0.1075 0.1024 0.0898 0.086 ...
##  $ compactness  : num  0.0813 0.127 0.0649 0.0377 0.0594 ...
##  $ concavity    : num  0.0666 0.0457 0.0296 0.0256 0.0159 ...
##  $ concavepoints: num  0.04781 0.0311 0.02076 0.02923 0.00592 ...
##  $ symmetry     : num  0.188 0.197 0.181 0.147 0.177 ...
##  $ fractal      : num  0.0577 0.0681 0.069 0.0586 0.065 ...
##  $ tipo         : Factor w/ 2 levels "benigno","maligno": 1 1 1 1 1 1 1 1 1 1 ...
```

```r
cat("Estadisticas descriptivas")
```

```
## Estadisticas descriptivas
```

```r
pander(summary(Wisconsin), round = 4)
```

Table 3: Table continues below

radius	texture	perimeter	area
Min. : 6.981	Min. : 9.71	Min. : 43.79	Min. : 143.5
1st Qu.:11.700	1st Qu.:16.17	1st Qu.: 75.17	1st Qu.: 420.3
Median :13.370	Median :18.84	Median : 86.24	Median : 551.1
Mean :14.127	Mean :19.29	Mean : 91.97	Mean : 654.9
3rd Qu.:15.780	3rd Qu.:21.80	3rd Qu.:104.10	3rd Qu.: 782.7
Max. :28.110	Max. :39.28	Max. :188.50	Max. :2501.0

Table 4: Table continues below

smoothness	compactness	concavity	concavepoints
Min. :0.05263	Min. :0.01938	Min. :0.00000	Min. :0.00000
1st Qu.:0.08637	1st Qu.:0.06492	1st Qu.:0.02956	1st Qu.:0.02031
Median :0.09587	Median :0.09263	Median :0.06154	Median :0.03350
Mean :0.09636	Mean :0.10434	Mean :0.08880	Mean :0.04892
3rd Qu.:0.10530	3rd Qu.:0.13040	3rd Qu.:0.13070	3rd Qu.:0.07400
Max. :0.16340	Max. :0.34540	Max. :0.42680	Max. :0.20120

symmetry	fractal	tipo
Min. :0.1060	Min. :0.04996	benigno:357
1st Qu.:0.1619	1st Qu.:0.05770	maligno:212

symmetry	fractal	tipo
Median :0.1792	Median :0.06154	NA
Mean :0.1812	Mean :0.06280	NA
3rd Qu.:0.1957	3rd Qu.:0.06612	NA
Max. :0.3040	Max. :0.09744	NA

Visualizamos las relaciones entre las variables mediante una matriz de dispersión. Esto nos permite observar las correlaciones y el grado de solapamiento entre los tumores benignos y malignos.

```
pairs.panels(Wisconsin[1:10],
             gap = 0,
             pch = 21,
             cex = 0.5,
             bg = c("green", "blue")[Wisconsin$tipo],
             main = "Matriz de dispersión y correlaciones"
)
```

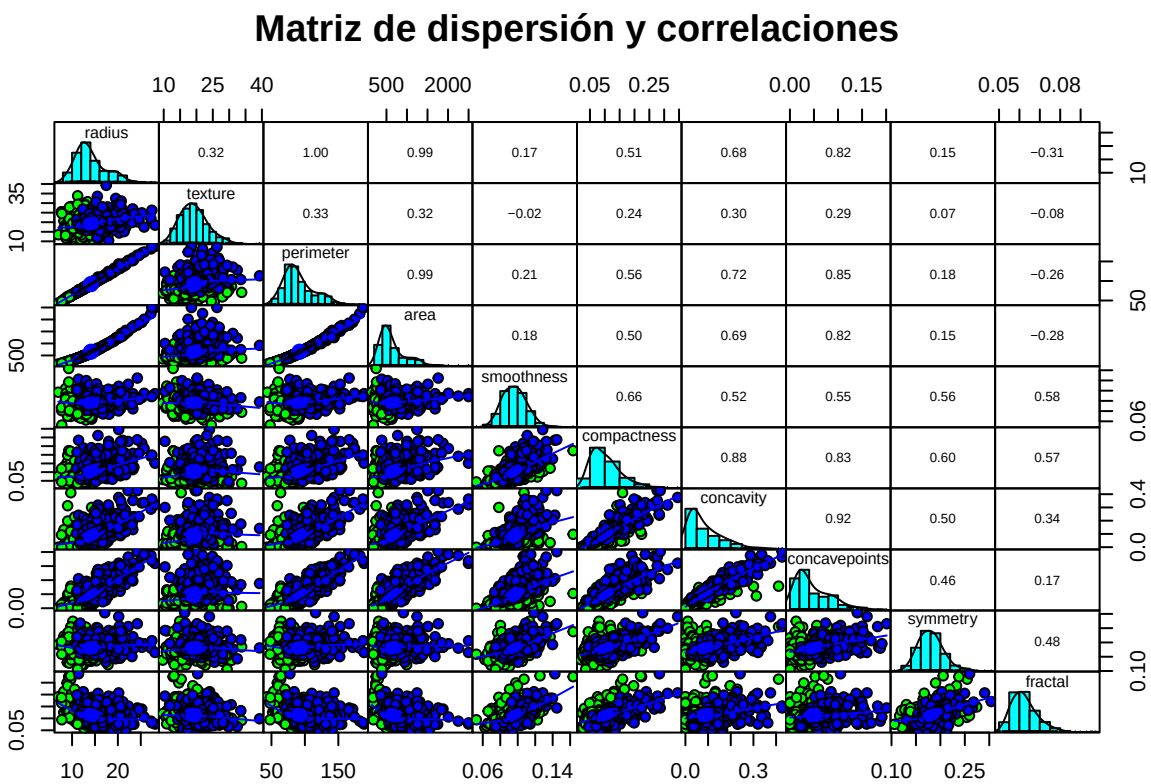

Observamos de manera preliminar que los datos presentan un buen potencial para la realización de un análisis discriminante. No obstante, antes de proceder, es necesario verificar el cumplimiento de ciertos supuestos estadísticos clave…

1.2. Normalidad

Uno de los supuestos fundamentales para el Análisis Discriminante Lineal (LDA) es la normalidad de las variables. Por lo tanto, debemos comprobar si nuestros datos siguen una distribución normal. Para ello, utilizaremos la prueba de Shapiro-Wilk.

```r
pander(stat.desc(Wisconsin[, -11], basic=FALSE, norm=TRUE), round = 4)
```

Table 6: Table continues below

	radius	texture	perimeter	area	smoothness
median	13.37	18.84	86.24	551.1	0.0959
mean	14.13	19.29	91.97	654.9	0.0964
SE.mean	0.1477	0.1803	1.019	14.75	6e-04
CI.mean.0.95	0.2902	0.3542	2.001	28.98	0.0012
var	12.42	18.5	590.4	123844	2e-04
std.dev	3.524	4.301	24.3	351.9	0.0141
coef.var	0.2494	0.223	0.2642	0.5374	0.146
skewness	0.9374	0.647	0.9854	1.637	0.4539
skew.2SE	4.576	3.159	4.811	7.992	2.216
kurtosis	0.8141	0.728	0.9393	3.587	0.8245
kurt.2SE	1.991	1.78	2.297	8.77	2.016
normtest.W	0.9411	0.9767	0.9362	0.8584	0.9875
normtest.p	0	0	0	0	1e-04

	compactness	concavity	concavepoints	symmetry	fractal
median	0.0926	0.0615	0.0335	0.1792	0.0615
mean	0.1043	0.0888	0.0489	0.1812	0.0628
SE.mean	0.0022	0.0033	0.0016	0.0011	3e-04
CI.mean.0.95	0.0043	0.0066	0.0032	0.0023	6e-04
var	0.0028	0.0064	0.0015	8e-04	0
std.dev	0.0528	0.0797	0.0388	0.0274	0.0071
coef.var	0.5062	0.8978	0.7932	0.1513	0.1124
skewness	1.184	1.394	1.165	0.7218	1.298
skew.2SE	5.779	6.804	5.688	3.524	6.335
kurtosis	1.609	1.953	1.032	1.251	2.948
kurt.2SE	3.934	4.776	2.525	3.059	7.209
normtest.W	0.917	0.8668	0.8917	0.9726	0.9233
normtest.p	0	0	0	0	0

Dado que los valores p son inferiores a 0.05, se rechaza la hipótesis nula de normalidad. Sin embargo, dado el tamaño de la muestra, el LDA puede seguir siendo una técnica robusta para la clasificación.

1.3 Análisis Discriminante

Finalmente, procedemos a realizar el esperado análisis discriminante.

```r
discriminante <- lda(tipo~., data = Wisconsin)
discriminante
```

```
## Call:
## lda(tipo ~ ., data = Wisconsin)
##
## Prior probabilities of groups:
##   benigno   maligno
## 0.6274165 0.3725835
##
```

```
## Group means:
##           radius  texture perimeter     area smoothness compactness  concavity
## benigno 12.14652 17.91476  78.07541 462.7902 0.09247765  0.08008462 0.04605762
## maligno 17.46283 21.60491 115.36538 978.3764 0.10289849  0.14518778 0.16077472
##         concavepoints symmetry    fractal
## benigno    0.02571741 0.174186 0.06286739
## maligno    0.08799000 0.192909 0.06268009
##
## Coefficients of linear discriminants:
##                       LD1
## radius         2.173832578
## texture        0.097479319
## perimeter     -0.243883158
## area          -0.004235635
## smoothness     8.610211091
## compactness    0.431476344
## concavity      3.592356858
## concavepoints 28.529778564
## symmetry       4.489073661
## fractal       -0.529214778
```

1. En primer lugar, observamos las **probabilidades a priori**, que representan la proporción de tumores benignos y malignos en nuestro conjunto de datos.
2. A continuación, se presentan las medias grupales para cada variable. Podemos observar que en algunas de ellas existen diferencias notables entre grupos (por ejemplo, el `radios`: 12.15 frente a 17.46; o la `concavity`: 0.046 frente a 0.16), mientras que en otras, como la simetría (`symmetry`) o la dimensión `fractal`, las diferencias son mínimas o casi inexistentes.
3. La tercera sección de los resultados muestra los **coeficientes lineales de discriminación**. Es fundamental señalar que **no podemos comparar directamente la magnitud de estos coeficientes** para determinar qué variables son las más influyentes en el modelo, ya que **las variables originales no han sido estandarizadas**. Por lo tanto, para una interpretación correcta, procederemos a calcular los coeficientes estandarizados y a ordenarlos según su importancia.

```r
# 1. Calculamos las puntuaciones (scores) de LD1 para cada observación
lda_values <- predict(discriminante)$x

# 2. Calculamos la correlación entre las variables originales y LD1
correlations <- cor(Wisconsin[1:10], lda_values)

# 3. Mostramos los resultados ordenados por importancia (valor absoluto)
sort(abs(correlations[,1]), decreasing = TRUE)
```

```
## concavepoints     perimeter        radius          area     concavity
##    0.93987433    0.89875307    0.88349579    0.85802709    0.84274910
##   compactness       texture    smoothness      symmetry       fractal
##    0.72193755    0.50246595    0.43393678    0.39997627    0.01553634
```

Tras analizar la matriz de estructura (las correlaciones entre las variables originales y la función discriminante LD1), podemos clasificar las variables en tres grupos según su poder de discriminación:

- **Variables clave o de alta importancia** (correlación > 0.7): `concavepoints`, `perimeter`, `radius`, `area`, `concavity` i `compactness`. Estas características son los principales indicadores para diferenciar los tipos de tumor.
- **Variables de importancia moderada** (correlación entre 0.3 y 0.7): `texture`, `smoothness` i `symmetry`. Tienen una contribución relevante, aunque secundaria.

- **Variables poco significativas** (correlación < 0.3): `fractal`. Esta variable apenas aporta información útil para la separación de los grupos en este modelo.

```
discriminante$svd
```

```
## [1] 34.93298
```

```
# tutaj jeszcze można dodać model manova
```

El modelo de análisis discriminante presenta un valor singular (`$svd`) de 34.93. Este valor es considerablemente elevado, lo que indica una excelente capacidad de separación entre las dos clases (tumores benignos y malignos).

Al ser un problema de clasificación con solo dos grupos, existe una única función discriminante (LD1) que captura el 100% de la variabilidad inter-grupos. La magnitud de este valor refleja que las medias de los grupos están muy alejadas entre sí en comparación con su dispersión interna, lo que sugiere que el modelo será altamente preciso en sus predicciones.

1.4. Visualizaciones - resultos

```
plot(discriminante, dimen = 1, type="b")
```

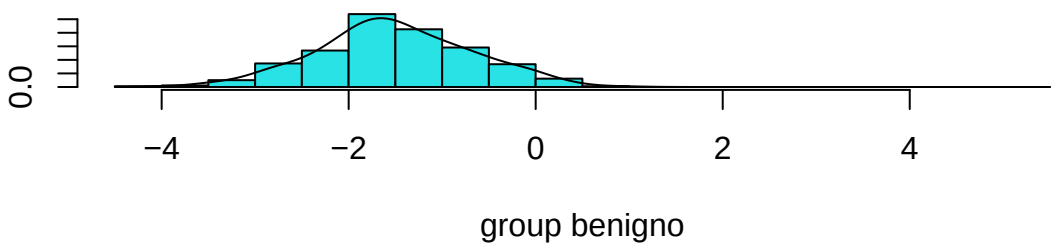

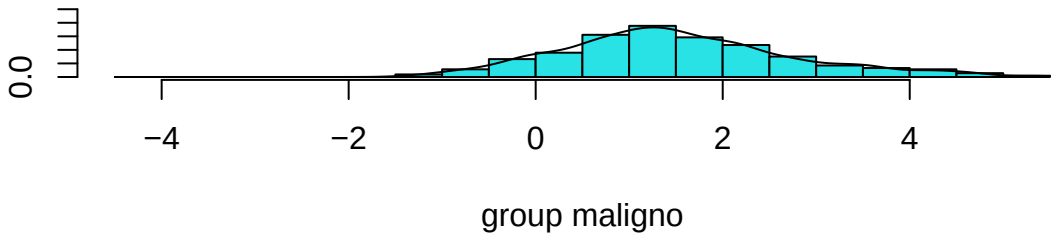

C.D.N....

[Matriz de confusion]

[predicciones]

2. Ejercicio 2

2.0 Presentación del problema.

El fichero de datos (`discriminante.txt`) contiene para 37 individuos los datos correspondientes a 13 variables denominadas $X1, X2, ..., X13$ y una última variable que clasifica a las observaciones en tres grupos.

Realizar un análisis discriminante completo.