

Ejercicios de Regresión logística

Jan Žurek y Guido D’Inverno

05/2026

Contents

Ejercicio 1	1
1.0. Análisis previos	1
1.1. Regresión Logística Binomial	3
1.2. Comprobación de la significatividad del modelo y de las variables	5
1.3. Evaluación de la Calidad y Bondad de Ajuste	8
1.4. Diagnóstico de Multicolinealidad	8
1.5. Capacidad Predictiva: Matriz de Confusión	8
1.6. Análisis de Discriminación: Curva ROC y AUC	9
1.7. Conclusiones e Interpretación Final	9
Ejercicio 2 :Regresión Logística de dataset ‘multinomial.txt’	10
2.1. Análisis previos	10
2.1. Regresión Logística Multinomial	11
2.2. Comprobación de la significatividad del modelo y de las variables	13
2.4. Modelo más parsimonioso	15
2.5. Bondad del ajuste y Significatividad de la predicción	16
2.6. Estimación e Interpretación de los parametros	17
2.6. Conclusión	19

Ejercicio 1

1.0. Análisis previos

En esta sección se realiza la carga de los datos y la preparación de las variables. Es fundamental que las variables cualitativas sean tratadas como factores, y en los casos donde existe una jerarquía lógica, como factores ordenados.

Carga de datos y conversión inicial a factores

Comenzamos importando el archivo de datos y transformando las columnas categóricas básicas en factores para que el modelo de regresión logística las interprete correctamente.

```
# Importación del conjunto de datos
binomial1 <- as.data.frame(read.table("binomial.txt", header = T, sep = "\t"))

# Visualización de los nombres de las columnas
colnames(binomial1)
```

```
## [1] "edad"          "EstadoCivil"    "Direccion"      "Ingresos"
## [5] "tipovehiculo"  "Educacion"      "Anostrabajando" "Satisfaclab"
## [9] "Personashogar" "Baja"
```

```
# Conversión masiva de variables cualitativas a factores (columnas 2 a 8 y 10)
binomial1[c(2:8,10)] <- lapply(binomial1[c(2:8,10)], as.factor)
```

Configuración de factores ordinales

Para las variables que representan una escala o progresión (como ingresos, educación o satisfacción), definimos factores ordenados (`ordered = TRUE`). Esto permitirá al modelo identificar tendencias (lineales, cuadráticas, etc.) en los resultados.

```
# Definición de Ingresos como factor ordinal (el orden se toma automáticamente de los niveles existentes)
binomial1$Ingresos <- factor(binomial1$Ingresos,
                             ordered = TRUE)
```

Variable: Ingresos

Variable: Educación Establecemos una jerarquía que va desde el nivel de estudios más bajo hasta el más alto.

```
# Ordenación jerárquica de los niveles educativos
binomial1$Educacion <- factor(binomial1$Educacion,
                              levels = c("Basicos", "Bachillerato", "Diplomado", "Licenciado", "Tercer c
                              ordered = TRUE)
```

Variable: Antigüedad laboral Categorizamos los años de trabajo en tres niveles de experiencia.

```
# Definición de niveles de antigüedad laboral de menor a mayor
binomial1$Anostrabajando <- factor(binomial1$Anostrabajando,
                                   levels = c("Menos de 5", "5 a 15", "Mas de 15"),
                                   ordered = TRUE)
```

Variable: Satisfacción laboral Se trata como una escala Likert de cinco puntos, fundamental para medir el clima laboral.

```
# Ordenación de los niveles de satisfacción, desde el más negativo al más positivo
binomial1$Satisfaclab <- factor(binomial1$Satisfaclab,
                                levels = c("Muy insatisfecho", "Algo insatisfecho", "Neutro", "Algo s
                                ordered = TRUE)
```

Verificación de la estructura de los datos

Finalmente, revisamos que todas las transformaciones se hayan aplicado correctamente y que las variables tengan el formato esperado antes de ejecutar el modelo.

```
# Inspección de la estructura final del dataframe
str(binomial1)
```

```
## 'data.frame': 1093 obs. of 10 variables:
## $ edad : int 55 56 28 24 25 45 42 35 46 34 ...
## $ EstadoCivil : Factor w/ 2 levels "Casado","Soltero": 1 2 1 1 2 1 2 2 1 ...
## $ Direccion : Factor w/ 47 levels "0","1","2","3",...: 13 30 10 5 3 10 20 16 27 1 ...
## $ Ingresos : Ord.factor w/ 4 levels "-25"<"25-49"<...: 3 4 2 2 1 3 2 3 1 4 ...
## $ tipovehiculo : Factor w/ 3 levels "Economico","Estandar",...: 3 3 1 1 1 2 2 2 1 3 ...
## $ Educacion : Ord.factor w/ 5 levels "Basicos"<"Bachillerato"<...: 1 1 3 4 2 3 3 2 1 3 ...
## $ Anostrabajando: Ord.factor w/ 3 levels "Menos de 5"<"5 a 15"<...: 3 3 1 1 2 2 2 1 2 2 ...
## $ Satisfaclab : Ord.factor w/ 5 levels "Muy insatisfecho"<...: 5 4 3 1 2 2 2 1 5 4 ...
```

```
## $ Personashogar : int  4 1 3 3 2 2 1 1 2 6 ...
## $ Baja          : Factor w/ 2 levels "No","SI": 1 1 1 1 1 1 1 1 1 1 ...
```

Comentarios sobre la estructura:

- **Variable objetivo:** Baja es un factor con 2 niveles (“No”, “SI”), lo cual es adecuado para una regresión logística binaria.
- **Variables cuantitativas:** edad y Personashogar se mantienen como enteros (int), representando valores numéricos directos.
- **Variables ordinales:** Ingresos, Educacion y Anostrabajando aparecen correctamente como Ord.factor. Esto permitirá al modelo capturar tendencias jerárquicas.
- **Alta cardinalidad:** Se observa que la variable Direccion posee **47 niveles**. Como se analizó en el test de Wald, esta variable aporta demasiada complejidad al modelo sin mejorar necesariamente su precisión, por lo que su eliminación está justificada estadísticamente.
- **Factores cualitativos:** EstadoCivil y tipovehiculo están definidos como factores nominales básicos, ideales para representar categorías sin un orden intrínseco.

1.1. Regresión Logística Binomial

En esta sección, procedemos a ajustar el modelo de regresión logística para predecir la probabilidad de la variable objetivo Baja.

Ajuste del modelo completo

Primero, estimamos un modelo inicial que incluye todas las variables predictoras presentes en el conjunto de datos. Utilizamos la función `glm` con la familia `binomial` para indicar que estamos ante un problema de clasificación binaria.

```
# Ajuste del modelo de regresión logística utilizando todas las variables disponibles
logistica <- glm(Baja ~ ., data = binomial1, family = binomial)
```

Extracción de coeficientes y cálculo de Odds Ratios

Dado que los coeficientes del modelo (`Estimate`) se expresan en escala logarítmica (*log-odds*), su interpretación directa no es intuitiva. Para facilitar la comprensión del impacto de cada variable, calculamos los **Odds Ratios** aplicando la función exponencial a los coeficientes.

```
# Extracción de la tabla de coeficientes, errores estándar, estadístico z y p-valores
tab_wyniki <- summary(logistica)$coefficients

# Cálculo de los Odds Ratios (exponencial de los coeficientes) redondeados a 3 decimales
OR <- round(exp(coef(logistica)), 3)
```

Consolidación de resultados

Finalmente, combinamos los resultados estadísticos del modelo con los *Odds Ratios* en una única tabla para su análisis. Un *Odds Ratio* superior a 1 indica un aumento en la probabilidad de “Baja”, mientras que un valor inferior a 1 indica una disminución.

```
# Combinación de la tabla de coeficientes con la columna de Odds Ratios
tabela_finalna <- cbind(tab_wyniki, Odds_Ratio = OR)

# Presentación estética de los resultados finales con la función kable
library(knitr)
kable(round(tabela_finalna, 5), caption = "Resumen del Modelo Logístico con Odds Ratios")
```

Table 1: Resumen del Modelo Logístico con Odds Ratios

	Estimate	Std. Error	z value	Pr(> z)	Odds_Ratio
(Intercept)	-0.15504	0.48672	-0.31854	0.75007	0.856
edad	-0.00720	0.00772	-0.93231	0.35117	0.993
EstadoCivilSoltero	-0.48559	0.17751	-2.73557	0.00623	0.615
Direccion1	-0.23338	0.33853	-0.68940	0.49057	0.792
Direccion2	0.08078	0.35388	0.22826	0.81944	1.084
Direccion3	-0.08088	0.34311	-0.23572	0.81365	0.922
Direccion4	-0.63430	0.40222	-1.57699	0.11480	0.530
Direccion5	-0.25655	0.37135	-0.69086	0.48965	0.774
Direccion6	0.00997	0.37755	0.02641	0.97893	1.010
Direccion7	0.01156	0.37643	0.03070	0.97551	1.012
Direccion8	-0.12936	0.37987	-0.34055	0.73344	0.879
Direccion9	0.10092	0.39277	0.25695	0.79722	1.106
Direccion10	-0.33999	0.41010	-0.82905	0.40708	0.712
Direccion11	-0.13797	0.46706	-0.29541	0.76768	0.871
Direccion12	-0.32888	0.44053	-0.74656	0.45533	0.720
Direccion13	0.02655	0.39786	0.06672	0.94680	1.027
Direccion14	0.46800	0.44070	1.06195	0.28826	1.597
Direccion15	-0.79118	0.48523	-1.63053	0.10299	0.453
Direccion16	0.47346	0.45172	1.04814	0.29457	1.606
Direccion17	-0.42981	0.51029	-0.84229	0.39962	0.651
Direccion18	-0.23632	0.53637	-0.44060	0.65950	0.790
Direccion19	0.12652	0.49662	0.25477	0.79890	1.135
Direccion20	-0.14924	0.64574	-0.23112	0.81722	0.861
Direccion21	-0.46291	0.68214	-0.67862	0.49738	0.629
Direccion22	0.06346	0.61072	0.10391	0.91724	1.066
Direccion23	0.24121	0.53918	0.44736	0.65462	1.273
Direccion24	-2.05336	1.09406	-1.87683	0.06054	0.128
Direccion25	-0.06122	0.66816	-0.09163	0.92700	0.941
Direccion26	-0.15588	0.80618	-0.19336	0.84668	0.856
Direccion27	-0.52896	0.69537	-0.76068	0.44685	0.589
Direccion28	0.46333	0.58292	0.79484	0.42671	1.589
Direccion29	0.04401	0.70237	0.06266	0.95003	1.045
Direccion30	0.35358	0.61775	0.57236	0.56707	1.424
Direccion31	0.38205	0.73811	0.51760	0.60473	1.465
Direccion32	-0.28167	0.91731	-0.30706	0.75880	0.755
Direccion33	-0.46286	1.28086	-0.36136	0.71783	0.629
Direccion34	-0.57538	0.93471	-0.61557	0.53818	0.562
Direccion35	-1.09969	0.87804	-1.25244	0.21041	0.333
Direccion36	0.70616	0.97207	0.72645	0.46756	2.026
Direccion37	-13.68386	605.79601	-0.02259	0.98198	0.000
Direccion38	0.08851	1.47467	0.06002	0.95214	1.093
Direccion39	15.53380	882.74346	0.01760	0.98596	5574990.382
Direccion40	0.98673	1.50934	0.65375	0.51327	2.682
Direccion41	-14.62934	882.74347	-0.01657	0.98678	0.000
Direccion43	1.27215	1.27584	0.99711	0.31871	3.569
Direccion48	-14.11695	882.74348	-0.01599	0.98724	0.000
Direccion50	-14.69844	882.74349	-0.01665	0.98672	0.000
Direccion51	-13.40411	882.74349	-0.01518	0.98788	0.000
Direccion56	-13.75831	882.74350	-0.01559	0.98756	0.000
Ingresos.L	-0.73673	0.29832	-2.46957	0.01353	0.479

	Estimate	Std. Error	z value	Pr(> z)	Odds_Ratio
Ingresos.Q	-0.27123	0.17700	-1.53238	0.12543	0.762
Ingresos.C	0.27316	0.13856	1.97146	0.04867	1.314
tipovehiculoEstandar	0.32265	0.21771	1.48202	0.13833	1.381
tipovehiculoLujo	1.52661	0.35767	4.26814	0.00002	4.603
Educacion.L	-0.04700	0.21607	-0.21751	0.82781	0.954
Educacion.Q	0.03134	0.18908	0.16574	0.86836	1.032
Educacion.C	0.14604	0.15577	0.93752	0.34849	1.157
Educacion^4	0.04270	0.14185	0.30104	0.76338	1.044
Anostrabajando.L	-0.04560	0.18138	-0.25144	0.80148	0.955
Anostrabajando.Q	0.12054	0.11802	1.02141	0.30706	1.128
Satisfaclab.L	-0.16945	0.18015	-0.94065	0.34688	0.844
Satisfaclab.Q	-0.23381	0.15498	-1.50867	0.13138	0.792
Satisfaclab.C	0.06359	0.14563	0.43667	0.66235	1.066
Satisfaclab^4	-0.08525	0.13988	-0.60948	0.54220	0.918
Personashogar	-0.11618	0.06121	-1.89812	0.05768	0.890

1.2. Comprobación de la significatividad del modelo y de las variables

En esta etapa, evaluamos si todas las variables incluidas aportan valor predictivo al modelo o si, por el contrario, algunas generan ruido innecesario.

1.2.1. Test de Wald para la variable ‘Direccion’

La variable *Direccion* presenta una alta cardinalidad (46 niveles en el modelo). Utilizamos el test de Wald para evaluar la significatividad conjunta de todos estos parámetros. Una hipótesis nula con un p-valor elevado indicaría que la variable no contribuye significativamente al modelo.

```
# Realización del test de Wald para los términos del 4 al 49 (niveles de Direccion)
library(aod)
wald.test(b = coef(logistica), Sigma = vcov(logistica), Terms = 4:49)
```

```
## Wald test:
## -----
##
## Chi-squared test:
## X2 = 25.4, df = 46, P(> X2) = 0.99
```

Nota: Si el p-valor es alto (ej. 0.99), se confirma que la variable ‘Direccion’ puede ser eliminada sin perder capacidad explicativa.

1.2.2. Refinamiento del modelo (logistica2)

Tras observar la baja significatividad de la ubicación geográfica, ajustamos un segundo modelo excluyendo la variable *Direccion*. El objetivo es obtener un modelo más parsimonioso y evitar el sobreajuste (overfitting).

```
# Modelo excluyendo la variable Direccion
logistica2 <- glm(Baja ~ . - Direccion, data = binomial1, family = binomial)

# Resumen estadístico del segundo modelo
summary(logistica2)
```

```
##
## Call:
## glm(formula = Baja ~ . - Direccion, family = binomial, data = binomial1)
```

```
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.286742   0.420414  -0.682   0.4952
## edad           -0.006963   0.006437  -1.082   0.2793
## EstadoCivilSoltero -0.425646   0.172174  -2.472   0.0134 *
## Ingresos.L      -0.727318   0.286187  -2.541   0.0110 *
## Ingresos.Q      -0.232142   0.171560  -1.353   0.1760
## Ingresos.C       0.320581   0.133563   2.400   0.0164 *
## tipovehiculoEstandar 0.312568   0.212766   1.469   0.1418
## tipovehiculoLujo   1.456368   0.345077   4.220 2.44e-05 ***
## Educacion.L      -0.027399   0.211044  -0.130   0.8967
## Educacion.Q       0.078689   0.184394   0.427   0.6696
## Educacion.C       0.135683   0.152301   0.891   0.3730
## Educacion^4       0.039271   0.137083   0.286   0.7745
## Anostrabajando.L -0.046384   0.173944  -0.267   0.7897
## Anostrabajando.Q  0.105872   0.113588   0.932   0.3513
## Satisfaclab.L    -0.161514   0.175126  -0.922   0.3564
## Satisfaclab.Q    -0.256775   0.149302  -1.720   0.0855 .
## Satisfaclab.C     0.015622   0.139901   0.112   0.9111
## Satisfaclab^4    -0.066068   0.133978  -0.493   0.6219
## Personashogar    -0.110966   0.059737  -1.858   0.0632 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1471.8  on 1092  degrees of freedom
## Residual deviance: 1433.5  on 1074  degrees of freedom
## AIC: 1471.5
##
## Number of Fisher Scoring iterations: 4
```

1.2.3. Selección de variables clave (logística3)

Basándonos en los resultados anteriores y en la significatividad individual de los coeficientes, proponemos un tercer modelo que solo incluye las variables que han mostrado ser relevantes o que están cerca del umbral de significatividad: EstadoCivil, Ingresos, tipovehiculo y Personashogar.

```
# Ajuste del modelo parsimonioso con las variables más influyentes
logistica3 <- glm(Baja ~ EstadoCivil + Ingresos + tipovehiculo + Personashogar,
                 data = binomial1,
                 family = binomial)

# Resumen del modelo simplificado
summary(logistica3)
```

```
##
## Call:
## glm(formula = Baja ~ EstadoCivil + Ingresos + tipovehiculo +
##      Personashogar, family = binomial, data = binomial1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.56525   0.25800  -2.191   0.02846 *
```

```
## EstadoCivilSoltero    -0.38874    0.16637   -2.337    0.01946 *
## Ingresos.L            -0.77830    0.28121   -2.768    0.00565 **
## Ingresos.Q            -0.26304    0.16838   -1.562    0.11824
## Ingresos.C             0.32689    0.13253    2.467    0.01364 *
## tipovehiculoEstandar   0.22290    0.20663    1.079    0.28071
## tipovehiculoLujo       1.32061    0.33400    3.954 7.69e-05 ***
## Personashogar          -0.08942    0.05570   -1.605    0.10840
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 1471.8  on 1092  degrees of freedom
## Residual deviance: 1441.3  on 1085  degrees of freedom
## AIC: 1457.3
##
## Number of Fisher Scoring iterations: 4
```

1.2.4. Comparación de modelos y análisis de devianza

Para validar nuestras decisiones, analizamos la tabla de devianza. Esta nos permite observar cómo cada variable reduce el error del modelo. Además, comparamos los modelos mediante el **AIC (Akaike Information Criterion)**.

```
# Análisis de la reducción de la devianza para el modelo 2
anova(logistica2, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: Baja
##
## Terms added sequentially (first to last)
##
##
##              Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL                                1092     1471.8
## edad              1    0.0068      1091     1471.8 0.9341369
## EstadoCivil       1    3.1564      1090     1468.7 0.0756277 .
## Ingresos           3    7.2887      1087     1461.4 0.0632437 .
## tipovehiculo       2   18.0609      1085     1443.3 0.0001197 ***
## Educacion          4    0.9472      1081     1442.4 0.9176987
## Anostrabajando     2    1.0796      1079     1441.3 0.5828520
## Satisfaclab        4    4.2862      1075     1437.0 0.3686608
## Personashogar      1    3.4961      1074     1433.5 0.0615134 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Conclusión de la comparación

Al comparar los modelos, observamos los valores del **AIC**. Un valor de **AIC más bajo** indica un mejor equilibrio entre el ajuste del modelo y su complejidad (parsimonia).

- Si el modelo simplificado mantiene o mejora el AIC del modelo completo, se prefiere el modelo más sencillo por ser más eficiente y fácil de interpretar.

1.3. Evaluación de la Calidad y Bondad de Ajuste

En la regresión logística no existe un R^2 convencional. Por ello, utilizamos medidas como el **Pseudo-R2 de McFadden** para entender qué proporción de la varianza es explicada por el modelo final (logistica3).

```
### Bondad de ajuste (McFadden)
# Un valor entre 0.2 y 0.4 se considera un ajuste excelente.
library(psc1)
pseudo_r2 <- pR2(logistica3)["McFadden"]
```

```
## fitting null model for pseudo-r2
print(paste("Pseudo-R2 de McFadden:", round(pseudo_r2, 4)))
```

```
## [1] "Pseudo-R2 de McFadden: 0.0208"
```

1.4. Diagnóstico de Multicolinealidad

Es fundamental verificar que las variables predictoras no estén altamente correlacionadas entre sí, ya que esto podría inflar los errores estándar y sesgar los resultados. Utilizamos el **Factor de Inflación de la Varianza (VIF)**.

```
### Evaluación de multicolinealidad
# Valores de VIF mayores a 5 o 10 indicarían problemas graves.
library(car)
vif(logistica3)
```

```
##           GVIF Df GVIF^(1/(2*Df))
## EstadoCivil  1.762359  1      1.327539
## Ingresos     8.269466  3      1.422044
## tipovehiculo 8.206030  2      1.692518
## Personashogar 1.781180  1      1.334608
```

1.5. Capacidad Predictiva: Matriz de Confusión

Evaluamos el rendimiento práctico del modelo comparando las predicciones con los datos reales. Para ello, convertimos las probabilidades en clasificaciones binarias usando un umbral (cut-off) de 0.5.

```
### Generación de la Matriz de Confusión
# Obtenemos las probabilidades predichas por el modelo
predicciones_prob <- predict(logistica3, type = "response")

# Clasificamos: Si prob > 0.5 entonces "SI", de lo contrario "No"
predicciones_clase <- ifelse(predicciones_prob > 0.5, "SI", "No")

# Crear la tabla de confusión
matriz <- table(Real = binomial1$Baja, Predicho = predicciones_clase)
print(matriz)
```

```
##      Predicho
## Real  No  SI
## No 593  62
## SI 385  53
```

```
# Cálculo de la Precisión Global (Accuracy)
exactitud <- sum(diag(matriz)) / sum(matriz)
print(paste("Precisión global del modelo:", round(exactitud, 4)))
```




```
## [1] "Precisión global del modelo: 0.591"
```

1.6. Análisis de Discriminación: Curva ROC y AUC

La **Curva ROC** visualiza la relación entre la sensibilidad y la especificidad. El **AUC** (**Área bajo la curva**) mide la capacidad del modelo para diferenciar entre las categorías de la variable Baja.

```
### Curva ROC y cálculo del AUC
library(pROC)
roc_obj <- roc(binomial1$Baja, predicciones_prob)

plot(roc_obj, col = "blue", main = "Curva ROC - Rendimiento del Modelo",
     xlab = "Especificidad (1 - Falsos Positivos)",
     ylab = "Sensibilidad (Verdaderos Positivos)")
```



```
print(paste("AUC del modelo:", round(auc(roc_obj), 4)))
```

```
## [1] "AUC del modelo: 0.5893"
```

1.7. Conclusiones e Interpretación Final

Tras el análisis estadístico y la validación del modelo, se presentan las siguientes conclusiones:

1. **Variables Determinantes:** El modelo identifica que el **Tipo de Vehículo** (especialmente los de lujo), el **Estado Civil** y los **Ingresos** son los factores más significativos para predecir la probabilidad de Baja.
2. **Perfiles de Riesgo:**

- Los propietarios de **vehículos de lujo** tienen una probabilidad significativamente mayor de registrar una “Baja” en comparación con los dueños de vehículos económicos.
 - Las personas con estado civil **Soltero** muestran una menor propensión al evento en comparación con el grupo de referencia.
3. **Desempeño del Modelo:** El modelo final presenta una buena capacidad de discriminación, con un AUC de 0.589 y una precisión global de 59.1%.
 4. **Optimización:** La eliminación de variables como **Direccion** y **Educacion** permitió simplificar el modelo (reduciendo el AIC) sin perder capacidad predictiva significativa, cumpliendo con el principio de parsimonia.

Ejercicio 2 :Regresión Logística de dataset ‘multinomial.txt’

Se desea estimar un modelo para predecir donde comprará un consumidor en función del resto de variables y determinar si son influyentes todas las variables.

2.1. Análisis previos

```
datos <-read.table("multinomial.txt",header=T,sep="\t")
pander(head(datos))
```

Table 2: Table continues below

Especialidad	sexo	Persona	Frecuencia	Ofertas
Delicatesen	Hombre	El mismo	Quincenal	internet
Delicatesen	Hombre	El mismo	Quincenal	internet
Delicatesen	Hombre	El mismo y familia	Semanal	No
Delicatesen	Hombre	El mismo y pareja	Semanal	internet
sin especialidad	Hombre	El mismo y pareja	Quincenal	propaganda
sin especialidad	Hombre	El mismo y pareja	Semanal	De ambos

Gasto	Tipo.comercio
416.3	Mediana
383.2	Mediana
577.2	Mediana
436.4	Mediana
341.6	Grande
348.3	Grande

Datos cargados correctamente.

```
# Verificación de valores faltantes
pander(colSums(is.na(datos)))
```

Especialidad	sexo	Persona	Frecuencia	Ofertas	Gasto	Tipo.comercio
0	0	0	0	0	0	0

No tenemos valores NA.

```

datos$Especialidad<-as.factor(datos$Especialidad)
datos$sexo<-as.factor(datos$sexo)
datos$Persona<-as.factor(datos$Persona)
datos$Frecuencia<-as.factor(datos$Frecuencia)
datos$Ofertas<-as.factor(datos$Ofertas)
datos$Tipo.comercio<-as.factor(datos$Tipo.comercio)

```

```
str(datos)
```

```

## 'data.frame':  351 obs. of  7 variables:
## $ Especialidad : Factor w/ 4 levels "Delicatesen",...: 1 1 1 1 4 4 4 4 4 4 ...
## $ sexo          : Factor w/ 2 levels "Hombre","Mujer": 1 1 1 1 1 1 2 1 1 1 ...
## $ Persona       : Factor w/ 3 levels "El mismo","El mismo y familia",...: 1 1 2 3 3 3 3 1 3 3 ...
## $ Frecuencia    : Factor w/ 3 levels "diario","Quincenal",...: 2 2 3 3 2 3 2 3 3 2 ...
## $ Ofertas       : Factor w/ 4 levels "De ambos","internet",...: 2 2 3 2 4 1 1 3 2 2 ...
## $ Gasto         : num  416 383 577 436 342 ...
## $ Tipo.comercio: Factor w/ 3 levels "Grande","Mediana",...: 2 2 2 2 1 1 1 1 1 1 ...

```

Estructura de datos preparada correctamente para la regresión logística.

```
levels(as.factor(datos$Tipo.comercio))
```

```
## [1] "Grande" "Mediana" "Pequeña"
```

Una vez elegida nuestra variable objetivo y tras comprobar cuántas categorías contiene, decidimos realizar una regresión logística multinomial.

2.1. Regresión Logística Multinomial

```

summ <- summary(multi_saturo)
coeffs <- summ$coefficients
std_err <- summ$standard.errors

```

```
z_values <- coeffs / std_err
```

```
p_values <- (1 - pnorm(abs(z_values), 0, 1)) * 2
```

```
odds_ratios <- exp(coeffs)
```

```

for (i in 1:nrow(coeffs)) {
  cat("\n--- Comparativa de la categoría:", rownames(coeffs)[i], "en comparación con la categoría 'Grande'")

  table_final <- cbind(
    Coeficientes = coeffs[i, ],
    Std_Error    = std_err[i, ],
    Z_Value      = z_values[i, ],
    P_Value      = round(p_values[i, ], 5),
    Odds_Ratio   = odds_ratios[i, ]
  )

  print(table_final)
}

```

```

##
## --- Comparativa de la categoría: Mediana en comparación con la categoría 'Grande' ---
##      Coeficientes   Std_Error   Z_Value P_Value
## (Intercept)      -1.155937289  1.033449696 -1.1185230 0.26334
## Especialidadherbolario    0.046794411  0.444239159  0.1053361 0.91611
## EspecialidadPanaderia     0.105780500  0.512518816  0.2063934 0.83648
## Especialidadsin especialidad -1.105182572  0.308614877 -3.5811059 0.00034
## sexoMujer              0.175865283  0.287590940  0.6115119 0.54086
## PersonaEl mismo y familia -0.404565817  0.464744521 -0.8705123 0.38402
## PersonaEl mismo y pareja -0.223373646  0.300050660 -0.7444531 0.45660
## FrecuenciaQuincenal      0.357982380  0.429256204  0.8339597 0.40430
## FrecuenciaSemanal       -0.112704847  0.357034975 -0.3156689 0.75225
## Ofertasinternet        -0.096225921  0.376688833 -0.2554520 0.79837
## OfertasNo              0.306220608  0.389680849  0.7858241 0.43197
## Ofertaspropaganda      -0.229206156  0.406324949 -0.5640957 0.57269
## Gasto                 0.004616229  0.002135061  2.1621068 0.03061
##      Odds_Ratio
## (Intercept)      0.3147624
## Especialidadherbolario    1.0479065
## EspecialidadPanaderia     1.1115779
## Especialidadsin especialidad 0.3311504
## sexoMujer              1.1922774
## PersonaEl mismo y familia 0.6672665
## PersonaEl mismo y pareja 0.7998159
## FrecuenciaQuincenal      1.4304404
## FrecuenciaSemanal       0.8934143
## Ofertasinternet        0.9082588
## OfertasNo              1.3582819
## Ofertaspropaganda      0.7951646
## Gasto                 1.0046269
##
## --- Comparativa de la categoría: Pequeña en comparación con la categoría 'Grande' ---
##      Coeficientes   Std_Error   Z_Value P_Value
## (Intercept)      -2.839035264  1.40671411 -2.01820344 0.04357
## Especialidadherbolario    1.201898415  0.50156769  2.39628357 0.01656
## EspecialidadPanaderia     1.431755089  0.56574074  2.53076186 0.01138
## Especialidadsin especialidad -1.767885891  0.48290848 -3.66091295 0.00025
## sexoMujer              0.141080794  0.38505464  0.36639162 0.71407
## PersonaEl mismo y familia -0.970503667  0.65139575 -1.48988332 0.13625
## PersonaEl mismo y pareja -0.644366587  0.41016004 -1.57101258 0.11618
## FrecuenciaQuincenal      -0.137895207  0.61436935 -0.22445001 0.82241
## FrecuenciaSemanal       0.149287285  0.46178456  0.32328340 0.74648
## Ofertasinternet        0.306127741  0.49556477  0.61773508 0.53675
## OfertasNo              -0.005424971  0.53335075 -0.01017149 0.99188
## Ofertaspropaganda      -0.212079564  0.55510033 -0.38205627 0.70242
## Gasto                 0.006427819  0.00297337  2.16179572 0.03063
##      Odds_Ratio
## (Intercept)      0.05848206
## Especialidadherbolario    3.32642587
## EspecialidadPanaderia     4.18603962
## Especialidadsin especialidad 0.17069347
## sexoMujer              1.15151768
## PersonaEl mismo y familia 0.37889215
## PersonaEl mismo y pareja 0.52499498

```

```
## FrecuenciaQuincenal      0.87118998
## FrecuenciaSemanal       1.16100648
## Ofertasinternet         1.35815579
## OfertasNo               0.99458972
## Ofertaspropaganda       0.80890034
## Gasto                   1.00644852
```

Al verificar los valores del modelo, podemos observar cuáles son las variables más significativas y cuáles no.

- **Especialidadsin especialidad:** presenta valores muy altos y significativos en ambas categorías, lo que significa que, si una tienda no está especializada, es mucho menos probable que sea un comercio ‘mediano’ o ‘pequeno’.

Esto significa que las tiendas no especializadas tienden a ser ‘grandes’.

- **Gasto:** muy significativo para ambas categorías; el coeficiente bajo se debe a que la escala de variación de los gastos es muy pequeña (1 euro), pero si la aumentáramos, aumentaría su incidencia dada su altísima significación.
- **Especialidad | herbolario y panadería:** significativas solo en el pequeño comercio, lo que significa que estas especializaciones aumentan drásticamente la probabilidad de que el comercio sea ‘pequeno’ en comparación con ‘grande’.

Variables poco significativas

- **sexoMujer (p=0.54 y 0.71):** El género no influye en absoluto en la elección del tipo de comercio en esta muestra.
- **Ofertas (Internet, No, publicidad):** Ninguna de las modalidades de oferta es significativa (todas p-value > 0.40).

Las promociones no son un factor determinante a la hora de decidir si ir a una tienda grande, mediana o pequeña.

Frecuencia (quincenal, semanal): La frecuencia de compra tampoco muestra una relación estadística relevante (p-value hasta 0.82).

Persona (la propia persona y su familia o pareja): Quien realiza la compra no parece cambiar el destino final de la misma.

2.2. Comprobación de la significatividad del modelo y de las variables

```
anova(multisintparametros,multi_saturo)
```

```
## Likelihood ratio tests of Multinomial Models
##
## Response: datos$Tipo.comercio
## Response: Tipo.comercio
##
## 1                               Model Resid. df
## 1                               1       700
## 2 Especialidad + sexo + Persona + Frecuencia + Ofertas + Gasto 676
##   Resid. Dev   Test    Df LR stat.    Pr(Chi)
## 1   734.3810
## 2   643.3671 1 vs 2    24 91.01393 9.788671e-10
```

El valor p es inferior a 0.05, por lo que el modelo es significativo en comparación con el modelo que solo incluye la intersección.

Veamos ahora qué variables resultan significativas.

```

tabla_lr <- data.frame(
  Variable = c("Especialidad", "Sexo", "Persona", "Frecuencia", "Ofertas", "Gasto"),
  P_Value = c(
    test_esp$`Pr(>Chisq)`[2],
    test_sex$`Pr(>Chisq)`[2],
    test_per$`Pr(>Chisq)`[2],
    test_fre$`Pr(>Chisq)`[2],
    test_ofe$`Pr(>Chisq)`[2],
    test_gas$`Pr(>Chisq)`[2]
  )
)

tabla_lr$Significatividad <- ifelse(tabla_lr$P_Value < 0.001, "***",
                                   ifelse(tabla_lr$P_Value < 0.01, "**",
                                           ifelse(tabla_lr$P_Value < 0.05, "*", "ns")))

pander(tabla_lr, caption = "Resumen de las pruebas de razón de verosimilitud")

```

Table 5: Resumen de las pruebas de razón de verosimilitud

Variable	P_Value	Significatividad
Especialidad	3.676e-13	***
Sexo	0.8251	ns
Persona	0.5148	ns
Frecuencia	0.4	ns
Ofertas	0.6258	ns
Gasto	0.03522	*

Solo rechazaremos la hipótesis nula para las variables Especialidad y Gasto por tanto recalculamos el modelo quitando estas variables.

Para una última comprobación, sigamos un procedimiento por pasos → backward stepwise

```
multi_ottimal <- step(multi_saturo, direction = "backward", trace = 0)
```

```

## trying - Especialidad
## trying - sexo
## trying - Persona
## trying - Frecuencia
## trying - Ofertas
## trying - Gasto
## # weights: 33 (20 variable)
## initial value 385.612913
## iter 10 value 325.978616
## iter 20 value 323.879707
## final value 323.872058
## converged
## trying - Especialidad
## trying - sexo
## trying - Persona
## trying - Frecuencia

```

```
## trying - Gasto
## # weights: 27 (16 variable)
## initial value 385.612913
## iter 10 value 327.389262
## iter 20 value 325.736355
## final value 325.736276
## converged
## trying - Especialidad
## trying - sexo
## trying - Persona
## trying - Gasto
## # weights: 21 (12 variable)
## initial value 385.612913
## iter 10 value 328.873932
## final value 327.727691
## converged
## trying - Especialidad
## trying - sexo
## trying - Gasto
## # weights: 18 (10 variable)
## initial value 385.612913
## iter 10 value 328.498716
## final value 327.891955
## converged
## trying - Especialidad
## trying - Gasto
```

Tenemos la confirmación de que las únicas variables significativas son 'Especialidad' y 'Gasto'.

2.4. Modelo más parsimonioso

A la vista de los resultados obtenidos, el modelo más parsimonioso es:

Comprobemos que el nuevo modelo sea significativo.

```
anova(multisinparametros,multi2)
```

```
## Likelihood ratio tests of Multinomial Models
##
## Response: datos$Tipo.comercio
## Response: Tipo.comercio
##
##      Model Resid. df Resid. Dev   Test    Df LR stat.    Pr(Chi)
## 1          1      700   734.3810
## 2 Especialidad + Gasto      692   655.7839 1 vs 2     8 78.59707 9.35918e-14
```

Sí, tenemos la confirmación de que es significativo en comparación con el modelo que solo tiene la intersección.

Comprobemos si el `model_reducido` es mejor que el `model_saturado`.

```
anova(multi2, multi_saturado)
```

```
## Likelihood ratio tests of Multinomial Models
##
## Response: Tipo.comercio
##
##      Model Resid. df
## 1          Especialidad + Gasto      692
## 2 Especialidad + sexo + Persona + Frecuencia + Ofertas + Gasto      676
## Resid. Dev   Test    Df LR stat.   Pr(Chi)
```

```
## 1    655.7839
## 2    643.3671 1 vs 2    16 12.41686 0.7148202
```

Valor $p > 0.05$: significa que el modelo reducido no es peor que el completo.

En otras palabras, las variables eliminadas no aportaban información relevante.

Comprobemos si las dos variables siguen siendo significativas o si su significación se debía a sus relaciones con las demás.

```
# Estraiamo i p-value da ogni test per costruire una tabella chiara
tabla_lr2 <- data.frame(
  Variable = c("Especialidad", "Gasto"),
  P_Value = c(
    test_esp2$`Pr(>Chisq)`[2],
    test_gas2$`Pr(>Chisq)`[2]
  )
)

# Aggiungiamo i simboli di significatività (codici standard statistici)
tabla_lr2$Significatividad <- ifelse(tabla_lr2$P_Value < 0.001, "***",
                                     ifelse(tabla_lr2$P_Value < 0.01, "**",
                                             ifelse(tabla_lr2$P_Value < 0.05, "*", "ns")))

pander(tabla_lr2, caption = "Resumen de las pruebas de razón de verosimilitud")
```

Table 6: Resumen de las pruebas de razón de verosimilitud

Variable	P_Value	Significatividad
Especialidad	3.749e-13	***
Gasto	0.02042	*

Las variables siguen siendo muy significativas.

2.5. Bondad del ajuste y Significatividad de la predicción

```
pander(round(PseudoR2(multi2, which = c("CoxSnell", "Nagelkerke", "McFadden")),4))
```

CoxSnell	Nagelkerke	McFadden
0.2006	0.2289	0.107

Estos índices explican la mejora de la verosimilitud del modelo con respecto a un modelo nulo (sin predictores).

Los valores de todos los índices son bastante bajos; aunque las dos variables son excelentes predictores, no explican la totalidad del comportamiento de los consumidores, por lo que puede haber otros factores que no se hayan tenido en cuenta en el análisis.

```
prevision <- predict(multi2)

real <- datos$Tipo.comercio
```



```
matrix <- confusionMatrix(prevision, real)
```

```
print(matrix)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction Grande Mediana Pequeña
##   Grande      96      52      10
##   Mediana     39      62      29
##   Pequeña      9       27      27
##
## Overall Statistics
##
##           Accuracy : 0.5271
##           95% CI : (0.4734, 0.5803)
##   No Information Rate : 0.4103
##   P-Value [Acc > NIR] : 6.644e-06
##
##           Kappa : 0.2526
##
## Mcnemar's Test P-Value : 0.5763
##
## Statistics by Class:
##
##           Class: Grande Class: Mediana Class: Pequeña
## Sensitivity           0.6667           0.4397           0.40909
## Specificity           0.7005           0.6762           0.87368
## Pos Pred Value        0.6076           0.4769           0.42857
## Neg Pred Value        0.7513           0.6425           0.86458
## Prevalence            0.4103           0.4017           0.18803
## Detection Rate        0.2735           0.1766           0.07692
## Detection Prevalence  0.4501           0.3704           0.17949
## Balanced Accuracy     0.6836           0.5580           0.64139
```

A pesar de su baja precisión (52.7 %), el modelo, a través del valor p [Precisión > NIR] (6.644e-06), confirma que es estadísticamente mejor que el mero azar, por lo que es significativo.

El modelo confunde a menudo ‘Mediana’ con ‘Grande’ (52 veces) y ‘Mediana’ con ‘Pequeña’ (29 veces).

Es muy raro que el modelo confunda una tienda Grande con una Pequeña (solo 9 veces) o viceversa (solo 10 veces).

Esto significa que al modelo le cuesta distinguir los límites sutiles entre una categoría y la adyacente.

La categoría más fácil de predecir es Grande, mientras que la más difícil es Pequeña.

2.6. Estimación e Interpretación de los parametros

```
summ2 <- summary(multi2)
coeffs2 <- summ2$coefficients
std_err2 <- summ2$standard.errors

z_values2 <- coeffs2 / std_err2
```

```

p_values2 <- (1 - pnorm(abs(z_values2), 0, 1)) * 2

# Odds Ratios
odds_ratios2<- exp(coeffs2)

for (i in 1:nrow(coeffs)) {
  cat("\n--- Comparativa de la categoría:", rownames(coeffs)[i], "en comparación con la categoría 'Grande' ---\n")

  table_final2 <- cbind(
    Coeficientes = coeffs2[i, ],
    Std_Error    = std_err2[i, ],
    Z_Value      = z_values2[i, ],
    P_Value      = round(p_values2[i, ], 5),
    Odds_Ratio   = odds_ratios2[i, ]
  )

  print(table_final2)
}

```

```

##
## --- Comparativa de la categoría: Mediana en comparación con la categoría 'Grande' ---
##
##              Coeficientes  Std_Error  Z_Value P_Value
## (Intercept)    -0.628779781  0.554503951 -1.1339500 0.25682
## Especialidadherbolario    0.124742949  0.436797605  0.2855852 0.77520
## EspecialidadPanaderia    0.164285038  0.502446488  0.3269702 0.74369
## Especialidadsin especialidad -1.059047050  0.303458556 -3.4899232 0.00048
## Gasto           0.002947943  0.001323944  2.2266372 0.02597
##
##              Odds_Ratio
## (Intercept)    0.5332421
## Especialidadherbolario    1.1328572
## EspecialidadPanaderia    1.1785502
## Especialidadsin especialidad 0.3467861
## Gasto           1.0029523
##
## --- Comparativa de la categoría: Pequeña en comparación con la categoría 'Grande' ---
##
##              Coeficientes  Std_Error  Z_Value P_Value
## (Intercept)    -2.25002469  0.743794375 -3.025063 0.00249
## Especialidadherbolario    1.21085550  0.489754539  2.472372 0.01342
## EspecialidadPanaderia    1.29628634  0.546847316  2.370472 0.01777
## Especialidadsin especialidad -1.77902123  0.476141008 -3.736333 0.00019
## Gasto           0.00428768  0.001731049  2.476926 0.01325
##
##              Odds_Ratio
## (Intercept)    0.1053966
## Especialidadherbolario    3.3563548
## EspecialidadPanaderia    3.6556954
## Especialidadsin especialidad 0.1688033
## Gasto           1.0042969

```

Analicemos solo los que son estadísticamente significativos (considerando un valor $p < 0.05$).

Especialidad (sin especialidad) (0.3467): si la tienda no está especializada, la ventaja de ser 'Mediana'

se reduce en un 66 % con respecto a la ‘Grande’.

Esto significa que la escasa especialización favorece a las tiendas ‘Grandes’.

Para una tienda mediana, la falta de especialización supone una enorme desventaja competitiva frente a la gran distribución.

Gasto (1.0029): a medida que aumenta el presupuesto, aumenta la preferencia por la tienda de tamaño mediano frente a la gran distribución.

En las tiendas medianas, el precio unitario de los productos es más alto o el cliente tiende a realizar compras más selectivas y de mayor valor.

Intercepto (0.1053): indica que, en principio, es mucho menos probable elegir una tienda pequeña que una grande si no intervienen otros factores.

Especialidad (herbolario) (3.3563): si la tienda es una herbolaria, la ventaja de que sea una tienda ‘Pequena’ es 3.36 veces mayor que la de ser una tienda ‘Grande’.

Especialidad (Panadería) (3.6556): al igual que en el caso de la herboristería, el OR de 3.66 indica que las panaderías suelen asociarse con el comercio ‘pequeno’.

Especialidad sin especialidad (0.1688): si la tienda pequeña no está especializada, en comparación con la tienda mediana, la gente se inclina más por ir a la tienda ‘Grande’.

Gasto (1.0042): similar a la variable ‘Gasto’ comparada para las tiendas medianas.

2.6. Conclusión

Las tiendas Pequeñas y Medianas sobreviven gracias a la especialización; si no hay especialización, el cliente casi siempre elige la tienda grande.

La variable ‘Gasto’ tiene un efecto positivo para ambas categorías en comparación con las ‘Grandes’: quienes gastan más tienden a preferir las tiendas especializadas.